

的鉴别，每台路由器配置相同的口令。当一台路由器发送一个 OSPF 分组，它以明文方式包括了口令。显然，简单鉴别并不是非常安全。MD5 鉴别基于配置在所有路由器上的共享秘密密钥。对每个发送的 OSPF 分组，路由器对附加秘密密钥的分组内容计算 MD5 散列值。（参见第 7 章中报文鉴别码的讨论。）然后它将所得的散列值包括在该 OSPF 分组中。接收路由器使用预配置的秘密密钥计算出该分组的 MD5 散列值，并与该分组携带的散列值进行比较，从而验证了该分组的真实性。在 MD5 鉴别中也使用了序号对重放攻击进行保护。

- 多条相同费用的路径。当到达某目的地的多条路径具有相同的费用时，OSPF 允许使用多条路径（这就是说，当多条相等费用的路径存在时，无需仅选择单一的路径来承载所有的流量）。
- 对单播与多播路由选择的综合支持。多播 OSPF（MOSPF）[RFC 1584] 提供对 OSPF 的简单扩展，以便提供多播路由选择（这是在 4.7.2 节更深入学习的主题）。MOSPF 使用现有的 OSPF 链路数据库，并为现有的 OSPF 链路状态广播机制增加了一种新型的链路状态通告。
- 支持在单个路由选择域内的层次结构。也许 OSPF 最重要的优点是具有按层次结构构造一个自治系统的能力。在 4.5.3 节中我们已看到了层次路由选择结构的许多优点。在本节剩余部分，我们将学习 OSPF 层次路由选择的实现。

一个 OSPF 自治系统可以配置成多个区域。每个区域都运行自己的 OSPF 链路状态路由选择算法，一个区域内的每台路由器都向该区域内的所有其他路由器广播其链路状态。在一个区域内，一台或多台区域边界路由器（area border router）负责为流向该区域以外的分组提供路由选择。最后，在 AS 内只有一个 OSPF 区域配置成主干（backbone）区域。主干区域的主要作用是为 AS 内其他区域之间的流量提供路由选择。该主干总是包含了 AS 内的所有区域边界路由器，并且可能还包含了一些非边界路由器。在 AS 内的区域间的路由选择要求分组首先路由到一个区域边界路由器（区域内路由选择），再通过主干路由到位于目的区域的区域边界路由器，然后再路由到最终目的地。

OSPF 是一个相当复杂的协议，而我们这里的讨论是十分简要的，[Huitema 1998; Moy 1998; RFC 2328] 提供了更多的细节。

实践原则

设置 OSPF 链路权值

我们有关链路状态路由选择的讨论隐含地假设了下列事实：链路权重已经设置好了，运行了诸如 OSPF 这样的路由选择算法，流量根据由 LS 算法计算所得的路由选择表流动。就原果而言，给定链路权重（即它们先发生），结果得到（经 Dijkstra 算法）最小化总体费用的路由选择路径。从这个角度看，链路权重反映了使用一条链路的费用（例如，如果链路权重与容量成反比，则使用高容量链路将具有较小的权重并因此从路由选择的角度更有吸引力），并且使用 Dijkstra 算法使得总费用为最小。

在实践中，链路权重和路由选择路径之间的因果关系也许是相反的，网络操作员配置链路权重，以获取某些流量工程目标的路由选择路径 [Fortz 2000; Fortz 2002]。例如，

假设某网络操作员具有在每个入口点进入和发向每个出口点的进入网络的流量估计。该操作员接下来可能要设置特定入口到出口的流路由选择，以最小化经所有网络链路的最大利用率。但使用如 OSPF 这样的路由选择算法，操作员调节通过网络的流的路由选择，主要手段是链路权重。因此，为了取得最小化最大链路利用率的目标，该操作员必须找出取得该目标的链路权重集合。这是一种相反的因果关系，即所希望的流路由选择已知，必须找到 OSPF 链路权重，使得该 OSPF 路由选择算法导致这种希望的流路由选择。

4.6.3 自治系统间的路由选择：BGP

我们刚才学习了 ISP 如何使用 RIP 和 OSPF 来决定位于相同 AS 内部的源和目的对之间的优化路径。我们现在研究一下，跨越多个 AS 的源和目的对之间是如何确定路径的。由 RFC 4271（亦可参见 [RFC 4274]）定义的边界网关协议（Border Gateway Protocol, BGP）版本 4 是当今因特网中域间路由选择协议事实上的标准。它通常被称为 BGP4 或简称为 BGP。作为一个自治系统间路由选择协议（参见 4.5.3 节），BGP 为每个 AS 提供了进行以下工作的手段：

- 1) 从相邻 AS 处获得子网可达性信息。
- 2) 向本 AS 内部的所有路由器传播这些可达性信息。
- 3) 基于可达性信息和 AS 策略，决定到达子网的“好”路由。

更为重要的是，BGP 使得每个子网向因特网的其余部分通告它的存在。一个子网高声宣布“我存在，我在这里”，并且 BGP 确保在因特网中的所有 AS 知道该子网以及如何到达那里。如果没有 BGP 的话，每个子网将是隔离的，即它们孤独并且不为因特网其余部分所知。

1. BGP 基础

BGP 极其复杂，许多专著致力于研究该主题，而且许多问题仍没有得到很好理解 [Yannuzzi 2005]。此外，作为较高层 ISP 的设计者或管理员，即使在阅读了这些专著和这些 RFC 以后，如果不花数月（即使不是数年）实际实践 BGP 的话，可能发现难以全面掌握 BGP。无论如何，因为 BGP 是因特网中绝对至关重要的协议，即从本质上讲，正是这个协议将所有的东西粘合在一起了，因此我们至少需要获得该协议工作原理的初步知识。我们从描述 BGP 在简单的例子网络环境下如何工作开始，我们曾在图 4-32 中学习过该例子网络。在下面的描述中，我们的讨论将基于 4.5.3 节中的层次路由选择，希望读者能复习一下该材料。

在 BGP 中，路由器对通过使用 179 端口的半永久 TCP 连接来交换路由选择信息。对于图 4-32 中的网络而言，该半永久 TCP 显示在图 4-40 中。对于每条直接连接位于两个不同的 AS 中的路由器的链路而言，通常有一条这样的 BGP TCP 连接。因此，在图 4-40 中，在网关路由器 3a 和 1c 之间有一条 TCP 连接，在网关路由器 1b 和 2a 之间有另一条 TCP 连接。在一个 AS 中的路由器之间还有许多半永久 BGP TCP 连接。特别是，图 4-40 显示了一个 AS 内部的每对路由器之间的一条 TCP 连接的通常配置，在每个 AS 内部产生了网状的 TCP 连接。对于每条 TCP 连接，位于该连接端点的两台路由器称为 BGP 对等方（BGP peers），沿着该连接发送所有 BGP 报文的 TCP 连接称为 BGP 会话（BGP session）。此外，跨越两个 AS 的 BGP 会话称为外部 BGP（eBGP）会话（external BGP session），在同一个

AS 中的两台路由器之间的 BGP 会话称为内部 BGP (iBGP) 会话 (internal BGP session)。在图 4-40 中, eBGP 会话显示为长虚线, iBGP 会话显示为短虚线。注意到图 4-40 中的 BGP 会话线并不总是与图 4-32 中的物理链路对应。




图 4-40 eBGP 和 iBGP 会话

实践原则

获得因特网的存在：拼好拼图

假定你刚刚创建一个有一些服务器的小型公司网络, 包括一个描述你所在公司产品和服务的公共 Web 服务器、公司雇员获得电子邮件报文的电子邮件服务器和一台 DNS 服务器。你很自然地希望整个世界能够在你的 Web 站点上冲浪, 知道你那些令人兴奋的产品和服务。此外, 你将希望公司雇员能够向遍及全球的潜在用户发送和接收电子邮件。

为了满足这些目标, 你先要获得因特网连通性。为做到这一点, 要与一个本地 ISP 签订合同并与之连接。你的公司将要有一台网关路由器, 将其与本地 ISP 相连接。这种连接可以通过现有的电话基础设施的 DSL 连接、一条到 ISP 的租用线, 或在第 1 章中描述的许多其他种接入方案之一。你的本地 ISP 也将为你提供一个 IP 地址范围, 例如一个由 256 个地址组成的 /24 地址范围。一旦有了自己的物理连接和 IP 地址范围, 你将在该地址范围内分配 IP 地址: 一个给你的 Web 服务器, 一个给你的邮件服务器, 一个给你的 DNS 服务器, 一个给你的网关路由器, 其他 IP 地址给你公司网络中的其他服务器和网络设备。

除了与一个 ISP 签约外, 你还需要与一个因特网注册机构签约, 以便为你的公司获得一个域名, 如第 2 章所述。例如, 如果你的公司名为 Xanadu 公司, 你当然试图获得域名 xanadu.com。你的公司还必须在 DNS 系统中存在。特别是, 因为外部要与你的 DNS 服务器联系以获得服务器的 IP 地址, 你还需要注册你的 DNS 服务器的 IP 地址。你的注册机构则将你的 DNS 服务器 (域名和对应的地址) 放入 .com 顶级域名服务器中的一个表项中, 如在第 2 章中所述。完成这个步骤后, 知道你域名 (如 xanadu.com) 的任何用户将能够经过 DNS 系统获得你 DNS 服务器的 IP 地址。

为了使人们能够发现你 Web 服务器的 IP 地址, 你需要在你的 DNS 服务器中包括一个将你的 Web 服务器名字 (如 www.xanadu.com) 映射为其 IP 地址的表项。你还要有用其他公共可用的公司服务器的类似表项, 包括你的邮件服务器。如此一来, 如果 Alice 要浏览你的 Web 服务器, DNS 系统将联系你的 DNS 服务器, 找出你的 Web 服务器的 IP 地址, 并将其提交 Alice。Alice 则能够与你的 Web 服务器直接创建一条 TCP 连接。

然而，允许来自全世界的外部者接入你的 Web 服务器仍存在其他必要的、决定性的步骤。考虑下列情况，假设 Alice 知道你 Web 服务器的 IP 地址，当她向那个 IP 地址发送一个 IP 数据报（如一个 TCP SYN 报文段）。这个报文段将通过因特网进行路由，访问位于许多不同 AS 中的一系列路由器，并最终到达你的 Web 服务器。当这些路由器中的任一个接收到该报文段，将去其转发表中查找表项，以决定它转发该报文段的出口。因此，每台路由器需要知道你公司的/24 前缀（或某些聚合项）的存在。一台路由器怎样才能知道你公司的前缀呢？如我们刚才所见，它从 BGP 知道了前缀！特别是，当你的公司联系一个本地 ISP 并分配到一个前缀（如一个地址范围）时，你的本地 ISP 将使用 BGP 来向它连接的 ISP 通告该前缀。那些 ISP 则将依次使用 BGP 来传播该通告。最终，所有的因特网路由器将知道你的前缀（或包括你的前缀的某些聚合），因而能够以你的 Web 和邮件服务器为目的地址适当地转发数据报。

BGP 使得每个 AS 知道经过其相邻 AS 可达哪些目的地。在 BGP 中，目的地不是主机而是 CDIR 化的前缀（prefix），每个前缀表示一个子网或一个子网的集合。因此，例如假定有 4 个子网与 AS2 相连：138.16.64/24，138.16.65/24，138.16.66/24 和 138.16.67/24。则 AS2 能为这 4 个子网聚合这些前缀，并使用 BGP 向 AS1 通告单一前缀 138.16.64/22。举另一个例子，假定这 4 个子网中的前 3 个在 AS2 中，第四个子网 138.16.67/24 位于 AS3 中。则如 4.4.2 节中的实践原则所述，因为路由器使用最长前缀匹配来转发数据报，所以 AS3 向 AS1 通告更特定的前缀 138.16.67/24，而 AS2 仍然向 AS1 通告聚合的前缀 138.16.64/22。

现在我们研究一下 BGP 是怎样经显示在图 4-40 中的 BGP 会话来分发前缀可达性信息的。正如你所预想的那样，在网关路由器 3a 和 1c 之间使用 eBGP 会话，AS3 向 AS1 发送经 AS3 可达的前缀列表；AS1 向 AS3 发送经 AS1 可达的前缀列表。类似地，AS1 和 AS2 通过它们的网关路由器 1b 和 2a 交换其可达性信息。同样如你预期的那样，在任何 AS 中的网关路由器接收到 eBGP 学习到的前缀后，该网关路由器使用它的 iBGP 会话来向该 AS 中的其他路由器发布这些前缀。因此，在 AS1 中的所有路由器将得知 AS3 的前缀，包括网关路由器 1b 也将得知这些前缀。在 AS1 中的网关路由器 1b 因此能向 AS2 重新通告 AS3 的前缀。当一台路由器（网关或不是网关）得知一个新前缀时，它为该前缀在其转发表中创建一个项，如 4.5.3 所述的那样。

2. 路径属性和 BGP 路由

在对 BGP 有了一些基本了解后，下面我们更深入地学习它（在此过程中将同时增加一些较为不重要的技术细节！）。在 BGP 中，一个自治系统由其全局唯一的自治系统号（Autonomous System Number, ASN）[RFC 1930] 所标识。（从技术上讲，并非每个 AS 都有一个 ASN。特殊是有一种所谓桩（stub）AS 通常就没有 ASN，这种桩 AS 仅承载源地址或目的地址为本 AS 的流量。我们将在下面讨论中忽略这种特殊情况，以便能从全局看问题。）就像 IP 地址一样，AS 号由 ICANN 地区注册机构分配 [ICANN 2012]。

当一台路由器通过 BGP 会话通告一个前缀时，它在前缀中包括一些 BGP 属性（BGP attribute）。用 BGP 术语来说，带有属性的前缀被称为一条路由（route）。因此，BGP 对等方彼此通告路由。两个较为重要的属性是 AS-PATH 和 NEXT-HOP。

- AS-PATH。该属性包含了前缀的通告已经通过的那些 AS。当一个前缀传送到一个 AS 时，该 AS 将它的 ASN 增加到 AS-PATH 属性中。例如，考虑图 4-40，假定前缀 138.16.64/24 首先是由 AS2 向 AS1 通告的；如果 AS1 接下来将该前缀向 AS3 通告，则该 AS-PATH 将是 AS2 AS1。路由器使用该 AS-PATH 属性来检测和防止循环通告；特别是如果一台路由器看到它的 AS 被包括在该路径列表中，它将拒绝该通告。我们将很快讨论到，路由器也使用 AS-PATH 属性在多条路径中选择相同的前缀。
- 在 AS 间和 AS 内部路由选择协议之间提供重要链路后，NEXT-HOP 属性具有一种微妙而重要的用途。NEXT-HOP 是一个开始某 AS-PATH 的路由器接口。为了深入理解该属性，我们再次观察图 4-40。考虑当 AS3 中的网关路由器 3a 向 AS1 中的网关路由器 1c 通告一条路由时发生的情况。该路由包括通告前缀（我们称该前缀为 x ）和针对该前缀的一个 AS-PATH。该通告也包括 NEXT-HOP，这是路由器 3c 通向 1c 的接口的 IP 地址。（前面讲过一台路由器具有多个 IP 地址，每个接口有一个地址。）现在考虑当路由器 1d 得知了来自 iBGP 的这条路由后发生的情况。在得知到 x 的这条路由后，路由器 1d 可能要沿着该路由向 x 转发分组，即路由器 1d 可能要在其转发表中包括表项 (x, l) ，其中 l 是从 1d 朝着网关路由器 1c 开始最低费用路径的接口。为了决定 l ，1d 在 NEXT-HOP 属性中提供了到它的 AS 内部路由选择模块的 IP 地址。注意到 AS 内部路由选择算法已经确定了到 AS1 中所有与该路由器相连的子网的最低费用路径，包括到用于 1c 和 3a 之间的链路的子网。从 1d 到 1c-3a 子网的这条最低费用路径出发，1d 决定它的路由器接口 l 开始于这条路径，进而将表项 (x, l) 增加进它的转发表中。这就实现了这项功能！总而言之，路由器使用 NEXT-HOP 属性正确地配置它们的转发表。
- 图 4-41 图示说明了另一种需要 NEXT-HOP 的情况。在该图中，AS1 和 AS2 由两条对等链路连接。在 AS1 中的路由器能够知道到相同前缀 x 的两条不同的路由。这两条路由具有到 x 的相同的 AS-PATH，但具有不同的 NEXT-HOP 值对应于不同的对等链路。使用 NEXT-HOP 值和 AS 内部路由选择算法，路由器能够确定到每条对等链路的路径的费用，然后应用热土豆路由选择（参见 4.5.3 节）来决定适当的接口。

BGP 也包括允许路由器对路由分配偏好测度的属性，以及指示前缀如何插入位于起始 AS 的 BGP 的属性。对于路由属性的全面讨论，参见 [Griffin 2002; Stewart 1999; Halabi 2000; Feamster 2004; RFC 4217]。

当一台网关路由器接收到一台路由器通告时，它使用其输入策略（import policy）来决定是否接收或过滤该路由，是否设置某种属性，如路由器偏好测度。输入策略可能过滤掉一条路由，因为该 AS 可能不希望通过在该路由的 AS-PATH 中的某个 AS 发送流量。网关路由器也可能过滤一条路由，因为它已经知道了一条到相同前缀的偏好路由。




图 4-41 在通告中用于确定使用哪条对等链路的 NEXT-HOP 属性

3. BGP 路由选择

如本节前面所述，BGP 使用 eBGP 和 iBGP 向在 AS 中的所有路由器发布路由。根据这种发布，路由器可能知道到达任何一条前缀的多条路由，在这种情况下路由器必须在可能的路由中选择一条。进入这个路由选择进程的输入是被路由器知道并接受的所有路由的集合。如果对相同前缀存在两条或多条路由，则 BGP 顺序地调用下列消除规则，直到留下一条路由。

- 路由被指派一个本地偏好值作为它们的属性之一。一条路由的本地偏好可能由该路由器设置或可能由在相同 AS 中的另一台路由器学习到。这是一条由 AS 的网络管理员决定的决策。（我们随后将更为详细地讨论 BGP 策略问题。）具有最高本地偏好值的路由将被选择。
- 在余下的路由中（所有都具有相同的本地偏好值），具有最短 AS-PATH 的路由将被选择。如果该规则是路由选择的唯一规则的话，则 BGP 将使用一种距离向量算法来决定路径，其中距离测度使用 AS 跳的数目而不是路由器跳的数目。
- 在余下的路由中（所有都具有相同的本地偏好和相同的 AS-PATH 长度），将选择具有最靠近 NEXT-HOP 路由器的路由。这里，最靠近是指具有最低费用路径的费用的路由器，它由 AS 内部算法来决定。如在 4.5.3 节中所讨论的那样，该进程经常被称为热土豆路由选择。
- 如果仍留下多条路由，该路由器使用 BGP 标识符来选择路由；参见 [Stewart 1999]。

消除规则甚至比上面描述的更为复杂。为了避免 BGP 出现严重问题，少量地学习一些 BGP 选择规则方面的知识是有帮助的。

实践原则

将它们拼装起来：表项是怎样进入路由器的转发表的？

前面讲过路由器转发表中的一个表项是由前缀（如 138.16.64/22）和一个对应的路由器输出端口（如端口 7）组成的。当一个分组到达路由器时，该分组的目 IP 地址与转发表中的前缀进行比较，找到与最长前缀匹配的表项。该分组则（在本路由器中）转发到与该前缀相关的端口。我们现在总结一下一个路由选择表项（前缀和相关端口）是如何进入转发表中的。这种简单的操作将我们已经学习的路由选择和转发的知识有机地结合了起来。为了使其有趣，我们假设该前缀是一种“外部前缀”，即它不属于该路由器的 AS 而属于某些其他 AS。

为使一个前缀进入路由器的转发表，路由器必须首先知晓该前缀（对应于一个子网或子网的一个聚合）。如我们已经学习的那样，经过 BGP 路由通告，该路由器知道了前缀。这种通告可能（从位于另一个 AS 中的一台路由器）经一个 eBGP 会话，或者（从位于相同 AS 中的一台路由器）经一个 iBGP 会话发送给它。

在路由器知道了前缀之后，在它能够在其转发表中加入该前缀之前，需要决定适当的输出端口——目的地指向该前缀的数据报将转发到该端口。如果路由器接收到对该前缀的多个路由通告，该路由器使用 BGP 路由选择进程，如本小节前面描述的那样，找到对于该前缀的“最好的”路由。假定这样一条最好的路由已选定。如前所述，所选择

的路由包括了 NEXT-HOP 属性，它是沿着这条最好路径的该路由器 AS 之外的第一台路由器的 IP 地址。如前所述，该路由器则使用它的 AS 内部路由选择协议（通常为 OSPF）来确定通向 NEXT-HOP 路由器的最短路径。路由器最后通过指出沿最短路径的第一段链路，确定端口号以关联其前缀。路由器则能够（最终！）将前缀 - 端口对加入其转发表！由路由选择过程计算（参见图 4-6）的转发表则被推入路由器的输入端口线路卡。

4. 路由选择策略

我们用一个简单的例子说明 BGP 路由选择策略的某些基本概念。图 4-42 显示了 6 个互联的自治系统：A、B、C、W、X 和 Y。重要的是注意到 A、B、C、W、X 和 Y 是 AS，而不是路由器。假设自治系统 W、X 和 Y 是桩网络，A、B 和 C 是主干提供商网络。我们还要假设 A、B 和 C 都是彼此对等的，并向它们的客户网络提供全部的 BGP 信息。所有进入桩网络（stub network）的流量必定是去往该网络，所有离开桩网络的流量必定源于该网络。W 和 Y 显然是桩网络。X 是一个多宿桩网络（multi-homed stub network），因为它是经由两个不同的提供商连到网络的其余部分（这种方法在实践中变得越来越普遍）。然而，就像 W 和 Y 一样，X 自身必定是进入/离开 X 的所有流量的源/目的地。但这种桩网络的行为是如何被实现和强制实现的呢？X 如何防止转发 B 与 C 之间的流量呢？这通过控制 BGP 路由的通告方式可容易地实现。特别是，X 如果（向其邻居 B 和 C）通告它没有通向（除自身以外）任何其他目的地的路径，那么它将起到一个桩网络的作用。这就是说，即使 X 可能知道一条路径能到达网络 Y，比如说 XCY，它也不该条路径通告给 B。由于 B 不知道 X 有一条路径到 Y，B 绝不会经由 X 转发目的为 Y（或 C）的流量。这个简单的例子说明了如何使用一条选择的路由通告策略来实现客户/提供商关系。




图 4-42 一个简单的 BGP 应用情况

我们接下来关注一个提供商网络，比如自治系统 B。假定 B 已经（从 A 处）知道了 A 有一条到 W 的路径 AW。B 因此能将路由 BAW 设置到其路由信息库中。显然，B 也想向它的客户 X 通告路径 BAW，这样 X 知道它能够通过 B 路由选择到 W。但是，B 应该将路径 BAW 通告给 C 吗？如果它这样做，则 C 可以经由 CBAW 将流量引导到 W。如果 A、B 和 C 都是主干提供商，而 B 也许正好觉得它不应该承担在 A 与 C 之间传送流量的负担（和费用！）。B 可能有理由认为，确保 C 能经过 A 和 C 之间的直接连接引导 A 客户的流量是 A 和 C 的工作（和费用）。目前还没有强制主干 ISP 之间如何路由选择的官方标准。然而，商业运行的 ISP 们都遵从的一个经验法则是：任何穿越某 ISP 主干网的流量必须是其源或目的（或两者）位于该 ISP 的某个客户网络中；不然的话这些流量将会免费搭车通过该 ISP 的网络。各个对等协定（用于解决前面提到的问题）通常都是 ISP 双方进行协商，而且经常是对外保密；[Huston 1999a] 提供了关于对等协定的有趣讨论。路由选择策略如

何反映 ISP 之间的商业关系的详细描述参见 [Gao 2001; Dimitropoulos 2007]。从 ISP 的立场出发, 有关 BGP 路由选择策略的讨论参见 [Caesar 2005b]。

如上所述, BGP 是一个对于公共因特网的 AS 之间路由选择的事实上的标准。为了观察从第一层 ISP 路由器 (大量) 提取出来的各种 BGP 路由选择表的内容, 参见 <http://www.routeviews.org>。BGP 路由选择表通常包含数以万计的前缀和对应的属性。有关 BGP 路由选择表的规模和特征的统计数据呈现在 [Potaroo 2012]。

我们完成了对 BGP 的简要介绍。理解 BGP 是重要的, 因为它在因特网中起着重要作用。我们鼓励你阅读参考文献 [Griffin 2012; Stewart 1999; Labovitz 1997; Halabi 2000; Huitema 1998; Gao 2001; Feamster 2004; Caesar 2005; Li 2007], 以学习更多的 BGP 知识。

实践原则

为什么会有不同的 AS 间和 AS 内部路由选择协议?

学习了目前部署在因特网中的特定的 AS 间和 AS 内部路由选择协议, 通过思考一个也许是最为根本性的问题——这是我们对这些协议首先会问的问题, 来得到结论 (希望你已经一直在思考该问题, 并且不致因技术细节而不能把握全局): 为什么要使用不同的 AS 间和 AS 内部路由选择协议?

对该问题的答案触及了 AS 内与 AS 间的路由选择目标之间差别的本质:

- 策略。在 AS 之间, 策略问题起主导作用。一个给定 AS 产生的流量不能穿过另一个特定的 AS, 这可能非常重要。类似地, 一个给定 AS 也许想控制它承载的其他 AS 之间穿越的流量。我们已看到, BGP 承载了路径属性, 并提供路由选择信息的受控分布, 以便能做出这种基于策略的路由选择决策。在一个 AS 内部, 一切都是在相同的管理控制名义下进行的, 因此策略问题在 AS 内部选择路中起着微不足道的作用。
- 规模。扩展一个路由选择算法及其数据结构以处理到大量网络或大量网络之间的路由选择的这种能力, 是 AS 间路由选择的一个关键问题。在一个 AS 内, 可扩展性不是关注的焦点。首先, 如果单个管理域变得太大时, 总是能将其分成两个 AS, 并在这两个新的 AS 之间执行 AS 间路由选择算法。(前面讲过, OSPF 通过将一个 AS 分成区域而建立这样的层次结构。)
- 性能。由于 AS 间路由选择是面向策略的, 因此所用路由的质量 (如性能) 通常是次要关心的问题 (即一条更长或费用更高但能满足某些策略条件的路由也许被采用了, 而更短但不满足那些条件的路由却不会被采用)。我们的确看到了在 AS 之间, 甚至没有与路由相关的费用 (除了 AS 跳计数外) 概念。然而在一个 AS 内部, 这种对策略的关心就不重要了, 可以使路由选择更多地关注于一条路由实现的性能级别方面。

4.7 广播和多播路由选择

到目前为止, 本章关注的是支持单播 (即点对点) 通信的路由选择协议, 单个源结点

基于这种协议向单个目的结点发送分组。在本节中，我们将注意力转向广播和多播路由选择协议。在广播路由选择（broadcast routing）中，网络层提供了从一种源结点到网络中的所有其他结点交付分组的服务；多播路由选择（multicast routing）使单个源结点能够向其他网络结点的一个子集发送分组的副本。在 4.7.1 节中，我们将考虑广播路由选择算法和它们在路由选择协议中的具体实现。我们将在 4.7.2 节中研究多播路由选择。

4.7.1 广播路由选择算法

也许完成广播通信的最直接的方式是由发送结点向每个目的地分别发送分组的副本，如图 4-43a 所示。在给定 N 个目的结点的情况下，源结点只是产生该分组的 N 份副本，对不同目的地的每个副本进行编址，并用单播路由选择向 N 个目的地传输这 N 份副本。这种用 N 次单播（ N -way-unicast）实现广播的方法简单，无需新的网络层路由选择协议以及分组复制或转发功能。然而，这种方法有几个缺点。第一个缺点是它的效率低。如果源结点经过单一链路与该网络其余部分相连的话，该（相同）分组的 N 份独立的副本将都经过该段链路传输。显然更为有效的方式是，经第一跳仅发送分组的单个副本，然后让第一跳后面其他端的结点生成并转发任何附加的所需副本。这就是说，让网络结点本身（而不只是源结点）生成分组的冗余副本将更加有效。例如，在图 4-43b 中，仅有分组的一个副本通过 $R1$ - $R2$ 链路。该分组则在 $R2$ 被复制，经链路 $R2$ - $R3$ 和 $R2$ - $R4$ 发送单个副本。

N 次单播的其他缺点也许更为微妙，但不太重要。 N 次单播的一个隐含假设是广播的接收方及其地址均为发送方所知。

但是怎样得到这些信息呢？最可能的是，需要有另外的协议机制（如广播成员或目的地注册协议）。这将增加更多的开销，并且重要的是为最初看起来相当简单的协议增加了复杂性。 N 次单播的最后一个缺点与使用广播的目的有关。在 4.5 节中，我们知道了链路状态路由选择协议使用广播来分发用于计算单播路由的链路状态信息。显然，在使用广播来生成和更新单播路由的情况下，基于单播路由选择基础设施来取得广播将（最多！）是不明智的。

指出了 N 次单播实现广播的几个缺点后，网络结点本身在分组复制、分组转发和广播路由计算中起积极作用的方法，将显然是令人感兴趣的。下面我们将研究这样的几种方法，并再次采用在 4.5 节中引入的图标标记法。我们再次将网络建模为图 $G = (N, E)$ ，其中 N 是结点的集合， E 是边的集合，其中每条边是来自 N 的一对结点。当不致混淆时，使用 N 表示结点的集合以及表示该集合的基数（ $|N|$ ）或长度，虽然这种标记法有点不够严谨。

1. 无控制洪泛

实现广播的最显而易见的技术是洪泛（flooding）方法，该方法要求源结点向它的所有邻居发送分组的副本。当某结点接收了一个广播分组时，它复制该分组并向它的所有邻




图 4-43 源复制与网络中复制的比较

居（除了从其接收该分组的那个邻居）转发之。显然，如果图是相连的，这种方案将最终将广播分组的副本交付给该图中的所有结点。虽然这种方案简单而优雅，但它具有致命缺点（在你继续阅读前，看看你能否猜出这个致命缺点）：如果该图具有圈，则每个广播分组的一个或多个分组副本将无休无止地循环。例如，在图 4-44 中，R2 将洪泛到 R3，R3 将洪泛到 R4，R4 将洪泛到 R2，R2 将（再次）洪泛到 R3，等等。这种简单情况导致两个广播分组无休止地循环，一个朝顺时针方向，一个朝逆时针方向。但还可能存在着一种更为不幸的致命缺陷：当一个结点与两个以上其他结点连接时，它将生成并转发广播分组的多个副本，这些副本中的每个又产生多个它们自身的副本（在有两个以上邻居的其他结点处），等等。这种**广播风暴**（broadcast storm）导致无休止的广播分组的复制，将最终导致在该网络中生成大量的广播分组，使得网络变得毫无用处。（参见本章课后作业中分析这种广播风暴增长速率的问题。）

2. 受控洪泛

避免广播风暴的关键是每个结点明智地选择何时洪泛分组，何时不洪泛分组（例如，如果它已经接收并洪泛了某分组的较早副本）。在实践中，这能够以几种方式来实现。

在**序号控制洪泛**（sequence-number-controlled flooding）中，源结点将其地址（或其他唯一的标识符）以及**广播序号**（broadcast sequence number）放入广播分组，再向它的所有邻居发送该分组。每个结点维护它已经收到的、复制的和转发的源地址和每个广播分组的序号列表。当结点接收到一个广播分组时，它首先检查该分组是否在列表中。如果在，丢弃该分组；如果不在，复制该分组并向该结点的所有邻居转发（除了接收到该分组从它的那个结点）。在第 2 章中讨论的 Gnutella 协议在它的覆盖网络中对广播查询使用了序号控制洪泛。（在 Gnutella 中，报文复制和转发在应用层执行，而不是在网络层执行。）

受控洪泛的第二种方法被称为**反向路径转发**（Reverse Path Forwarding, RPF）[Dalal 1978]，有时也称为**反向路径广播**（RPB）。RPF 的基本思想简单且优雅。当一台路由器接收到具有给定源地址的广播分组时，仅当该分组到达的链路正好是位于它自己的返回其源的最短单播路径上，它才向其所有出链路（除了它接收分组的那个）传输报文；否则，路由器只是丢弃入分组而不向任何它的出链路转发分组。因为路由器知道它在这样一条链路上将接收或者已经接收了该分组的一个副本（该链路位于自身返回发送方最短路径上），故这样一个分组能够被丢弃。（你也许应当搞清，事实上，如果发生了这样的情况，环路和广播风暴将不会出现。）注意到 RPF 不使用单播路由选择以实际将分组交付给目的地，它也不要求路由器知道从它自己到源的完整最短路径。RPF 仅需要知道在它到发送方的单播最短路径上的下一个邻居；它仅使用这个邻居的身份以决定是否洪泛一个接收到的广播分组。

图 4-44 举例说明了 RPF。假定用粗线画的链路表示了从接收方到源（A）的最低费用路径。结点 A 最初广播一个源为 A 的分组到结点 C 和 B。结点 B 将向结点 C 和 D 转发它从结点 A 接收到的源为 A 的分组（因为 A 位于到 A 的最低费用路径




图 4-44 反向路径转发

上)。B 将忽略（丢弃而不转发）从任何其他结点（如从路由器 C 或 D）接收的源为 A 的分组。我们现在考虑结点 C，C 将直接从 A 以及从 B 接收源为 A 的分组。因为 B 不在 C 自己到 A 的最短路径上，C 将忽略来自 B 的任何源为 A 的分组。在另一方面，当 C 接收到直接来自 A 的源为 A 的分组，它将向结点 B、E 和 F 转发该分组。

3. 生成树广播

虽然序号控制洪泛和 RPF 避免了广播风暴，但它们不能完全避免冗余广播分组的传输。例如，在图 4-44 中，结点 B、C、D、E 和 F 接收到一个或两个冗余分组。在理想情况下，每个结点应当仅接收广播分组的一个副本。查看在图 4-45a 中由粗线相连结点组成的树，你能看到如果广播分组仅沿着该树中的链路转发的话，所有网络结点的每个将恰好接收到广播分组的一个副本，这正是我们要寻找的解决方案！该树是一棵生成树（spanning tree）的例子，它包含了图中的每个结点。更形式化地讲，图 $G = (N, E)$ 的一棵生成树是一个图 $G' = (N, E')$ ，使得 E' 是 E 的子集， G' 是连通的， G' 不包含圈，并且 G' 包括了在 G 中的所有初始结点。如果每段链路具有相应的费用且一棵树的费用就是其链路费用之和，则在该图的所有生成树中费用最小的生成树（毫不奇怪地）被称为最小生成树（minimum spanning tree）。




图 4-45 沿着一棵生成树的广播

因此，提供广播的另一种方法是首先对网络结点构造出一棵生成树。当一个源结点要发送一个广播分组时，它向所有属于该生成树的特定链路发送分组。接收广播分组的结点则向在生成树中的所有邻居转发该分组（其接收该分组的邻居除外）。生成树不仅消除了冗余的广播分组，而且一旦合适，该生成树能够被任何结点用于开始广播分组，如图 4-45a 和图 4-45b 中所示。注意到一个结点不必知道整棵树；只需要知道它在 G 中的哪些邻居是生成树的邻居。

与生成树方法相关的复杂性主要是生成树的生成和维护。已经研制出了若干种分布式生成树算法 [Gallager 1983, Gartner 2003]。这里我们仅考虑一种简单的算法。采用基于中心的方法（center-based approach）建立一棵生成树时，要定义一个中心结点（也称之为汇合点（rendezvous point）或核（core））。结点则向中心结点单播加入树（tree-join）报文。加入树报文使用单播路由选择朝着中心结点转发，直到它到达一个已经属于生成树的结点或到达该中心。在任一种情况下，加入树报文经过的路径定义了发起加入树报文的边缘结点和中心之间的生成树分支。这个新分支能够认为已被嫁接到现有的生成树上了。

图 4-46 举例说明了基于中心生成树的构造过程。假定结点 E 被选作该树的中心。假定结点 F 首先加入树并向 E 转发加入树报文。单一链路 EF 成为初始的生成树。然后结点 B 通过向 E 发送它的加入树报文来加入该生成树。假定单播路径从 B 路由到 E 要经过 D。在这种情况下，加入树报文导致路径 BDE 被嫁接到生成树上。结点 A 接下来通过向 E 转发它的加入树报文来加入生成组。如果 A 到 E 的单播路径通过 B，则因为 B 已经加入了这棵生成树，A 的加入树报文到达 B 将导致该 AB 链路立即被嫁接在生成树上。结点 C 接下来通过向 E 直接转发它的加入树报文，加入了该生成树。最后，因为从 G 到 E 的单播路由选择必须经过结点 D，当 G 向 E 发送它的加入树报文时，该 GD 链路在结点 D 被嫁接到该生成树上。




图 4-46 基于中心构造一棵生成树

4. 实践中的广播算法

在实践中，广播协议被用于应用层和网络层。Gnutella [Gnutella 2009] 为了在 Gnutella 对等方之间广播对内容的查询，使用应用级的广播。其中，在 Gnutella 网络中的两个分布式应用级对等进程之间的一条链路实际上是一条 TCP 连接。Gnutella 使用某种形式的序号控制洪泛，其中使用了一个 16 比特标识符和一个 16 比特有效载荷描述符（它标识了 Gnutella 报文类型），以监测一个接收到的广播查询是否以前已经收到、复制和转发过。Gnutella 也使用一个寿命（TTL）字段来限制转发一个洪泛请求通过的跳数。当一个 Gnutella 进程接收并复制一个请求时，它在转发请求之前减小 TTL 字段。因此，一个洪泛的 Gnutella 请求将仅到达位于从该请求的发起者到给定数量（TTL 的初始值）的应用级跳数范围内的对等方。Gnutella 的洪泛机制因此有时被称为范围受限的洪泛。

在 OSPF [RFC 2328; Perlman 1999] 路由选择算法和中间系统到中间系统（IS-IS）路由选择算法 [RFC 1142; Perlman 1999] 中，使用了一种序号控制洪泛来广播链路状态通告（LSA）。OSPF 使用一个 32 比特序号，以及一个 16 比特年龄（age）字段来标识 LSA。前面讲过，当到邻居的链路费用变化时，或当一条链路变化为通/断时，OSPF 结点周期性地向与它相连的链路广播 LSA。LSA 序号被用于检测冗余的 LSA，但也服务于 OSPF 中的第二项重要功能。使用洪泛方法，源在时刻 t 生成的一个 LSA 的到达可能晚于相同源在时刻 $t + \delta$ 产生的较新的 LSA。源结点使用的序号使得一个较旧的 LSA 能够区别于较新的 LSA。年龄字段起到了类似于一个 TTL 值的作用。初始年龄字段值被置为 0，随着洪泛到每一跳而被增加，并且当它位于一台路由器内存中等待洪泛时也会增加。尽管我们这里只是

简要地描述了 LSA 洪泛算法，但我们注意到设计 LSA 广播协议是件技巧性很强的事情。[RFC 789; Perlman 1999] 描述了一次事故，在这次事故中，由于两个故障路由器不正确地传输 LSA，引起早期版本的 LSA 洪泛算法使整个 ARPAnet 瘫痪了！

4.7.2 多播

我们在前面小节中已经看到了使用广播服务，分组被交付给网络的所有结点。在本节中，我们将注意力转向多播（multicast）服务。使用这种服务，多播分组仅被交付给网络结点的一个子集。一些新兴的网络应用要求将分组从一个或多个发送方交付给一组接收方。这些应用包括批量数据传送（例如从软件开发者到需要升级的用户之间的升级软件的传送）、流式连续媒体（例如将一个演讲实况的音频、视频和文本传送给一组分布在多处的演讲参与者）、数据共享应用（例如在多个分布的参与者之间共享的电子公告或电视会议应用）、数据供给（例如股票报价）、Web 缓存更新、交互式游戏（例如分布式交互虚拟环境或多方游戏）。

在多播通信中，我们立即面临两个问题，即怎样标识多播分组的接收方，以及怎样为发送到这些接收方的分组编址。在单播通信情况下，接收方（目的地）的 IP 地址承载在每个 IP 单播数据报中并标识了单个接收方；在广播的情况下，所有结点需要接收广播分组，因此不需要目的地址。但在多播情况下，我们目前面对多个接收方。每个多播分组都携带所有接收方的 IP 地址，这合理吗？虽然这种方法对于少量的接收方可能是行得通的，但它不能很好地扩展到数以百计或数以千计的接收方场合；在数据报中编址信息的量将充斥该分组中有效载荷字段中实际可携带的数据量。还需要由发送方给出接收方的明确标识，使得发送方知道所有接收方的标识与地址。我们很快就会看到，在许多场合下是不希望有这种要求的。

由于这些原因，在因特网体系结构（还有其他体系结构如 ATM [Black 1995]）中，多播数据报使用间接地址（address indirection）来编址。这就是说，用一个标识来表示一组接收方，寻址到该组的分组副本被交付给所有与该组相关联的多播接收方，且该组使用这个单一标识符。在因特网中，这种表示一组接收方的单一标识就是一个 D 类多播地址。与一个 D 类地址相关联的接收方小组被称为一个多播组（multicast group）。多播组抽象在图 4-47 中举例说明。图中的 4 台主机（显示为深色）与多播组地址 226.17.30.197 相关联，而且它们将接收所有寻址到该多播地址的数据报。我们仍然必须应对的困难在于这样一个事实，每台主机有一个唯一的 IP 单播地址，该单播地址完全独立于它所参与的多播组的地址。

虽然多播组抽象是简单的，但它给人们（主机）（故意使用了双关语，英语中 host 有主机或主人之意）带来了一堆问题。一个组是如何形成，又如何终结的呢？如何选择组地址？新主机如何加入某个组（要么作为发送方，要么作为接收方）？任何主机都能加入一个组（向该组发送或从该组接收）或者组成员资格会受到限制吗？如果有限制，由谁限制？作为网络层协议的一部分，一个组成员知道其他组成员的标识吗？网络结点相互之间如何进行交互，以向所有组成员交付一个多播数据报呢？对于因特网，所有这些问题的答案都与因特网组管理协议（IGMP）[RFC 3376] 有关。所以，我们接下来简要地考虑 IGMP，然后再回到这些更为一般的问题上来。




图 4-47 多播组：寻址到该组的数据报被交付给多播组的所有成员

1. 因特网组管理协议

IGMP 版本 3 [RFC 3376] 运行在一台主机与其直接相连的路由器之间（不严格地说，我们可将直接相连的路由器看作第一跳路由器，即主机看到的在它自己本地网络外部的到任何其他主机的一条路径，或到该主机的任何路径上的最后一跳路由器），这种情况如图 4-48 所示。图 4-48 显示了 3 台第一跳多播路由器，每一台都通过一个向外的本地接口与相连的主机连接。在该例中，本地接口连到一个 LAN 上，且每个 LAN 都有多台相连的主机，在任意给定时间内至多有几台主机属于一个给定的多播组。




图 4-48 因特网中网络层多播的两个组件：IGMP 与多播路由选择协议

IGMP 为一台主机提供了手段，让它通知与其相连的路由器：在本主机上运行的一个应用程序想加入一个特定的多播组。由于 IGMP 的交互范围被局限在主机与其相连的路由器之间，显然需要另一种协议来协调遍及因特网内的多播路由器（包括相连的路由器），以便多播数据报能路由到其最终目的地。后一个功能是由网络层多播路由选择算法完成

的，我们将很快考虑这些算法。因此因特网中的网络层多播是由两个互补的组件组成的：IGMP 与多播路由选择协议。

IGMP 只有三种报文类型。与 ICMP 类似，IGMP 报文也是承载（封装）在一个 IP 数据报中，使用的 IP 协议号为 2。由一台路由器向所有与主机（如局域网上的所有主机）相连的接口（例如在一个局域网对所有主机）发送一个 membership_query 报文，以确定该接口上主机已加入的所有多播组集合。主机用一个 membership_report 报文来响应 membership_query 报文。当一个应用程序首次加入一个多播组时，也可由主机产生 membership_report 报文，而不用等待来自路由器的 membership_query 报文。最后一种 IGMP 报文类型是 leave_group 报文。有趣的是，这种报文是可选的！但如果它是可选的，那么一台路由器如何检测出一台主机是何时离开该多播组的呢？问题的答案就在于使用了 membership_query 报文：当无主机响应一个具有给定组地址的 membership_query 报文时，该路由器就推断出已没有主机在这个多播组了。这是因特网协议中有时被称为软状态（soft state）机制的一个例子。在一个软状态协议中，状态（在 IGMP 场合中，有主机加入某给定多播组的事实）如果未被显式地更新（在本例中，由来自一相连主机的 membership_report 报文更新），则通过超时事件（在本例中，通过来自路由器的周期性的 membership_query 报文）被删除。

软状态一词由 Clark [Clark 1988] 所创造，Clark 描述了由某个端系统发送的周期性状态更新报文的观念，并且建议使用这样的更新报文，状态能够在一次崩溃中丢失，接着自动地由后继的更新报文所恢复，即对该端系统来说所有都是透明的，并且不必调用任何显式的崩溃恢复过程：

“……状态信息对于维护与流相关联的所希望类型的服务将不是至关重要的。

相反，服务类型将由端点强制执行，端点将周期性地发送报文以确保适当类型的服务与该流相关联。以这种方式，与该流关联的状态信息可能在崩溃中丢失，但不会永久地破坏所使用的服务特色。我将这种概念称作“软状态”，它能非常好地使我们取得生存性和灵活性的基本目标……”

人们已争论过软状态协议要比硬状态协议的控制简单一些，后者不仅要求状态显式地增加或删除，还要求有机能够负责当实体提早结束或失败时清除状态。有关软状态的有趣讨论可在 [Raman 1999; Ji 2003; Lui 2004] 中找到。

2. 多播路由选择算法

图 4-49 中举例说明了多播路由选择问题（multicast routing problem）。加入该多播组的主机着深色，与其直接相连的路由器也着深色。如图 4-49 中所示，只有一部分路由器（那些具有加入该多播组的相连主机的路由器）实际需要接收多播流量。在图 4-49 中，只有路由器 A、B、E 和 F 需要接收该多播流量。因为与路由器 D 相连的主机中没有加入该多播组，且路由器 C 无相连





图 4-49 多播主机、与其相连的路由器及其他路由器

主机，所以 C 和 D 都不需要接收该多播组流量。那么多播路由选择的目标就是发现一棵链路的树，这些链路连接了所有具有属于该多播组的相连主机的路由器。于是多播分组将能够沿着这棵树从发送方路由到所有属于该多播树的主机。当然，该树也许会包含一些没有属于该多播组的相连主机的路由器（例如在图 4-49 中，若不包含路由器 C 或 D，则不可能连接路由器 A、B、E 和 F）。

在实践中，采用两种方法来确定多播路由选择树，我们已经在广播路由选择的内容中学习了这两种方法，因此这里只是顺便提一下它们。这两种方法的区别在于：是用单一的组共享树来为组中的所有发送方分发流量，还是为每个独立的发送方构建一棵特定源的路由选择树。

- 使用一棵组共享树的多播路由选择。如同在生成树广播的场合中，通过组共享树进行多播路由选择的基础是构建一棵树，该树包括了所有具有属于该多播组的相连主机的边缘路由器。在实践中，使用基于中心的方法来构造多播路由选择树，具有属于多播组的相连主机的边缘路由器向中心结点（经单播）发送加入报文。如同在广播情况下，一个加入报文使用单播路由选择朝着中心转发，直到它到达已经属于多播树的一台路由器或到达该中心。沿着该加入报文走过路径的所有路由器，则将向发起该多播加入的边缘路由器转发接收到的多播分组。使用基于中心的树进行多播路由选择，一个关键问题就是选择树中心的过程。中心选择算法在 [Wall 1980; Thaler 1997; Estrin 1997] 中进行了讨论。
- 使用一棵基于源的树的多播路由选择。组共享树多播路由选择构建单一的、共享的路由选择树，以路由所有发送方的分组，而第二种方法为多播组中的每个源构建一棵多播路由选择树。在实践中，使用 RPF 算法（具有源结点 x ）来构造一棵多播转发树，以用于源于源点 x 的多播数据报。我们前面学习的 RPF 算法在用于多播环境中时要求有些不同。为了理解其中的原因，考虑在图 4-50 中的路由器 D。在广播 RPF 情况下，它将向路由器 G 转发分组，即使路由器 G 没有加入该多播组的相连主机。对于 D 只有一个下游路由器 G 的情况来说，这还不算太坏，想象一下，若有上千台路由器在 D 下游时会出现什么情况！这数千台路由器中的每一个都将收到不想要的多播分组。（这种情景并不像看起来那么想当然。最初全球第一个多播网络 Mbone [Casner 1992; Macedonia 1994] 就经历了这样的问题。）解决应用 RPF 时会收到不想要的多播分组这个问题的方法称为剪枝（pruning）。一台接收到多播分组的多播路由器，如它无加入该组的相连主机，则它向其上游路由器发送一个剪枝报文。如果一台路由器从它每个下游路由器收到剪枝报文，则它就能向上游转发一个剪枝报文。



图例：

- 将被转发的分组
- 被路由器接收而不被转发的分组

图 4-50 在多播情况下的反向路径转发

3. 在因特网中的多播路由选择

第一个用于因特网中的多播路由选择协议是距离向量多播路由选择协议（Distance Vector Multicast Routing Protocol, DVMRP）[RFC 1075]。DVMRP 实现了具有反向路径转发与剪枝算法的基于源的树。DVMRP 使用一种前面描述的具有剪枝的 RFP 算法。也许使用最为广泛的因特网多播路由选择协议是协议无关的多播（Protocol Independent Multicast, PIM）路由选择协议，该协议明确辨识两种多播分发情形。在稠密模式（dense mode）[RFC 3973] 中，多播组的成员位置分布稠密；这就是说，在该区域内的许多或大多数路由器需要参与到多播数据报路由选择过程之中。PIM 稠密模式是一种洪泛与剪枝反向路径转发技术，类似于 DVMRP 的思想。

在稀疏模式（sparse mode）[RFC 4601] 中，具有相连组成员的路由器数量相对于路由器总数来说很少，组成员极为分散。PIM 稀疏模式使用聚集点来建立多播分发树。在源特定多播（Source-Specific Multicast, SSM）[RFC 3569；RFC 4607] 中，仅允许单一发送方向多播树中发送流量，大大简化了树的构造和维护。

当 PIM 和 DVMRP 用于一个域中时，网络操作者能够配置该域中的 IP 多播路由器，配置的方法与在域内配置单播路由选择协议如 RIP、IS-IS 和 OSPF 的方法非常类似。而当在不同域间需要多播路由时，将会发生什么情况呢？有一个与域间 BGP 等价的多播协议吗？答案是（从文献角度讲）肯定的。[RFC 4271] 定义了对 BGP 的多协议扩展，使得 BGP 能够为其他协议承载路由选择信息，包括多播信息。使用多播源发现协议（Multicast Source Discovery Protocol, MSDP）[RFC 3618；RFC 4611] 能够将不同的 PIM 稀疏模式域中的聚集点连接在一起。有关因特网中多播路由选择的当前状态的极好概述见 [RFC 5110]。

下面通过指出至今 IP 多播还没有得到大规模应用这样一个事实来结束我们对多播的讨论。有关当前因特网多播服务模式和部署问题的有趣讨论参见 [Diot 2000；Sharma 2003]。无论如何，尽管网络级多播还没有得到广泛部署，但它远没有“寿终正寝”。多年来在 Internet 2 上一直在承载多播流量，并且许多网络借助于 Internet 2 进行相互对等 [Internet2 Multicast 2012]。在英国，BBC 正在参与经 IP 多播分发内容的试验 [BBC Multicast 2012]。与此同时，如我们在第 2 章中看到的 PPLive 以及其他对等方到对等方系统如 End System Multicast [Chu 2002] 中那样，应用层多播使用应用层（而不是网络层）协议在对等方之间提供了内容的多播分发。未来的多播服务主要是在网络层（在网络核心中）实现，还是在应用层（在网络的边缘）实现呢？虽然当前经对等方到对等方方法分发内容的狂热暗示着至少在近期天平是向应用层多播倾斜的，但是 IP 多播将继续取得进展，总有一天前进的步伐最终会放慢并稳定下来。

4.8 小结

在本章中，我们开始了进入网络核心部分的旅程。我们知道网络层涉及网络中的每台主机与路由器。正因如此，网络层协议在协议栈中是最具挑战性的。

我们学习了路由器可能需要在同一时刻处理不同源和目的对之间的数以百万计的分组流。为了使得一台路由器能够处理如此大量的流，网络设计者多年前就认识到，路由器的任务应当尽可能地简单。为了使路由器的工作更容易，能够采取许多措施，包括使用数据报网络层而不使用虚电路网络层，使用一种流水线 and 固定长度的首部（如在 IPv6 中所做

的那样)，取消分片（也如 IPv6 中所做的那样）和提供唯一的尽力而为服务。也许这里最重要的技巧是：不要跟踪各个流，而是使路由选择决策只依赖于数据报中的层次结构化的目的地址。有趣的是注意到邮政服务已经使用这种方法很多年了。

在本章中，我们还审视了路由选择算法的基本原理。我们学习了路由选择算法如何把计算机网络抽象为一个具有结点和链路的图。有了这种抽象，我们能够利用图中的丰富的最短路径路由选择理论，该理论在过去 40 年中在运筹学研究和算法界得到了发展。我们看到有两大类方法：一种是集中式（全局）方法，在这种方法中，每个结点得到网络的一张完整的图并且独立地应用一种最短路径路由选择算法；另一种是分布式方法，在这种方法中，各结点只有整个网络的部分知识，且结点在一起工作以便沿最短路径交付分组。我们还学习了如何使用层次结构来处理规模问题，通过将大型网络划分成称为自治系统（AS）的独立管理域来解决。每个 AS 独立地为其数据报选择路由以通过本 AS，就像各个国家独立地在本国内指定邮件传递路线。我们学习了集中式、分散式和等级制方法是怎样具体应用于因特网中主要的路由选择协议中的，这些协议是 RIP、OSPF 和 BGP。通过考虑广播和多播路由选择，我们结束了路由选择算法的学习。

完成了对网络层的学习任务之后，我们的旅行将沿协议栈进一步向下，即到达链路层了。就像网络层一样，链路层也是网络核心的一部分。不过我们将在下一章看到，链路层在同一链路或 LAN 的结点之间具有更多的搬移分组的局部任务。虽然与网络层任务比起来这种任务从表面上看似乎是微不足道，但我们将看到链路层涉及许多重要而引人入胜的问题，这些问题足够我们学习一段时间的了的。

课后习题和问题



复习题

4.1 ~ 4.2 节

- R1. 我们回顾一下在本书中使用的某些术语。前面讲过运输层的分组名字是报文段，数据链路层的分组名字是帧。网络层分组的名字是什么？前面讲过路由器和链路层交换机都被称为分组交换机。路由器与链路层交换机间的根本区别是什么？回想我们对数据报网络和虚电路网络都使用词汇路由器。
- R2. 在数据报网络中，网络层的两个最重要功能是什么？虚电路网络中网络层的 3 个最重要的功能是什么？
- R3. 路由选择和转发的区别是什么？
- R4. 在数据报网络和虚电路网络中的路由器都使用转发表吗？如果是，描述用于这两类网络的转发表。
- R5. 描述网络层能为单个分组提供的某些假想的服务。对分组流进行相同的描述。因特网的网络层为你提供了这些假想服务吗？ATM 的 CBR 服务模型提供了这些假想服务吗？ATM 的 ABR 服务模型提供了这些假想服务吗？
- R6. 列出某些得益于 ATM 的 CBR 服务模型的应用。

4.3 节

- R7. 讨论为什么在高速路由器的每个输入端口都存储转发表的影子副本。
- R8. 在 4.3 节中讨论了 3 类交换结构。列出并简要讨论每一类交换结构。哪一种（如果有的话）能够跨越交换结构并行发送多个分组？
- R9. 描述在输入端口会出现分组丢失的原因。描述在输入端口如何消除分组丢失（不使用无限大缓存区）。
- R10. 描述在输出端口出现分组丢失的原因。通过增加交换结构速率，能够防止这种丢失吗？
- R11. 什么是 HOL 阻塞？它出现在输入端口还是输出端口？

4.4 节

- R12. 路由器有 IP 地址吗？如果有，有多少个？
- R13. IP 地址 223. 1. 3. 27 的 32 比特二进制等价形式是什么？
- R14. 考察使用 DHCP 的主机，获得它的 IP 地址、网络掩码、默认路由器和其本地 DNS 服务器的 IP 地址。列出这些值。
- R15. 假设在一个源主机和一个目的主机之间有 3 台路由器。不考虑分片，一个从源主机发送给目的主机的 IP 报文将通过多少个接口？为了将数据报从源移动到目的地需要检索多少个转发表？
- R16. 假设某应用每 20ms 生成一个 40 字节的数据块，每块封装在一个 TCP 报文段中，TCP 报文段再封装在一个 IP 数据报中。每个数据报的开销有多大？应用数据所占百分比是多少？
- R17. 假定主机 A 向主机 B 发送封装在一个 IP 数据报中的 TCP 报文段。当主机 B 接收到该数据报时，主机 B 中的网络层怎样知道它应当将该报文段（即数据报的有效载荷）交给 TCP 而不是 UDP 或某个其他东西呢？
- R18. 假定你购买了一个无线路由器并将其与电缆调制解调器相连。同时假定 ISP 动态地为你连接的设备（即你的无线路由器）分配一个 IP 地址。还假定你家有 5 台 PC，均使用 802. 11 以无线方式与该无线路由器相连。怎样为这 5 台 PC 分配 IP 地址？该无线路由器使用 NAT 吗？为什么？
- R19. 比较并对照 IPv4 和 IPv6 首部字段。它们有某些字段是相同的吗？
- R20. 有人说当 IPv6 建隧道通过 IPv4 路由器时，IPv6 将 IPv4 隧道作为链路层协议。你同意这种说法吗？为什么？

4.5 节

- R21. 比较和对照链路状态和距离向量路由选择算法。
- R22. 讨论因特网的等级制组织是怎样使得其能够扩展为数以百万计用户的。
- R23. 每个自治系统使用相同的 AS 内部路由选择算法是必要的吗？为什么？

4.6 节

- R24. 考虑图 4-37。从 D 中的初始表开始，假设 D 收到来自 A 的以下通告：

目的子网	下一台路由器	到目的地的跳数
<i>z</i>	C	10
<i>w</i>	—	1
<i>x</i>	—	1
.....		

D 中的表将会改变吗？如果是，应怎样变化？

- R25. 比较并对照 RIP 与 OSPF 使用的通告。
- R26. 填空：RIP 通告通常宣称到各目的地的跳数，而 BGP 更新却宣称到各目的地的_____。
- R27. 为什么在因特网中用到了不同类型的 AS 间与 AS 内协议？
- R28. 为什么策略考虑对于 AS 内部协议（如 OSPF 和 RIP），与对于 AS 间路由选择协议（如 BGP）一样重要呢？
- R29. 定义和对比下列术语：子网，前缀和 BGP 路由。
- R30. BGP 是怎样使用 NEXT-HOP 属性的？它是怎样使用 AS-PATH 属性的？
- R31. 描述一个较高层 ISP 的网络管理员在配置 BGP 时是如何实现策略的。


4.7 节

- R32. 通过多个单播实现广播抽象与通过支持广播的单个网络（路由器）实现广播抽象之间有什么重要区别？
- R33. 对于我们学习的广播通信的 3 种一般方法（无控制洪泛、受控洪泛和生成树广播）中的每种，下列说法是正确的吗？你可以假定分组不会因缓存溢出而丢失，所有分组以它们发送的顺序交付给链路。
- a. 一个结点可能接收到同一个分组的多个副本。
 - b. 一个结点可能通过相同的出链路转发多个分组的副本。

- R34. 当一台主机加入一个多播组时，它必须将其 IP 地址改变为它所加入的多播组的地址吗？
- R35. IGMP 和广域多播路由选择协议所起的作用是什么？
- R36. 在多播路由选择场合中，一棵组共享的树与一棵基于源的树之间有什么区别？

 习题


- P1. 在本题中，考虑虚电路网络和数据报网络的某些优缺点。
- a. 假设路由器遇到了可能经常会引起它无法正常运转的情况。提出理由说明是虚电路体系结构还是数据报体系结构更好，为什么？
 - b. 对于源和目的结点间传输流量的排他性使用，假设该源和目的结点要求，在沿源到目的地的路径上的所有路由器总能提供固定的容量。提出理由说明是虚电路体系结构还是数据报体系结构更好，为什么？
 - c. 假设网络中的链路和路由器从不出故障，并且所有源/目的地对之间所使用的路径保持不变。在这种情况下，虚电路或数据报体系结构哪个控制流量开销会更多？为什么？
- P2. 考虑一个虚电路网络。假定其 VC 号是一个 8 比特字段。
- a. 链路能够承载的虚电路的最大数量是多少？
 - b. 假定某中心结点在连接建立时确定了路径和 VC 号。假定沿着某虚电路的路径在每段链路使用相同的 VC 号。描述在连接建立时中心结点如何确定 VC 号。进行中虚电路比在（a）中确定的最大值要少，也没有相同的未用 VC 号，这种情况可能出现吗？
 - c. 假定沿着某条虚电路的路径允许不同的 VC 号。在连接建立期间，在端到端路径确定以后，描述链路如何以分散方式而不依赖中心结点选择它们的 VC 号并配置它们的转发表。
- P3. 在虚电路网络中的基本转发表具有 4 列。在这些列中的值的含义是什么？在数据报网络中的基本转发表有两列。在这些列中的值的含义是什么？
- P4. 考虑下列网络。
- a. 假定网络是一个数据报网络。显示路由器 A 中的转发表，其中所有指向主机 H3 的流量通过接口 3 转发。
 - b. 假定网络是一个数据报网络。你能写出路由器 A 中的转发表吗？其中所有从 H1 指向主机 H3 的流量通过接口 3 转发，而所有从 H2 指向主机 H3 的流量通过接口 4 转发。（提示：这是一个技巧问题。）
 - c. 现在假定网络是虚电路网络，在 H1 和 H3 之间有一个进行中的呼叫，H2 和 H3 之间有另一个进行中的呼叫。写出路由器 A 中的转发表，其中所有从 H1 指向主机 H3 的流量通过接口 3 转发，而所有从 H2 指向主机 H3 的流量通过接口 4 转发。
 - d. 假设场景与（c）中相同，写出在结点 B、C 和 D 中的转发表。



- P5. 考虑一个用 2 比特字段表示 VC 号的虚电路网络。假定该网络要通过 4 条链路（链路 A、链路 B、链路 C 和链路 D）建立一条虚电路。假定这些链路中的每条当前都承载两条其他的虚电路，这些其他虚电路的 VC 号如下：

链路 A	链路 B	链路 C	链路 D
00	01	10	11
01	10	11	00

- 在回答下列问题时，记住每个现有的虚电路可能通过这 4 条链路之一。
- a. 如果每条虚电路要求沿着其路径使用相同的 VC 号，能为该新的虚电路分配什么样的 VC 号？
 - b. 如果每条虚电路沿其路径允许不同的链路使用不同的 VC 号（因此转发表必须执行 VC 号转换），能够使用 4 个 VC 号的多少种不同的组合（一种组合用于这 4 条链路之一）？
- P6. 在本书中我们使用术语面向连接服务来描述运输层服务，使用术语连接服务描述网络层服务。在术语中为何有这种微妙的差异？
- P7. 假设两个分组在完全相同的时刻到达一台路由器的两个不同输入端口。同时假设在该路由器中没有其他分组。
- a. 假设这两个分组朝着两个不同的输出端口转发。当交换结构使用一条共享总线时，这两个分组可能在相同时刻通过交换结构转发吗？
 - b. 假设这两个分组朝着两个不同的输出端口转发。当交换结构使用纵横方式时，这两个分组可能在相同时刻通过交换结构转发吗？
 - c. 假设这两个分组朝着相同的输出端口转发。当交换结构使用纵横方式时，这两个分组可能在相同时刻通过交换结构转发吗？
- P8. 在 4.3 节中，我们注意到如果交换结构比输入线路速率快 n 倍，其最大的排队时延为 $(n - 1)D$ 。假设所有分组有相同长度，在相同时刻 n 个分组到达 n 个输出端口，同时所有 n 个分组要转发到不同的输出端口。对于内存、总线和纵横式交换结构，一个分组的最大时延是多少？
- P9. 考虑下列交换机。假设所有数据报具有相同长度，交换机以一种分时隙、同步的方式运行，在一个时隙中一个数据报能够从某输入端口传送到某输出端口。其交换结构是纵横式的，因此在一个时隙中至多一个数据报能够传送到一个给定输出端口，但在一个单一时隙中不同的输出端口能够接收到来自不同输入端口的数据报，从输入端口到它们的输出端口传送所示的分组，所需的时隙数量最少是多少？此时假定使用你所需要的任何输入排队调度方法（即此时没有 HOL 阻塞）。假定采用你能够设计的最差情况下的调度方案，假定非空输入队列不会空闲，所需的时隙数量最大是多少？



- P10. 考虑使用 32 比特主机地址的某数据报网络。假定一台路由器具有 4 条链路，编号为 0 ~ 3，分组能被转发到如下的各链路接口：

目的地址范围	链路接口
11100000 00000000 00000000 00000000 到 11100000 00111111 11111111 11111111	0
11100000 01000000 00000000 00000000 到 11100000 01000000 11111111 11111111	1
11100000 01000001 00000000 00000000 到 11100001 01111111 11111111 11111111	2
其他	3

- a. 提供一个具有 4 个表项的转发表，使用最长前缀匹配，转发分组到正确的链路接口。
- b. 描述你的转发表是如何为具有下列目的地址的数据报决定适当链路接口的。

11001000 10010001 01010001 01010101
11100001 01000000 11000011 00111100
11100001 10000000 00010001 01110111

P11. 考虑使用 8 比特主机地址的某数据报网络。假定一台路由器使用最长前缀匹配并具有下列转发表：

前缀匹配	接口
00	0
010	1
011	2
10	2
11	3

对这 4 个接口中的每个，给出相应的目的主机地址的范围和在该范围中的地址数量。


P12. 考虑使用 8 比特主机地址的数据报网络。假定一台路由器使用最长前缀匹配并具有下列转发表：

前缀匹配	接口
1	0
10	1
111	2
其他	3


对这 4 个接口中的每个，给出相应的目的主机地址的范围和在该范围中的地址数量。

- P13. 考虑互联 3 个子网（子网 1、子网 2 和子网 3）的一台路由器。假定在这 3 个子网的每个子网中的所有接口要求具有前缀 223. 1. 17/24。还假定子网 1 要求支持多达 60 个接口，子网 2 要求支持多达 90 个接口和子网 3 要求支持多达 12 个接口。提供 3 个满足这些限制的网络地址（形式为 *a. b. c. d/x*）。
- P14. 在 4. 2. 2 节中给出了一个转发表（使用最长前缀匹配）的例子。使用 *a. b. c. d/x* 记法代替二进制字符串记法，重写该转发表。
- P15. 在习题 P10 中要求你给出转发表（使用最长前缀匹配）。使用 *a. b. c. d/x* 记法代替二进制字符串记法，重写该转发表。
- P16. 考虑具有前缀 128. 119. 40. 128/26 的一个子网。给出能被分配给该网络的一个 IP 地址（形式为 *xxx. xxx. xxx. xxx*）的例子。假定一个 ISP 拥有形式为 128. 119. 40. 64/26 的地址块。假定它要从该地址块生成 4 个子网，每块具有相同数量的 IP 地址。这 4 个子网（形式为 *a. b. c. d/x*）的前缀是什么？
- P17. 考虑图 4-17 中显示的拓扑。（在 12:00 以顺时针开始）标记具有主机的 3 个子网为网络 A、B 和 C。标记没有主机的子网为网络 D、E 和 F。
- a. 为这 6 个子网分配网络地址，要满足下列限制：所有地址必须从 214. 97. 254/23 起分配；子网 A 应当具有足够地址以支持 250 个接口；子网 B 应当具有足够地址以支持 120 个接口；子网 C 应当具有足够地址以支持 120 个接口。当然，子网 D、E 和 F 应当支持两个接口。对于每个子网，分配采用的形式是 *a. b. c. d/x* 或 *a. b. c. d/x ~ e. f. g. h/y*。
 - b. 使用你对（a）部分的答案，为这 3 台路由器中的每台都提供转发表（使用最长前缀匹配）。
- P18. 使用美国因特网编码注册机构（<http://www.arin.net/whois>）的 whois 服务来确定三所大学所用的 IP 地址块。whois 服务能被用于确定某个特定的 IP 地址的确定地理位置吗？使用 www.maxmind.com 来确定位于这三所大学的 Web 服务器的位置。
- P19. 考虑向具有 700 字节 MTU 的一条链路发送一个 2400 字节的数据报。假定初始数据报标有标识号


422. 将会生成多少个分片？在生成相关分片的数据报中的各个字段中的值是多少？
- P20. 假定在源主机 A 和目的主机 B 之间的数据报被限制为 1500 字节（包括首部）。假设 IP 首部为 20 字节，要发送一个 5MB 组成的 MP3 需要多少个数据报？解释你的答案是如何计算的。
- P21. 考虑在图 4-22 中建立的网络。假定 ISP 此时为路由器分配地址 24. 34. 112. 235 以及家庭网络的网络地址是 192. 168. 1/24。
- a. 在家庭网络中为所有接口分配地址。
 - b. 假定每台主机具有两个进行中的 TCP 连接，所有都是对主机 128. 119. 40. 86 的 80 端口的。在 NAT 转换表中提供 6 个对应表项。
- P22. 假设你有兴趣检测 NAT 后面的主机数量。你观察到在每个 IP 分组上 IP 层顺序地标出一个标识号。由一台主机生成的第一个 IP 分组的标识号是一个随机数，后继 IP 分组的标识号是顺序分配的。假设由 NAT 后面主机产生的所有 IP 分组都发往外部。
- a. 基于这个观察，假定你能够俘获由 NAT 向外部发送的所有分组，你能概要给出一种简单的技术来检测 NAT 后面不同主机的数量吗？评估你的答案。
 - b. 如果标识号不是顺序分配而是随机分配的，这种技术还能正常工作吗？评估你的答案。
- P23. 在这个习题中，我们将探讨 NAT 对 P2P 应用程序的影响。假定具有用户名 Arnold 的对等方通过查询发现，具有用户名 Bernard 的对等方有一个要下载的文件。同时假定 Bernard 和 Arnold 都位于 NAT 后面。尝试设计一种技术，使得 Arnold 与 Bernard 创建一条 TCP 连接，而不对 NAT 做应用特定的配置。如果你难以设计这样的技术，试讨论其原因。
- P24. 观察图 4-27，列举从 *y* 到 *u* 不包含任何环路的路径。
- P25. 重复习题 P24，列举从 *x* 到 *z*、*z* 到 *u* 以及 *z* 到 *w* 的不包含任何环路的路径。
- P26. 考虑下面的网络。对于标明的链路费用，用 Dijkstra 的最短路径算法计算出从 *x* 到所有网络结点的最短路径。通过计算一个类似于表 4-3 的表，说明该算法是如何工作的。



- P27. 考虑习题 P26 中所示的网络。使用 Dijkstra 算法和一个类似于表 4-3 的表来说明你做的工作：
- a. 计算出从 *t* 到所有网络结点的最短路径。
 - b. 计算出从 *u* 到所有网络结点的最短路径。
 - c. 计算出从 *v* 到所有网络结点的最短路径。
 - d. 计算出从 *w* 到所有网络结点的最短路径。
 - e. 计算出从 *y* 到所有网络结点的最短路径。
 - f. 计算出从 *z* 到所有网络结点的最短路径。
- P28. 考虑下图所示的网络，假设每个结点初始时知道到它的每个邻居的费用。考虑距离向量算法，并显示在结点 *z* 中的距离表表项。




- P29. 考虑一个一般性拓扑（即不是以上所显示的特定网络）和一个同步版本的距离向量算法。假设每次迭代时，一个结点与其邻居交换其距离向量并接收它们的距离向量。假定算法开始时，每个结点只知道到其直接邻居的费用，在该分布式算法收敛前所需的最大迭代次数是多少？评估你的答案。
- P30. 考虑下图所示的网络段。 x 只有两个相连邻居 w 与 y 。 w 有一条通向目的地 u （没有显示）的最低费用路径，其值为 5； y 有一条通向目的地 u 的最低费用路径，其值为 6。从 w 与 y 到 u （以及 w 与 y 之间）的完整路径未显示出来。网络中所有链路费用皆为正整数值。




- 给出 x 对目的地 w 、 y 和 u 的距离向量。
 - 给出对 $c(x, w)$ 或 $c(x, y)$ 的链路费用的变化，使得执行了距离向量算法后， x 将通知其邻居有一条通向 u 的新最低费用路径。
 - 给出对 $c(x, w)$ 或 $c(x, y)$ 的链路费用的变化，使得执行了距离向量算法后， x 将不通知其邻居有一条通向 u 的新最低费用路径。
- P31. 考虑如图 4-30 中所示 3 个结点的拓扑。不使用显示在图 4-30 中的费用值，链路费用值现在是 $c(x, y) = 3$ ， $c(y, z) = 6$ ， $c(z, x) = 4$ 。在距离向量表初始化后和在同步版本的距离向量算法每次迭代后，计算它的距离向量表（如我们以前对图 4-30 讨论时所做的那样）。
- P32. 考虑在距离向量路由选择中的无穷计数问题。如果我们减小一条链路费用，将会出现无穷计数问题吗？为什么？如果我们连接没有链路的两个结点，会出现什么情况？
- P33. 讨论在图 4-30 中的距离向量算法，距离向量 $D(x)$ 中的每个值不是递增的并且最终将在有限步中稳定下来。
- P34. 考虑图 4-31。假定有另一台路由器 w ，与路由器 y 和 z 连接。所有链路费用给定如下： $c(x, y) = 4$ ， $c(x, z) = 50$ ， $c(y, w) = 1$ ， $c(z, w) = 1$ ， $c(y, z) = 3$ 。假设在距离向量路由选择算法中使用了毒性逆转。
- 当距离向量路由选择稳定时，路由器 w 、 y 和 z 向 x 通知它们的距离。它们告诉彼此什么样的距离值？
 - 现在假设 x 和 y 之间的链路成本增加到 60。即使使用了毒性逆转，将会存在无穷计数问题吗？为什么？如果存在无穷计数问题，距离向量路由选择需要多少次迭代才能再次到达稳定状态？评估你的答案。
 - 如果 $c(y, x)$ 从 4 变化到 60，怎样修改 $c(y, z)$ 使得不存在无穷计数问题。
- P35. 描述在 BGP 中是如何检测路径中的环路的。
- P36. 一台 BGP 路由器将总是选择具有最短 AS 路径长度的无环路由吗？评估你的答案。
- P37. 考虑下图所示的网络。假定 AS3 和 AS2 正在运行 OSPF 作为其 AS 内部路由选择协议。假定 AS1 和 AS4 正在运行 RIP 作为其 AS 内部路由选择协议。假定 AS 间路由选择协议使用的是 eBGP 和 iBGP。假定最初在 AS2 和 AS4 之间不存在物理链路。


- 路由器 3c 从下列哪个路由选择协议学习到了前缀 x : OSPF、RIP、eBGP 或 iBGP?
- 路由器 3a 从哪个路由选择协议学习到了前缀 x ?
- 路由器 1c 从哪个路由选择协议学习到了前缀 x ?
- 路由器 1d 从哪个路由选择协议学习到了前缀 x ?



- P38. 参考上一习题，一旦路由器 1d 知道了 x 的情况，它将一个表项 (x, I) 放入其转发表中。
- 对这个表项而言， I 将等于 I_1 还是 I_2 ? 用一句话解释其原因。
 - 现在假定在 AS2 和 AS4 之间有一条物理链路，显示为图中的虚线。假定路由器 1d 知道经 AS2 以及经 AS3 能够访问到 x 。 I 将设置为 I_1 还是 I_2 ? 用一句话解释其原因。
 - 现在假定有另一个 AS，它称为 AS5，其位于路径 AS2 和 AS4 之间（没有显示在图中）。假定路由器 1d 知道经 AS2 AS5 AS4 以及经 AS3 AS4 能够访问到 x 。 I 将设置为 I_1 还是 I_2 ? 用一句话解释其原因。
- P39. 考虑下面的网络。ISP B 为地区 ISP A 提供国家主干网服务。ISP C 为地区 ISP D 提供国家主干网服务。每个 ISP 由一个 AS 组成。B 和 C 使用 BGP 在两个地方互相对等。考虑从 A 到 D 的流量。B 宁愿将流量交给西海岸的 C（使得 C 将必须承担承载跨越整个国家的流量的费用），而 C 宁愿经其东海岸与 B 对等的站点得到这些流量（使得 B 将承载跨越整个国家的流量）。C 可能会使用什么样的 BGP 机制，使得 B 将通过东海岸对等点传递 A 到 D 的流量？要回答这个问题，你需要钻研 BGP 规范。



- P40. 在图 4-42 中，考虑到达桩网 W、X 和 Y 的路径信息。基于 W 与 X 处的可用信息，它们分别看到的网络拓扑是什么？评估你的答案。Y 所见的拓扑视图如下所示。



- P41. 考虑图 4-42。B 将不会基于 BGP 路由选择经过 X 以 Y 为目的地转发流量。但是有某些极为流行的应用程序，其数据分组先朝向 X，然后再流向 Y。指出一种这样的应用程序，描述数据分组是如何沿着这条不由 BGP 路由选择给定的路径流动的。
- P42. 在图 4-42 中，假定有另一个桩网络 V，它为 ISP A 的客户。假设 B 和 C 具有对等关系，并且 A 是 B 和 C 的客户。假设 A 希望让发向 W 的流量仅来自 B，并且发向 V 的流量来自 B 或 C。A 如何向 B 和 C 通告其路由？C 收到什么样的 AS 路由？
- P43. 假定 AS X 和 AS Z 不直接连接，但与 AS Y 连接。进一步假定 X 与 Y 具有对等协定，Y 与 Z 具有对等协定。最后，假定 Z 要传送所有 Y 的流量但不想传送 X 的流量。BGP 允许 Z 实现这种策略吗？
- P44. 考虑习题 P26 中 7 个结点的网络（结点标为 $t \sim z$ ）。给出根在 z 的包括（作为端主机）结点 u 、 v 、 w 和 y 的最低费用树。非形式化地讨论一下，为什么你给出的树是一棵最低费用树。
- P45. 考虑实现广播的两种基本方法：单播模拟与网络层（即路由器协助）广播，并假定使用生成树广播来实现网络层广播。考虑有一个发送方与 32 个接收方。假设发送方通过一棵路由器二叉树与接收方相连。在单播模拟与网络层广播情况下，对于这个拓扑，发送一个广播分组的费用各是多少？这里每次经单一链路发送一个分组（或一个分组的副本），产生一个单位费用。用什么样的拓扑互联发送方、接收方和路由器，将使得单播模拟与真正的网络层广播产生的费用相差尽可能大？你可按照自己的意愿选择多台路由器。
- P46. 考虑图 4-44 中反向路径转发（RPF）算法的运行。使用相同的拓扑，找出从所有结点到源结点 A 的一系列路径（并像在图 4-44 中那样用粗线指出这些路径），使得如果这些路径是最低费用路径，则结点 B 将接收来自使用 RPF 的结点 A、C 和 D 的 A 的广播报文的副本。
- P47. 考虑图 4-44 中所示的拓扑。假定所有链路具有单位费用并且结点 E 是广播源。在给定结点 E 为源的情况下，使用如图 4-44 中所示的箭头，指出使用 RPF 转发分组的链路，以及不转发分组的链路。
- P48. 使用习题 P26 中的图重复习题 P47。假定 z 是广播源，并且链路费用如在习题 P26 中所示。
- P49. 考虑在图 4-46 中所显示的拓扑，并假定每段链路有单位费用。假设结点 C 在基于中心的多播路由选择算法中被选为中心。假定每个相连路由器都使用到结点 C 的最低费用路径向 C 发送加入报文，画出所产生的基于中心的多播路由选择树。产生的树是一棵最低费用树吗？评估你的答案。
- P50. 重复习题 P49，使用习题 P26 中的图。假定中心结点是 v 。
- P51. 在 4.5.1 节中我们学习了计算单播路径的 Dijkstra 的链路状态路由选择算法，这些单播路径分别是 从源到所有目的地的最小费用路径。这些路径的并集能够被认为形成了一棵最低单播费用路径树（或一棵最短路单播路径树，如果所有链路费用是相同的）。通过构造一个反例，表明最低费用路径树并不总是与最小生成树相同。
- P52. 考虑所有结点与 3 个其他结点相连的网络。在单一时间步中，一个结点能够从它的邻居接收到所有传输的广播分组，复制分组，并向它的所有邻居发送之（除了发送给定分组的那个结点）。在下一个时间步中，相邻结点能够接收、复制和转发这些分组等等。假定使用无控制洪泛以在这样的网络中提供广播。在时间步 t ，多少个广播分组的副本将被传输，假定在时间步 1 期间，由源结点向它的 3 个邻居传输单个广播分组。
- P53. 我们在 4.7 节中看到，没有任何网络层协议能用于标识参与一个多播组的主机。在这种情况下，多播应用程序怎样知道参与一个多播组的主机的身份？
- P54. 设计（给出伪代码描述）一个应用级协议，该协议维护参与一个多播组的所有主机的地址。特别要指出你的协议所使用的网络服务（单播或多播），还要指出你的协议发送报文是在带内还是带外（关于多播组参与者之间的应用数据流）并说明其理由。
- P55. 多播地址空间的尺寸有多大？假设现有两个不同的多播组随机地选择一个多播地址。它们选择同一个地址的概率有多大？假设现有 1000 个多播组同时正在进行，随机选择它们的多播组地址。它们冲突的概率有多大？




套接字编程作业

在第2章结尾给出了四个套接字编程作业。下面给出第5个应用 ICMP 的作业，ICMP 的是本章讨论的协议。

作业5：ICMP ping


ping 是一种流行的网络应用程序，用于测试位于远程的某个特定的主机是否开机和可达。它也经常用于测量客户主机和目标主机之间的时延。它的工作过程是：向目标主机发送 ICMP “回显请求” 分组（即 ping 分组），并且侦听 ICMP “回显响应” 应答（即 pong 分组）。ping 测量 RRT、记录分组丢失和计算多个 ping-pong 交换（往返时间的最小、平均、最大和标准差）的统计汇总。

在本实验中，你将用 Python 语言编写自己的 ping 应用程序。你的应用程序将使用 ICMP。但为了保持程序的简单，你将不完全遵循 RFC 1739 中的官方规范。注意到你将仅需要写该程序的客户程序，因为服务器侧所需的功能构建在几乎所有的操作系统中。你能够在 Web 站点 <http://www.awl.com/kurose-ross> 找到本作业的全面细节，以及该 Python 代码的重要片段。



编程作业

在本编程作业中，你要写一组的“分布式”过程，以为下图所示的网络实现一个分布式异步距离向量路由选择算法。




你要写出下列例程，这些例程将在为该作业提供的模拟环境中异步“执行”。对于结点 0，你将写出这样的例程：

- `rtinit0()`。在模拟开始将调用一次该例程。`rtinit0()` 无参数。它应当初始化结点 0 中的距离表，以反映出到达结点 1、2 和 3 的直接费用分别为 1、3 和 7。在上图中，所有链路都是双向的，两个方向的费用皆相同。在初始化距离表和结点 0 的例程所需的其他数据结构后，它应向其直接连接的邻居（在本情况中为结点 1、2 和 3）发送它到所有其他网络结点的最低费用路径的费用信息。通过调用例程 `tolayer2()`，这种最低费用信息在一个路由选择更新分组中被发送给相邻结点，就像在完整编程作业中描述的那样。路由选择更新分组的格式也在完整编程作业中进行描述。
- `rtupdate0(struct rtpkt *rcvdpkt)`。当结点 0 收到一个由其直接相连邻居之一发给它的路由选择分组时，调用该例程。参数 `*rcvdpkt` 是一个指向接收分组的指针。`rtupdate0()` 是距离向量算法的“核心”。它从其他结点 i 接收的路由选择更新分组中包含结点 i 到所有其他网络结点的当前最短路费用值。`rtupdate0()` 使用这些收到的值来更新其自身的距离表（这是由距离向量算法所规定的）。如果它自己到另外结点的最低费用因此更新而发生改变的话，则结点 0 通过发送一个路由选择分组来通知其直接相连邻居这种最低费用的变化。我们在距离向量算法中讲过，仅有直接相连的结点才交换路由选择分组。因此，结点 1 和结点 2 将相互通信，但结点 1 和结点 3 将不相互通信。

为结点 1、2、3 定义类似的例程。因此你总共将写出 8 个过程：`rtinit0()`、`rtinit1()`、`rtinit2()`、`rtinit3()`、`rtupdate0()`、`rtupdate1()`、`rtupdate2()` 和 `rtupdate3()`。这些例程将共同实现一个分布式的、与图中所示拓扑和费用相关的距离表的异步计算。

你可在网址 <http://www.awl.com/kurose-ross> 处找到该编程作业的全部详细资料，以及你创建模拟硬件/软件环境所需的 C 程序代码。一个 Java 版的编程作业也可供使用。




Wireshark 实验

在与本书配套的 Web 站点 <http://www.awl.com/kurose-ross> 上, 你将找到两个 Wireshark 实验作业。第一个实验研究了 IP 协议的运行, 特别是 IP 数据报的格式。第二个实验探讨了在 ping 和 traceroute 命令中 ICMP 协议的使用。



人物专访

Vinton G. Cerf 是 Internet Evangelist for Google 公司的副总裁兼总管。他在 MCI 公司的各种职位上服务了 16 年, 最后以技术战略部资深副总裁的身份结束了他在那里的任期。他是众所周知的 TCP/IP 协议和因特网体系结构的共同设计者。1976 年到 1982 年在美国国防部高级研究计划署 (DARPA) 任职期间, 他在领导因特网和与因特网相关的数据分组与安全技术的研发方面发挥了重要作用。他于 2005 年获得了美国总统自由奖章, 于 1977 年获得了美国国家技术奖章。他在斯坦福大学获得数学学士学位, 在加利福尼亚大学洛杉矶分校 (UCLA) 获得了计算机科学的硕士和博士学位。



Vinton G. Cerf

◦ 是什么使您专注于网络技术的呢?

在 20 世纪 60 年代末, 我在 UCLA 一直做程序员的工作。我的工作得到了美国国防部高级研究计划署 (那时叫 ARPA, 现在叫 DARPA) 的支持。我那时在刚创建不久的 ARPAnet 的网络测量中心, 为 Leonard Kleinrock 教授的实验室工作。ARPAnet 的第一个结点于 1969 年 9 月 1 日安装在 UCLA。我负责为计算机编程, 以获取有关 ARPAnet 的性能信息, 并报告这些信息以便与数学模型作比较, 预测网络性能。

其他几名研究生和我负责研制所谓的 ARPAnet 主机级协议, 该协议的过程和格式将使得网络中许多不同类型的计算机相互交互。这是我进入分布式计算与通信新世界中的一次迷人的探索。

◦ 当您第一次设计该协议时, 您曾想象过 IP 会像今天这样变得无所不在吗?

当 Bob Kahn 和我于 1973 年最初从事该项工作时, 我想我们的注意力大多集中在这样一个重要的问题: 假定我们不能实际改变这些网络本身, 那么怎样才能让异构的分组网络彼此互操作呢? 我们希望能找到一种方法可以使任意多的分组交换网以透明的方式进行互联, 以便主机彼此之间不做任何转换就能进行端到端通信。我认为我们那时已经知道了我们正在处理强大的和可扩充的技术, 但还没清楚地想过有数亿台计算机都连入因特网时的世界会是什么样。

◦ 您现在能预见网络与因特网的未来吗? 您认为在它们的发展中存在的最大挑战或障碍是什么?

我相信因特网本身以及一般的网络都将继续扩大。已有令人信服的证据表明, 在因特网上将有数十亿个因特网使能设备, 包括移动电话、冰箱、个人数字助理、家用服务器、电视等家用电器, 以及大批通常的便携机、服务器等。重大挑战包括支持移动性、电池寿命、网络接入链路的容量、以不受限的方式扩展网络光学核心的能力。设计因特网的星际扩展是我在喷气推进实验室深入研究的一项计划。我们需要从 IPv4 (32 比特地址) 过渡到 IPv6 (128 比特)。要做的事情实在是太多了!

◦ 是谁激发了您专业上的灵感呢?

我的同事 Bob Kahn、我的论文导师 Gerald Estrin、我最好的朋友 Steve Crocker (我们在高中就认识了, 1960 年是他带我进入了计算机学科之门!), 以及数千名今天仍在继续推动因特网发展的工程师。

◦ 您对进入网络/因特网领域的学生有什么忠告吗?

要跳出现有系统的限制来思考问题, 想一想什么是可行的; 随后再做艰苦工作以谋划如何从事物的当前状态到达所想的状态。要敢于想象: 喷气推进实验室的 6 个同事和我一直在从事陆地因特网的星际扩展设计。这也许要花几十年才能实现, 任务会一个接着一个地出现, 可以用这句话来总结: “一个人总是要不断地超越自我, 否则还有什么乐趣可言?”

链路层：链路、接入网和局域网

在上一章中，我们学习了网络层提供的任意两台主机之间的通信服务。在两台主机之间，数据报跨越一系列通信链路传输，一些是有线链路，而一些是无线链路，从源主机起始，通过一系列分组交换机（交换机和路由器），在目的主机结束。当我们沿协议栈继续往下，从网络层到达链路层，我们自然而然地想知道分组是如何通过构成端到端通信路径的各段链路的。为了在单段链路上传输，网络层的数据报是怎样被封装进链路层帧的呢？沿此通信路径，不同的链路能够采用不同的链路层协议吗？在广播链路中传输碰撞是如何解决的？在链路层存在编址吗？如果需要，链路层编址如何与我们在第4章中学习的网络层编址一起运行呢？交换机和路由器之间到底有哪些差异？我们将在本章回答这些和其他一些重要的问题。

在链路层的讨论中，我们将看到两种截然不同类型的链路层信道。第一种类型是广播信道，这种信道用于连接有线局域网、卫星网和混合光纤同轴电缆（Hybrid Fiber Coaxial cable, HFC）接入网中的多台主机。因为许多主机与相同的广播信道连接，需要所谓的媒体访问协议来协调帧传输。在某些场合中，可以使用中心控制器来协调传输。第二种类型的链路层信道是点对点通信链路，这在诸如长距离链路连接的两台路由器之间，或用户办公室计算机与它们所连接的邻近以太网交换机之间等场合经常能够发现。协调点对点链路的访问较为简单；在本书 Web 网站上的相关材料详细地讨论了点到点协议（Point-to-Point Protocol, PPP），该协议的适用范围从经电话线的拨号服务到经光纤链路的高速点到点帧传输。

我们将在本章中研讨几个链路层概念和技术。我们将更深入地研究差错检测和纠正，这个主题我们在第3章中简要讨论过。我们将考虑多路访问网络和交换局域网，包括以太网，这是目前最流行的有线局域网技术。我们还将学习虚拟局域网和数据中心网络。尽管 WiFi 及更一般的无线局域网都属于链路层范围，但我们将在第6章才学习这些重要的主题。

5.1 链路层概述

我们首先学习一些有用的术语。在本章中为方便讨论，将运行链路层协议（即第2层）协议的任何设备均称为**结点**（node）。结点包括主机、路由器、交换机和 WiFi 接入点（在第6章中讨论）。我们也把沿着通信路径连接相邻结点的通信信道称为**链路**（link）。为了将一个数据报从源主机传输到目的主机，数据报必须通过沿端到端路径上的各段链路传输。举例来说，显示在图5-1下部的公司网络中，考虑从无线主机之一向服务器之一发送一个数据报。该数据报将实际通过6段链路：发送主机与 WiFi 接入点之间的 WiFi 链路，接入点和链路层交换机之间的以太网链路，链路层交换机与路由器之间的链路，两台路由器之间的链路，最后是交换机和服务器之间的以太网链路。在通过特定的链路时，传输结点将数据报封装在链路层帧中，并将该帧传送到链路中。




图 5-1 无线主机和服务端之间的 6 个链路层跳

为了透彻理解链路层以及它是如何与网络层关联的，我们考虑一个交通运输的类比例子。假如一个旅行社计划为游客开辟从美国新泽西州的普林斯顿到瑞士洛桑的旅游路线。假定该旅行社认为对于游客而言最为便利的方案是：从普林斯顿乘豪华大轿车到 JFK 机场，然后乘飞机从 JFK 机场去日内瓦机场，最后乘火车从日内瓦机场到洛桑火车站。一旦该旅行社作了这 3 项预定，普林斯顿豪华大轿车公司将负责将游客从普林斯顿带到 JFK，航空公司将负责将游客从 JFK 带到日内瓦，瑞士火车服务将负责将游客从日内瓦带到洛桑。该旅程中 3 段中的每一段都在两个“相邻”地点之间是“直达的”。注意到这 3 段运输是由不同的公司管理，使用了完全不同的运输方式（豪华大轿车、飞机和火车）。尽管运输方式不同，但它们都提供了将旅客从一个地点运输到相邻地点的基本服务。在这个运输类比中，一个游客好比一个数据报，每个运输区段好比一条链路，每种运输方式好比一种链路层协议，而该旅行社好比一个路由选择协议。

5.1.1 链路层提供的服务

尽管任一链路层的基本服务都是将数据报通过单一通信链路从一个结点移动到相邻结点，但所提供的服务细节能够随着链路层协议的不同而变化。链路层协议能够提供的可能服务包括：

- 成帧（framing）。在每个网络层数据报经链路传送之前，几乎所有的链路层协议都要将其用链路层帧封装起来。一个帧由一个数据字段和若干首部字段组成，其中网络层数据报就插在数据字段中。帧的结构由链路层协议规定。当我们在本章的后半部分研究具体的链路层协议时，将看到几种不同的帧格式。
- 链路接入。媒体访问控制（Medium Access Control, MAC）协议规定了帧在链路上传输的规则。对于在链路的一端仅有一个发送方、链路的另一端仅有一个接收方的点对点链路，MAC 协议比较简单（或者不存在），即无论何时链路空闲，发送方都能够发送帧。更有趣的情况是当多个结点共享单个广播链路时，即所谓多路访问问题。这里，MAC 协议用于协调多个结点的帧传输。
- 可靠交付。当链路层协议提供可靠交付服务时，它保证无差错地经链路层移动每个网络层数据报。前面讲过，某些运输层协议（例如 TCP）也提供可靠交付服务。与运输层可靠交付服务类似，链路层的可靠交付服务通常是通过确认和重传取得的（参见 3.4 节）。链路层可靠交付服务通常用于易于产生高差错率的链路，例如无线链路，其目的是本地（也就是在差错发生的链路上）纠正一个差错，而不是通过运输层或应用层协议迫使进行端到端的数据重传。然而，对于低比特差错的链路，包括光纤、同轴电缆和许多双绞铜线链路，链路层可靠交付可能会被认为是一种不必要的开销。由于这个原因，许多有线的链路层协议不提供可靠交付服务。
- 差错检测和纠正。当帧中的一个比特作为 1 传输时，接收方结点中的链路层硬件可能不正确地将其判断为 0，反之亦然。这种比特差错是由信号衰减和电磁噪声导致的。因为没有必要转发一个有差错的数据报，所以许多链路层协议提供一种机制来检测这样的比特差错。通过让发送结点在帧中包括差错检测比特，让接收结点进行差错检查，以此来完成这项工作。第 3 章和第 4 章讲过，因特网的运输层和网络层也提供了有限形式的差错检测，即因特网检验和。链路层的差错检测通常更复杂，并且用硬件实现。差错纠正类似于差错检测，区别在于接收方不仅能检测帧中出现的比特差错，而且能够准确地确定帧中的差错出现的位置（并因此纠正这些差错）。

5.1.2 链路层在何处实现

在深入学习链路层的细节之前，本概述的最后一节考虑一下在何处实现链路层的问题。我们将关注一个端系统，因为我们在第 4 章中知道链路层是实现在路由器的线路卡中的。主机的链路层是用硬件还是用软件实现的呢？它是实现在一块单独的卡上还是一个芯片上？它是怎样与主机的硬件和操作系统组件的其他部分接口的呢？

图 5-2 显示了一个典型的主机体系结构。链路层的主体部分是在网络适配器（network adapter）中实现的，网络适配器有时也称为网络接口卡（Network Interface Card, NIC）。位于网络适配器核心的是链路层控制器，该控制器通常是一个实现了许多链路层服务（成帧、链路接入、差错检测等）的专用芯片。因此，链路层控制器的许多功能是用硬件实现

的。例如，Intel 的 8254x 控制器 [Intel 2012] 实现了以太网协议，我们将在 5.5 节中学习该协议；Atheros AR5006 [Atheros 2012] 控制器实现了 802.11 WiFi 协议，我们将在第 6 章学习该协议。直到 20 世纪 90 年代后期，大部分网络适配器还是物理上分离的卡（如一块 PCMCIA 卡或者一块插进 PC 的 PCI 卡槽中的插入卡），但越来越多的网络适配器被综合进主机的主板，即所谓的局域网在主板配置。

在发送端，控制器取得了由协议栈较高层生成并存储在主机内存中的数据报，在链路层帧中封装该数据报（填写该帧的各个字段），然后遵循链路接入协议将该帧传进通信链路中。在接收端，控制器接收了整个帧，抽取出网络层数据报。如果链路层执行差错检测，则需要发送控制器在该帧的首部设置差错检测比特，由接收控制器执行差错检测。

图 5-2 显示了与主机总线（例如一条 PCI 或 PCI-X 总线）连接的网络适配器，这里它看起来非常像与其他主机组件连接的任何其他 I/O 设备。图 5-2 还显示了尽管大部分链路层是在硬件中实现的，但部分链路层是在运行于主机 CPU 上的软件中实现的。链路层的软件组件实现了高层链路层功能，如组装链路层寻址信息和激活控制器硬件。在接收端，链路层软件响应控制器中断（例如，由于一个或多个帧的到达），处理差错条件并将数据报向上传递给网络层。所以，链路层是硬件和软件的结合体，即此处是协议栈中软件与硬件交接的地方。[Intel 2012] 从软件编程的角度提供了有关 8245x 控制器的可读性很强的概述（以及详细的描述）。




图 5-2 网络适配器：它与其他主机组件及协议栈功能的关系

5.2 差错检测和纠正技术

在上一节中，我们提到了比特级差错检测和纠正（bit-level error detection and correction），即对从一个结点发送到另一个物理上连接的邻近结点的链路层帧中的比特损伤进行检测和纠正，它们通常是链路层提供的两种服务。我们在第 3 章中看到差错检测和纠正服务通常也由运输层提供。在本节中，我们将研究几种最简单的技术，它们能够用于检测比特差错，而且在某些情况下，能够纠正这样的比特差错。对该主题理论和实现的全面描述是许多教科书的主题（例如 [Schwartz 1980] 或 [Bertsekas 1991]），而我们这里仅讨论必要内容。我们此时的目的是对差错检测和纠正技术提供的能力有一种直观的认识，并看看一些简单技术在链路层中的工作原理及其如何实际应用。

图 5-3 图示说明了我们研究的环境。在发送结点，为了保护比特免受差错，使用差错检测和纠正比特（Error-Detection and-Correction, EDC）来增强数据 D 。通常，要保护的数据不仅包括从网络层传递下来需要通过链路传输的数据报，而且包括链路帧首部中的链路级的寻址信息、序号和其他字段。链路级帧中的 D 和 EDC 都被发送到接收结点。在接收结点，接收到比特序列 D' 和 EDC' 。注意到因传输中的比特翻转所致， D' 和 EDC' 可能与初始的 D 和 EDC 不同。




图 5-3 差错检测与纠正的场景

接收方的挑战是在它只收到 D' 和 EDC' 的情况下，确定 D' 是否和初始的 D 相同。在图 5-3 中的接收方判定的准确措词（我们问是否检测到一个差错，而非是否出现了差错！）是重要的。差错检测和纠正技术使接收方有时但并不总是检测出已经出现的比特差错。即使采用差错检测比特，也还是可能有未检出比特差错（undetected bit error）；这就是说，接收方可能无法知道接收的信息中包含着比特差错。因此，接收方可能向网路层交付一个损伤的数据报，或者不知道该帧首部的某个其他字段的内容已经损伤。我们因此要选择一个差错检测方案，使得这种事件发生的概率很小。一般而言，差错检测和纠错技术越复杂（即那些具有未检测出比特差错概率较小的技术），导致的开销就越大，这就是意味着需要更多的计算量及更多的差错检测和纠错比特。

我们现在来研究在传输数据中检测差错的 3 种技术：奇偶校验（它用来描述差错检测和纠正背后隐含的基本思想）、检验和方法（它通常更多地应用于运输层）和循环冗余检测（它通常更多地应用在适配器中的链路层）。

5.2.1 奇偶校验

也许差错检测最简单的方式就是用单个奇偶校验位（parity bit）。假设在图 5-4 中要发送的信息 D 有 d 个比特。在偶校验方案中，发送方只需包含一个附加的比特，选择它的值，使得这 $d + 1$ 个比特（初始信息加上一个校验比特）中 1 的总数是偶数。对于奇校验方案，选择校验比特值使得有奇数个 1。图 5-4 描述了一个偶校验的方案，单个校验比特被存放在一个单独的字段中。




图 5-4 1 比特偶校验

采用单个奇偶校验位方式，接收方的操作也很简单。接收方只需要数一数接收的 $d + 1$ 比特中 1 的数目即可。如果在采用偶校验方案中发现了奇数个值为 1 的比特，接收方知道至少出现了一个比特差错。更精确的说法是，出现了奇数个比特差错。

但是如果出现了偶数个比特差错，那会发生什么现象呢？你应该认识到这将导致一个

未检出的差错。如果比特差错的概率小，而且比特之间的差错可以被看作是独立发生的，在一个分组中多个比特同时出错的概率将是极小的。在这种情况下，单个奇偶校验位可能是足够的了。然而，测量已经表明了差错经常以“突发”方式聚集在一起，而不是独立地发生。在突发差错的情况下，使用单比特奇偶校验保护的一帧中未检测出差错的概率能够达到 50% [Spragins 1991]。显然，需要一个更健壮的差错检测方案（幸运的是实践中正在使用这样的方式！）。但是在研究实践中使用的差错检测方案之前，我们考虑对单比特奇偶校验的一种简单一般化方案，这将使我们深入地理解纠错技术。

图 5-5 显示了单比特奇偶校验方案的二维一般化方案。这里 D 中的 d 个比特被划分为 i 行 j 列。对每行和每列计算奇偶值。产生的 $i+j+1$ 奇偶比特构成了链路层帧的差错检测比特。

现在假设在初始 d 比特信息中出现了单个比特差错。使用这种二维奇偶校验（two-dimensional parity）方案，包含比特值改变的列和行的校验值都将会出现差错。因此接收方不仅可以检测到出现了单个比特差错的事实，而且还可以利用存在奇偶校验差错的列和行的索引来实际识别发生差错的比特并纠正它！图 5-5 显示了一个例子，其中位于 $(2, 2)$ 的值为 1 的比特损坏了，变成了 0，该差错就是一个在接收方可检测并可纠正的差错。尽管我们的讨论是针对初始 d 比特信息的，但校验比特本身的单个比特差错也是可检测和可纠正的。二维奇偶校验也能够检测（但不能纠正！）一个分组中两个比特差错的任何组合。二维奇偶校验方案的其他特性将在本章后面的习题中进行探讨。




图 5-5 二维偶校验

接收方检测和纠正差错的能力被称为前向纠错（Forward Error Correction, FEC）。这些技术通常用于如音频 CD 这样的音频存储和回放设备中。在网络环境中，FEC 技术可以单独应用，或与链路层 ARQ 技术一起应用，ARQ 技术与我们在第 3 章研究的协议类似。FEC 技术很有价值，因为它们可以减少所需的发送方重发的次数。也许更为重要的是，它们允许在接收方立即纠正差错。FEC 避免了不得不等待的往返时延，而这些时延是发送方收到 NAK 分组并向接收方重传分组所需要的，这对于实时网络应用 [Rubenstein 1998] 或者具有长传播时延的链路（如深空间链路）可能是一种非常重要的优点。研究差错控制协议中 FEC 的使用的资料包括 [Biersack 1992; Nonnenmacher 1998; Byers 1998; Shacham 1990]。

5.2.2 检验和方法

在检验和技术中，图 5-4 中的 d 比特数据被作为一个 k 比特整数的序列处理。一个简单检验和方法就是将这 k 比特整数加起来，并且用得到的和作为差错检测比特。因特网检验和（Internet checksum）就基于这种方法，即数据的字节作为 16 比特的整数对待并求

和。这个和的反码形成了携带在报文段首部的因特网检验和。如在 3.3 节讨论的那样，接收方通过对接收的数据（包括检验和）的和取反码，并且检测其结果是否为全 1 比特来检测检验和。如果这些比特中有任何比特是 0，就可以指示出差错。RFC 1071 详细地讨论因特网检验和算法和它的实现。在 TCP 和 UDP 协议中，对所有字段（包括首部和数据字段）都计算因特网检验和。在其他协议中，例如 XTP [Strayer 1992]，对首部计算一个检验和，对整个分组计算另一个检验和。

检验和方法需要相对小的分组开销。例如，TCP 和 UDP 中的检验和只用了 16 比特。然而，与后面要讨论的常用于链路层的 CRC 相比，它们提供相对弱的差错保护。这时，一个很自然的问题是：为什么运输层使用检验和而链路层使用 CRC 呢？前面讲过运输层通常是在主机中作为用户操作系统的一部分用软件实现的。因为运输层差错检测用软件实现，采用简单而快速如检验和这样的差错检测方案是重要的。在另一方面，链路层的差错检测在适配器中用专用的硬件实现，它能够快速执行更复杂的 CRC 操作。Feldmeier [Feldmeier 1995] 描述的快速软件实现技术不仅可用于加权检验和编码，而且可用于 CRC（见后面）和其他编码。

5.2.3 循环冗余检测

现今的计算机网络中广泛应用的差错检测技术基于循环冗余检测（Cyclic Redundancy Check, CRC）编码。CRC 编码也称为多项式编码（polynomial code），因为该编码能够将要发送的比特串看作为系数是 0 和 1 一个多项式，对比特串的操作被解释为多项式算术。

CRC 编码操作如下。考虑 d 比特的数据 D ，发送结点要将其发送给接收结点。发送方和接收方首先必须协商一个 $r+1$ 比特模式，称为生成多项式（generator），我们将其表示为 G 。我们将要求 G 的最高有效位的比特（最左边）是 1。CRC 编码的关键思想如图 5-6 所示。对于一个给定的数据段 D ，发送方要选择 r 个附加比特 R ，并将它们附加到 D 上，使得得到的 $d+r$ 比特模式（被解释为一个二进制数）用模 2 算术恰好能被 G 整除（即没有余数）。用 CRC 进行差错检测的过程因此很简单：接收方用 G 去除接收到的 $d+r$ 比特。如果余数为非零，接收方知道出现了差错；否则认为数据正确而被接收。




图 5-6 CRC

所有 CRC 计算采用模 2 算术来做，在加法中不进位，在减法中不借位。这意味着加法和减法是相同的，而且这两种操作等价于操作数的按位异或（XOR）。因此，举例来说：

```
1011 XOR 0101 = 1110
1001 XOR 1101 = 0100
类似的，我们还会有：
1011 - 0101 = 1110
1001 - 1101 = 0100
```

除了所需的加法或减法操作没有进位或借位外，乘法和除法与在二进制算术中是相同的。如在通常的二进制算术中那样，乘以 2^k 就是以一种比特模式左移 k 个位置。这样，给定 D 和 R ， $D \cdot 2^r \text{ XOR } R$ 产生如图 5-6 所示的 $d+r$ 比特模式。在下面的讨论中，我们将利用图 5-6 中这种 $d+r$ 比特模式的代数特性。

现在我们回到发送方怎样计算 R 这个关键问题上来。前面讲过，我们要求出 R 使得对于 n 有：

$$D \cdot 2^r \text{ XOR } R = nG$$

也就是说，我们要选择 R 使得 G 能够除以 $D \times 2^r \text{ XOR } R$ 而没有余数。如果我们对上述等式的两边都用 R 异或（即用模 2 加，而没有进位），我们得到

$$D \cdot 2^r = nG \text{ XOR } R$$

这个等式告诉我们，如果我们用 G 来除 $D \cdot 2^r$ ，余数值刚好是 R 。换句话说，我们可以这样计算 R ：

$$R = \text{remainder} \frac{D \cdot 2^r}{G}$$

图 5-7 举例说明了在 $D = 101110$ ， $d = 6$ ， $G = 1001$ 和 $r = 3$ 的情况下的计算过程。在这种情况下传输的 9 个比特是 101110011。你应该自行检查一下这些计算，并核对一下 $D \cdot 2^r = 101011 \cdot G \text{ XOR } R$ 的确成立。




图 5-7 一个简单的 CRC 计算

国际标准已经定义了 8、12、16 和 32 比特生成多项式 G 。CRC-32 32 比特的标准被多种链路级 IEEE 协议采用，使用的一个生成多项式是：

$$G_{\text{CRC-32}} = 10000010011000001000111011011011$$

每个 CRC 标准都能检测小于 $r + 1$ 比特的突发差错。（这意味着所有连续的 r 比特或者更少的差错都可以检测到。）此外，在适当的假设下，长度大于 $r + 1$ 比特的突发差错以概率 $1 - 0.5^r$ 被检测到。每个 CRC 标准也都能检测任何奇数个比特差错。有关 CRC 检测实现的讨论可参见 [Williams 1993]。CRC 编码甚至更强的编码所依据的理论超出了本书的范围。教科书 [Schwartz 1980] 对这个主题提供了很好的介绍。

5.3 多路访问链路和协议

在本章概述中，我们提到了有两种类型的网络链路：点对点链路和广播链路。点对点链路（point-to-point link）由链路一端的单个发送方和链路另一端的单个接收方组成。许多链路层协议都是为点对点链路设计的，如点对点协议（point-to-point protocol, PPP）和高级数据链路控制（high-level data link control, HDLC）就是两种这样的协议，我们将在本章后面涉及它们。第二种类型的链路是广播链路（broadcast link），它能够让多个发送和接收结点都连接到相同的、单一的、共享的广播信道上。这里使用术语“广播”是因为当任何一个结点传输一个帧时，信道广播该帧，每个其他结点都收到一个副本。以太网和无线局域网是广播链路层技术的例子。在本节，我们暂缓讨论特定的链路层协议，而先研究一个对链路层很重要的问题：如何协调多个发送和接收结点对一个共享广播信道的访问，这就是多路访问问题（multiple access problem）。广播信道通常用于局域网中，局域网是一个地理上集中在一座建筑物中（或者在一个公司，或者在大学校园）的网络。因此我们还将在本节后面考察一下多路访问信道是如何在局域网中使用的。

我们都很熟悉广播的概念，因为自电视发明以来就使用了这种通信方式。但是传统的电视是一种一个方向的广播（即一个固定的结点向许多接收结点传输），而计算机网络广

播信道上的结点既能够发送也能够接收。也许对广播信道的一个更有人情味的类比是鸡尾酒会，在那里许多人聚集在一个大房间里（空气为提供广播的媒体）谈论和倾听。第二个切题的类比是许多读者都很熟悉的地方，即一间教室，在那里老师们和同学们同样共享相同的、单一的广播媒体。在这两种场景下，一个中心问题是确定谁以及在什么时候获得说话权力（也就是向信道传输）。作为人类，为了共享这种广播信道，我们已经演化得到了一个精心设计的协议集了：

- “给每个人一个讲话的机会。”
- “该你讲话时你才说话。”
- “不要一个人独占整个谈话。”
- “如果有问题请举手。”
- “当有人讲话时不要打断。”
- “当其他人讲话时不要睡觉。”

计算机网络有类似的协议，也就是所谓的**多路访问协议**（multiple access protocol），即结点通过这些协议来规范它们在共享的广播信道上的传输行为。如图 5-8 所示，在各种各样的网络环境下需要多路访问协议，包括有线和无线接入网，以及卫星网络。尽管从技术上讲每个结点通过它的适配器访问广播信道，但在本节中我们将把结点作为发送和接收设备。在实践中，数以百计或者甚至数以千计个结点能够通过一个广播信道直接通信。




图 5-8 多种多路访问信道

因为所有的结点都能够传输帧，所以多个结点可能会同时传输帧。当发生这种情况时，所有结点同时接到多个帧；这就是说，传输的帧在所有的接收方处**碰撞**（collide）了。通常，当碰撞发生时，没有一个接收结点能够有效地获得任何传输的帧；在某种意义上，碰撞帧的信号纠缠在一起。因此，涉及此次碰撞的所有帧都丢失了，在碰撞时间间隔中的广播信道被浪费了。显然，如果许多结点要频繁地传输帧，许多传输将导致碰撞，广播信道的大量带宽将被浪费掉。

当多个结点处于活跃状态时，为了确保广播信道执行有用的工作，以某种方式协调活

跃结点的传输是必要的。这种协调工作由多路访问协议负责。在过去的 40 年中，已经有上千篇文章和上百篇博士论文研究过多路访问协议；有关这部分工作前 20 年来的一个内容丰富的综述见 [Rom 1990]。此外，由于新类型链路尤其是新的无线链路不断出现，在多路访问协议方面研究的活跃状况仍在继续。

这些年来，在大量的链路层技术中已经实现了几十种多路访问协议。尽管如此，我们能够将任何多路访问协议划分为 3 种类型之一：信道划分协议（channel partitioning protocol），随机接入协议（random access protocol）和轮流协议（taking-turns protocol）。我们将在后续的 3 个小节中讨论这几类多路访问协议。

在结束概述之前，我们给出下列条件。在理想情况下，对于速率为 R bps 的广播信道，多路访问协议应该具有以下所希望的特性：

- 1) 当仅有一个结点有数据发送时，该结点具有 R bps 的吞吐量；
- 2) 当有 M 个结点要发送数据时，每个结点吞吐量为 R/M bps。这不要求 M 结点中的每一个结点总是有 R/M 的瞬间速率，而是每个结点在一些适当定义的时间间隔内应该有 R/M 的平均传输速率。
- 3) 协议是分散的；这就是说不会因某主结点故障而使整个系统崩溃。
- 4) 协议是简单的，使实现不昂贵。

5.3.1 信道划分协议

我们前面在 1.3 节讨论过，时分多路复用（TDM）和频分多路复用（FDM）是两种能够用于在所有共享信道结点之间划分广播信道带宽的技术。举例来说，假设一个支持 N 个结点的信道且信道的传输速率为 R bps。TDM 将时间划分为时间帧（time frame），并进一步划分每个时间帧为 N 个时隙（slot）。（不应当把 TDM 时间帧与在发送和接收适配器之间交换的链路层数据单元相混淆，后者也被称为帧。为了减少混乱，在本小节中我们将链路层交换的数据单元称为分组。）然后把每个时隙分配给 N 个结点中的一个。无论何时某个结点在有分组要发送的时候，它在循环的 TDM 帧中指派给它的时隙内传输分组比特。通常，选择的时隙长度应使一个时隙内能够传输单个分组。图 5-9 表示一个简单的 4 个结点的 TDM 例子。再回到我们的鸡尾酒会类比中，一个采用 TDM 规则的鸡尾酒会将允许每个聚会客人在固定的时间段发言，然后再允许另一个聚会客人发言同样时长，以此类推。一旦每个人都有了说话机会，将不断重复着这种模式。

TDM 是有吸引力的，因为它消除了碰撞而且非常公平：每个结点在每个帧时间内得到了专用的传输速率 R/N bps。然而它有两个主要缺陷。首先，结点被限制于 R/N bps 的平均速率，即使当它是唯一有分组要发送的结点时。其次，结点必须总是等待它在传输序列中的轮次，即我们再次看到，即使它是唯一一个有




图 5-9 一个 4 结点的 TDM 与 FDM 的例子

帧要发送的结点。想象一下某聚会客人是唯一一个有话要说的人的情形（并且想象一下这种十分罕见的情况，即酒会上所有的人都想听某一个人说话）。显然，一种多路访问协议用于这个特殊聚会时，TDM 是一种很糟的选择。

TDM 在时间上共享广播信道，而 FDM 将 R bps 信道划分为不同的频段（每个频段具有 R/N 带宽），并把每个频率分配给 N 个结点中的一个。因此 FDM 在单个较大的 R bps 信道中创建了 N 个较小的 R/N bps 信道。FDM 也有 TDM 同样的优点和缺点。它避免了碰撞，在 N 个结点之间公平地划分了带宽。然而，FDM 也有 TDM 所具有的主要缺点，也就是限制一个结点只能使用 R/N 的带宽，即使当它是唯一一个有分组要发送的结点时。

第三种信道划分协议是码分多址（Code Division Multiple Access, CDMA）。TDM 和 FDM 分别为结点分配时隙和频率，而 CDMA 对每个结点分配一种不同的编码。然后每个结点用它唯一的编码来对它发送的数据进行编码。如果精心选择这些编码，CDMA 网络具有一种奇妙的特性，即不同的结点能够同时传输，并且它们各自相应的接收方仍能正确接收发送方编码的数据比特（假设接收方知道发送方的编码），而不在乎其他结点的干扰传输。CDMA 已经在军用系统中使用了一段时间（由于它的抗干扰特性），目前已经广泛地用于民用，尤其是蜂窝电话中。因为 CDMA 的使用与无线信道紧密相关，所以我们将把有关 CDMA 技术细节的讨论留到第 6 章。此时，我们知道 CDMA 编码类似于 TDM 中的时隙和 FDM 中的频率，能分配给多路访问信道的用户就可以了。

5.3.2 随机接入协议

第二大类多访问协议是随机接入协议。在随机接入协议中，一个传输结点总是以信道的全部速率（即 R bps）进行发送。当有碰撞时，涉及碰撞的每个结点反复地重发它的帧（也就是分组），到该帧无碰撞地通过为止。但是当—个结点经历—次碰撞时，它不必立刻重发该帧。相反，它在重发该帧之前等待—个随机时延。涉及碰撞的每个结点独立地选择随机时延。因为该随机时延是独立地选择的，所以下述现象是有可能的：这些结点之一所选择的时延充分小于其他碰撞结点的时延，并因此能够无碰撞地将它的帧在信道中发出。

文献中描述的随机接入协议即使没有上百种也有几十种 [Rom 1990; Bertsekas 1991]。在本节中，我们将描述一些最常用的随机接入协议，即 ALOHA 协议 [Abramson 1970; Abramson 1985; Abramson 2009] 和载波侦听多路访问（CSMA）协议 [Kleinrock 1975b]。以太网 [Metcalfe 1976] 是一种流行并广泛部署的 CSMA 协议。

1. 时隙 ALOHA

我们以最简单的随机接入协议之一——时隙 ALOHA 协议，开始我们对随机接入协议的学习。在对时隙 ALOHA 的描述中，我们做下列假设：

- 所有帧由 L 比特组成。
- 时间被划分成长度为 L/R 秒的时隙（这就是说，一个时隙等于传输—帧的时间）。
- 结点只在时隙起点开始传输帧。
- 结点是同步的，每个结点都知道时隙何时开始。
- 如果在一个时隙中有两个或者更多个帧碰撞，则所有结点在该时隙结束之前检测到该碰撞事件。

令 p 是一个概率，即一个在 0 和 1 之间的数。在每个结点中，时隙 ALOHA 的操作是

简单的：

- 当结点有一个新帧要发送时，它等到下一个时隙开始并在该时隙传输整个帧。
- 如果没有碰撞，该结点成功地传输它的帧，从而不需要考虑重传该帧。（如果该结点有新帧，它能够为传输准备一个新帧。）
- 如果有碰撞，该结点在时隙结束之前检测到这次碰撞。该结点以概率 p 在后续的几个时隙中重传它的帧，直到该帧被无碰撞地传输出去。

我们说以概率 p 重传，是指某结点有效地投掷一个有偏倚的硬币；硬币正面事件对应着重传，而重传出现的概率为 p 。硬币反面事件对应着“跳过这个时隙，在下个时隙再掷硬币”；这个事件以概率 $(1 - p)$ 出现。所有涉及碰撞的结点独立地投掷它们的硬币。

时隙 ALOHA 看起来有很多优点。与信道划分不同，当某结点是唯一活跃的结点时（一个结点如果有帧要发送就认为它是活跃的），时隙 ALOHA 允许该结点以全速 R 连续传输。时隙 ALOHA 也是高度分散的，因为每个结点检测碰撞并独立地决定什么时候重传。（然而，时隙 ALOHA 的确需要在结点中对时隙同步；我们很快将讨论 ALOHA 协议的一个不分时隙的版本以及 CSMA 协议，这两种协议都不需要这种同步。）时隙 ALOHA 也是一个极为简单的协议。

当只有一个活跃结点时，时隙 ALOHA 工作出色，但是当有多个活跃结点时效率又将如何呢？这里有两个可能要考虑的效率问题。首先，如在图 5-10 中所示，当有多个活跃结点时，一部分时隙将有碰撞，因此将被“浪费”掉了。第二个考虑是，时隙的另一部分将是空闲的，因为所有活跃结点由于概率传输策略会节制传输。唯一“未浪费的”时隙是那些刚好有一个结点传输的时隙。刚好有一个结点传输的时隙称为一个**成功时隙**（successful slot）。时隙多路访问协议的**效率**（efficiency）定义为：当有大量的活跃结点且每个结点总有大量的帧要发送时，长期运行中成功时隙的份额。注意到如果不使用某种形式的访问控制，而且每个结点都在每次碰撞之后立即重传，这个效率将为零。时隙 ALOHA 显然增加了它的效率，使之大于零，但是效率增加了多少呢？




图 5-10 结点 1、2 和 3 在第一个时隙碰撞。结点 2 最终在第 4 个时隙成功，结点 1 在第 8 个时隙成功，结点 3 在第 9 个时隙成功

现在我们继续概要讨论时隙 ALOHA 最大效率的推导过程。为了保持该推导简单，我们对协议做了一点修改，假设每个结点试图在每个时隙以概率 p 传输一帧。（这就是说，我们假设每个结点总有帧要发送，而且结点对新帧和已经经历一次碰撞的帧都以概率 p 传输。）假设有 N 个结点。则一个给定时隙是成功时隙的概率为结点之一传输而余下的 $N - 1$