

- (1) 可扩展的（速率从 10 Mbit/s 到 400 Gbit/s）。
- (2) 灵活的（多种媒体、全/半双工、共享/交换）。
- (3) 易于安装的。
- (4) 稳健性好的。

3.5.4 使用以太网进行宽带接入

现在人们也在使用以太网进行宽带接入互联网。为此，IEEE 在 2001 年初成立了 802.3EFM 工作组^①，专门研究高速以太网的宽带接入技术问题。

以太网接入的一个重要特点是它可以提供双向的宽带通信，并且可以根据用户对带宽的需求灵活地进行带宽升级（例如，把 10 兆的以太网交换机更新为吉比特的以太网交换机）。当城域网和广域网都采用吉比特以太网或 10 吉比特以太网时，采用以太网接入可以实现端到端的以太网传输，中间不需要再进行帧格式的转换。这就提高了数据的传输效率且降低了传输的成本。

然而以太网的帧格式标准中，在地址字段部分并没有用户名字段，也没有让用户键入密码来鉴别用户身份的过程。如果网络运营商要利用以太网接入到互联网，就必须解决这个问题。

于是有人就想法子把数据链路层的两个成功的协议结合起来，即把 PPP 协议中的 PPP 帧再封装到以太网中来传输。这就是 1999 年公布的 PPPoE (PPP over Ethernet)，意思是“在以太网上运行 PPP” [RFC 2516]。现在的光纤宽带接入 FTTx 都要使用 PPPoE 的方式进行接入。

例如，如果使用光纤到大楼 FTTB 的方案，就在每个大楼的楼口安装一个光网络单元 ONU（其作用和以太网交换机差不多），然后根据用户所申请的带宽，用 5 类线（请注意，到这个地方，传输媒体已经变为铜线了）接到用户家中。如果大楼里上网的用户很多，那么还可以在每一个楼层再安装一个 100 Mbit/s 的以太网交换机。各大楼的以太网交换机通过光缆汇接到光汇接点（光汇接点一般通过城域网连接到互联网的主干网）。

使用这种方式接入到互联网时，在用户家中不再需要使用任何调制解调器，只要一个 RJ-45 的插口即可。用户把自己的个人电脑通过 5 类网线连接到墙上的 RJ-45 插口中，然后在 PPPoE 弹出的窗口中键入在网络运营商处购买的用户名（就是一串数字）和密码（严格说就是口令），就可以进行宽带上网了。请注意，使用这种以太网宽带接入时，从用户家中的个人电脑到户外的第一个以太网交换机的带宽是能够得到保证的。因为这个带宽是用户独占的，没有和其他用户共享。但这个以太网交换机到上一级的交换机的带宽，是许多用户共享的。因此，如果过多的用户同时上网，则有可能使每一个用户实际上享受到的带宽减少。这时，网络运营商就应当及时进行扩容，以保证用户的利益不受损伤。

顺便指出，当用户利用 ADSL（非对称数字用户线）进行宽带上网时，从用户个人电脑到家中的 ADSL 调制解调器之间，也是使用 RJ-45 和 5 类线（即以太网使用的网线）进行连

^① 注：通信网的数字化是从主干网开始的，最后剩下的一段模拟线路是用户线，因此这一段用户线常称为是通信线路数字化过程中的“最后一英里”。IEEE 802.3EFM 中的“EFM”表示“Ethernet in the First Mile”，意思是从用户端开始算，“第一英里采用以太网”，也就是说，EFM 表示“采用以太网接入”。

接的，并且也是使用 PPPoE 弹出的窗口进行拨号连接的。但是用户个人电脑发送的以太网帧到了家里的 ADSL 调制解调器后，就转换为 ADSL 使用的 PPP 帧。需要注意的是，在用户家中墙上是通过电话使用的 RJ-11 插口，用普通的电话线传送 PPP 帧。这已经和以太网没有关系了。所以这种上网方式不能称为以太网上网，而是利用电话线宽带接入到互联网。

本章的重要概念

- 链路是从一个节点到相邻节点的一段物理线路，数据链路则是在链路的基础上增加了一些必要的硬件（如网络适配器）和软件（如协议的实现）。
- 数据链路层使用的信道主要有点对点信道和广播信道两种。
- 数据链路层传送的协议数据单元是帧。数据链路层的三个基本问题是：封装成帧、透明传输和差错检测。
- 循环冗余检验 CRC 是一种检错方法，而帧检验序列 FCS 是添加在数据后面的冗余码。
- 点对点协议 PPP 是数据链路层使用最多的一种协议，它的特点是：简单；只检测差错，而不是纠正差错；不使用序号，也不进行流量控制；可同时支持多种网络层协议。
- PPPoE 是为宽带上网的主机使用的链路层协议。
- 局域网的优点是：具有广播功能，从一个站点可很方便地访问全网；便于系统的扩展和逐渐演变；提高了系统的可靠性、可用性和生存性。
- 共享通信媒体资源的方法有二：一是静态划分信道（各种复用技术），二是动态媒体接入控制，又称为多点接入（随机接入或受控接入）。
- IEEE 802 委员会曾把局域网的数据链路层拆成两个子层，即逻辑链路控制（LLC）子层（与传输媒体无关）和媒体接入控制（MAC）子层（与传输媒体有关）。但现在 LLC 子层已成为历史。
- 计算机与外界局域网的通信要通过网络适配器，它又称为网络接口卡或网卡。计算机的硬件地址就在适配器的 ROM 中。
- 以太网采用无连接的工作方式，对发送的数据帧不进行编号，也不要求对方发回确认。目的站收到有差错帧就把它丢弃，其他什么也不做。
- 以太网采用的协议是具有冲突检测的载波监听多点接入 CSMA/CD。协议的要点是：发送前先监听，边发送边监听，一旦发现总线上出现了碰撞，就立即停止发送。然后按照退避算法等待一段随机时间后再次发送。因此，每一个站在自己发送数据之后的一小段时间内，存在着遭遇碰撞的可能性。以太网上各站点都平等地争用以太网信道。
- 传统的总线以太网基本上都是使用集线器的双绞线以太网。这种以太网在物理上是星形网，但在逻辑上则是总线网。集线器工作在物理层，它的每个端口仅仅简单地转发比特，不进行碰撞检测。
- 以太网的硬件地址，即 MAC 地址实际上就是适配器地址或适配器标识符，与主机所在的地点无关。源地址和目的地址都是 48 位长。
- 以太网的适配器有过滤功能，它只接收单播帧、广播帧或多播帧。
- 使用集线器可以在物理层扩展以太网（扩展后的以太网仍然是一个网络）。
- 交换式集线器常称为以太网交换机或第二层交换机（工作在数据链路层）。它就是

一个多端口的网桥，而每个端口都直接与某台单主机或另一个集线器相连，且工作在全双工方式。以太网交换机能同时连通许多对端口，使每一对相互通信的主机都能像独占通信媒体那样，无碰撞地传输数据。

- 高速以太网有 100 Mbit/s 的快速以太网、吉比特以太网和 10 Gbit/s 的 10 吉比特以太网。最近还发展到 400 吉比特以太网。在宽带接入技术中，也常使用高速以太网进行接入。

习题

- 3-01** 数据链路（即逻辑链路）与链路（即物理链路）有何区别？“链路接通了”与“数据链路接通了”的区别何在？
- 3-02** 数据链路层中的链路控制包括哪些功能？试讨论数据链路层做成可靠的链路层有哪些优点和缺点。
- 3-03** 网络适配器的作用是什么？网络适配器工作在哪一层？
- 3-04** 数据链路层的三个基本问题（封装成帧、透明传输和差错检测）为什么都必须加以解决？
- 3-05** 如果在数据链路层不进行封装成帧，会发生什么问题？
- 3-06** PPP 协议的主要特点是什么？为什么 PPP 不使用帧的编号？PPP 适用于什么情况？为什么 PPP 协议不能使数据链路层实现可靠传输？
- 3-07** 要发送的数据为 1101011011。采用 CRC 的生成多项式是 $P(X) = X^4 + X + 1$ 。试求应添加在数据后面的余数。
若要发送的数据在传输过程中最后一个 1 变成了 0，即变成了 1101011010，问接收端能否发现？
若要发送的数据在传输过程中最后两个 1 都变成了 0，即变成了 1101011000，问接收端能否发现？
采用 CRC 检验后，数据链路层的传输是否就变成了可靠的传输？
- 3-08** 要发送的数据为 101110。采用 CRC 的生成多项式是 $P(X) = X^3 + 1$ 。试求应添加在数据后面的余数。
- 3-09** 一个 PPP 帧的数据部分（用十六进制写出）是 7D 5E FE 27 7D 5D 7D 5D 65 7D 5E。试问真正的数据是什么（用十六进制写出）？
- 3-10** PPP 协议使用同步传输技术传送比特串 011011111111100。试问经过零比特填充后变成怎样的比特串？若接收端收到的 PPP 帧的数据部分是 0001110111110111110110，试问删除发送端加入的零比特后会变成怎样的比特串？
- 3-11** 试分别讨论以下各种情况在什么条件下是透明传输，在什么条件下不是透明传输。（提示：请弄清什么是“透明传输”，然后考虑能否满足其条件。）
(1) 普通的电话通信。
(2) 互联网提供的电子邮件服务。
- 3-12** PPP 协议的工作状态有哪几种？当用户要使用 PPP 协议和 ISP 建立连接进行通信时，需要建立哪几种连接？每一种连接解决什么问题？
- 3-13** 局域网的主要特点是什么？为什么局域网采用广播通信方式而广域网不采用呢？
- 3-14** 常用的局域网的网络拓扑有哪些种类？现在最流行的是哪种结构？为什么早期的以

- 以太网选择总线拓扑结构而不使用星形拓扑结构，但现在却改为使用星形拓扑结构呢？
- 3-15 什么叫作传统以太网？以太网有哪两个主要标准？
- 3-16 数据率为 10 Mbit/s 的以太网在物理媒体上的码元传输速率（即码元/秒）是多少？
- 3-17 为什么 LLC 子层的标准已制定出来了但现在却很少使用？
- 3-18 试说明 10BASE-T 中的“10”“BASE”和“T”所代表的意思。
- 3-19 以太网使用的 CSMA/CD 协议是以争用方式接入到共享信道的，这与传统的时分复用 TDM 相比有何优缺点？
- 3-20 假定 1 km 长的 CSMA/CD 网络的数据率为 1 Gbit/s。设信号在网络上的传播速率为 200000 km/s。求能够使用此协议的最短帧长。
- 3-21 什么叫作比特时间？使用这种时间单位有什么好处？100 比特时间是多少微秒？
- 3-22 假定在使用 CSMA/CD 协议的 10 Mbit/s 以太网中某个站在发送数据时检测到碰撞，执行退避算法时选择了随机数 $r = 100$ 。试问这个站需要等待多长时间后才能再次发送数据？如果是 100 Mbit/s 的以太网呢？
- 3-23 公式(3-3)表示，以太网的极限信道利用率与连接在以太网上的站点数无关。能否由此推论出：以太网的利用率也与连接在以太网上的站点数无关？请说明你的理由。
- 3-24 假定站点 A 和 B 在同一个 10 Mbit/s 以太网网段上。这两个站点之间的传播时延为 225 比特时间。现假定 A 开始发送一帧，并且在 A 发送结束之前 B 也发送一帧。如果 A 发送的是以太网所容许的最短的帧，那么 A 在检测到和 B 发生碰撞之前能否把自己的数据发送完毕？换言之，如果 A 在发送完毕之前并没有检测到碰撞，那么能否肯定 A 所发送的帧不会和 B 发送的帧发生碰撞？（提示：在计算时应当考虑到每一个以太网帧在发送到信道上时，在 MAC 帧前面还要增加若干字节的前同步码和帧定界符。）
- 3-25 上题中的站点 A 和 B 在 $t = 0$ 时同时发送了数据帧。当 $t = 225$ 比特时间，A 和 B 同时检测到发生了碰撞，并且在 $t = 225 + 48 = 273$ 比特时间完成了干扰信号的传输。A 和 B 在 CSMA/CD 算法中选择不同的 r 值退避。假定 A 和 B 选择的随机数分别是 $r_A = 0$ 和 $r_B = 1$ 。试问 A 和 B 各在什么时间开始重传其数据帧？A 重传的数据帧在什么时间到达 B？A 重传的数据会不会和 B 重传的数据再次发生碰撞？B 会不会在预定的重传时间停止发送数据？
- 3-26 以太网上只有两个站，它们同时发送数据，产生了碰撞。于是按截断二进制指数退避算法进行重传。重传次数记为 i ， $i = 1, 2, 3, \dots$ 。试计算第 1 次重传失败的概率、第 2 次重传失败的概率、第 3 次重传失败的概率，以及一个站成功发送数据之前的平均重传次数 I 。
- 3-27 有 10 个站连接到以太网上。试计算以下三种情况下每一个站所能得到的带宽。
(1) 10 个站都连接到一个 10 Mbit/s 以太网集线器；
(2) 10 个站都连接到一个 100 Mbit/s 以太网集线器；
(3) 10 个站都连接到一个 10 Mbit/s 以太网交换机。
- 3-28 10 Mbit/s 以太网升级到 100 Mbit/s、1 Gbit/s 和 10 Gbit/s 时，都需要解决哪些技术问题？为什么以太网能够在发展的过程中淘汰掉自己的竞争对手，并使自己的应用范围从局域网一直扩展到城域网和广域网？
- 3-29 以太网交换机有何特点？用它怎样组成虚拟局域网？

3-30 在图 3-30 中, 某学院的以太网交换机有三个端口分别和学院三个系的以太网相连, 另外三个端口分别和电子邮件服务器、万维网服务器以及一个连接互联网的路由器相连。图中的 A、B 和 C 都是 100 Mbit/s 以太网交换机。假定所有的链路的速率都是 100 Mbit/s, 并且图中的 9 台主机中的任何一个都可以和任何一个服务器或主机通信。试计算这 9 台主机和两个服务器产生的总的吞吐量的最大值。为什么?




图 3-30 习题 3-30 的图

- 3-31** 假定图 3-30 中的所有链路的速率仍然为 100 Mbit/s, 但三个系的以太网交换机都换成为 100 Mbit/s 的集线器。试计算这 9 台主机和两个服务器产生的总的吞吐量的最大值。为什么?
- 3-32** 假定图 3-30 中的所有链路的速率仍然为 100 Mbit/s, 但所有的以太网交换机都换成为 100 Mbit/s 的集线器。试计算这 9 台主机和两个服务器产生的总的吞吐量的最大值。为什么?
- 3-33** 在图 3-31 中, 以太网交换机有 6 个端口, 分别接到 5 台主机和一个路由器。




图 3-31 习题 3-33 的图

在下面表中的“动作”一栏中, 表示先后发送了 4 个帧。假定在开始时, 以太网交换机的交换表是空的。试把该表中其他的栏目都填写完。

动作	交换表的状态	向哪些端口转发帧	说明
A 发送帧给 D			
D 发送帧给 A			
E 发送帧给 A			
A 发送帧给 E			

第4章 网络层

本章讨论网络互连问题。在介绍网络层提供的两种服务和两个层面后，就进入本章的核心内容——网际协议 IP，这是本书的一个重点内容。只有深入地掌握了协议 IP 的主要内容，才能理解互联网是怎样工作的。本章还要讨论网际控制报文协议 ICMP、几种常用的路由选择协议、IPv6 的主要特点、IP 多播的概念等。在讨论虚拟专用网 VPN 和网络地址转换 NAT 后，最后简单介绍多协议标签交换 MPLS 和软件定义网络 SDN 的基本概念。

本章最重要的内容是：

- (1) 虚拟互连网络和两种服务、两个层面的概念。
- (2) IP 地址与 MAC 地址的关系。
- (3) 传统分类的 IP 地址和无分类域间路由选择 CIDR（后者是重点）。
- (4) 路由选择协议的工作原理。

4.1 网络层的几个重要概念

4.1.1 网络层提供的两种服务

在计算机网络领域，网络层应该向运输层提供怎样的服务（“面向连接”还是“无连接”）曾引起了长期的争论。争论焦点的实质就是：在计算机通信中，可靠交付应当由谁来负责？是网络还是端系统？

有些人认为应当借助于电信网的成功经验，让网络负责可靠交付。大家知道，传统电信网的主要业务是提供电话服务。电信网使用昂贵的程控交换机（其软件也非常复杂），用面向连接的通信方式，使电信网络能够向用户（实际上就是电话机）提供可靠传输的服务。因此他们认为，计算机网络也应模仿打电话所使用的面向连接的通信方式。当两台计算机进行通信时，也应当先建立连接（但在分组交换中是建立一条虚电路 VC (Virtual Circuit)^①），以预留双方通信所需的一切网络资源。然后双方就沿着已建立的虚电路发送分组。这样的分组的首部不需要填写完整的目的主机地址，而只需要填写这条虚电路的编号（一个不大的整数），因而减少了分组的开销。这种通信方式如果再使用可靠传输的网络协议，就可使所发送的分组无差错按序到达终点，当然也不丢失、不重复。在通信结束后要释放建立的虚电路。图 4-1(a)是网络提供虚电路服务的示意图。主机 H_1 和 H_2 之间交换的分组都必须在事先建立的虚电路上传送。

但互联网的先驱者却提出一种崭新的网络设计思路。他们认为，电信网提供的端到端可靠传输的服务对传统的电话业务无疑是很合适的，因为那时电信网的终端（电话机）非常

^① 注：虚电路表示这只是一条逻辑上的连接，分组都沿着这条逻辑连接（好像是一条物理连接）按照存储转发方式传送，而并不是真正建立了一条物理连接。请注意，电路交换的电话通信是先建立了一条真正的连接。因此分组交换的虚连接和电路交换的连接只是类似而已，并不完全一样。

简单，没有智能，更没有差错处理能力。因此电信网必须负责把用户电话机话筒产生的话音信号可靠地传送到对方的电话机，使其耳机发出的声音符合话音质量的技术规范要求。但计算机网络的端系统是有智能的计算机。计算机有很强的差错处理能力（这点和传统的电话机有本质上的差别）。因此，互联网在设计上就采用了和电信网完全不同的思路。

互联网采用的设计思路是这样的：网络层要设计得尽量简单，向上层只提供简单灵活的、无连接的、尽最大努力交付的数据报服务^①。这里的“数据报”(datagram)是互联网的设计者最初使用的名词，其实数据报（或 IP 数据报）就是我们经常使用的“分组”。在本书中，IP 数据报和 IP 分组是同义词，可以混用。

网络在发送分组时不需要先建立连接。每一个分组（也就是 IP 数据报）独立发送，与其前后的分组无关（不进行编号）。网络层不提供服务质量的承诺。也就是说，所传送的分组可能出错、丢失、重复和失序（即不按序到达终点），当然也不保证分组交付的时限。由于传输网络不提供端到端的可靠传输服务，这就使网络中的路由器比较简单，且价格低廉（与电信网的交换机相比较）。如果主机（即端系统）进程之间需要进行可靠的通信，那么就由主机中的运输层负责（包括差错处理、流量控制等）。采用这种设计思路的好处是：网络造价大大降低，运行方式灵活，能够适应多种应用。互联网能够发展到今日的规模，充分证明了当初采用这种设计思路的正确性。

图 4-1(b)给出了网络提供数据报服务的示意图。主机 H_1 向 H_2 发送的分组各自独立地查找路由器中的转发表，逐跳传送到目的主机。在分组传送的过程中有丢失的可能。




图 4-1 网络层提供的两种服务

OSI 体系的支持者曾极力主张在网络层使用可靠传输的虚电路服务，也曾推出过网络层虚电路服务的著名标准——ITU-T 的 X.25 建议书。但现在 X.25 早已成为历史文献了。

表 4-1 归纳了虚电路服务与数据报服务的主要区别。

^① 注：尽最大努力交付(best effort delivery)当然不表示路由器可以任意丢弃分组，但这种交付方式实质上就是不可靠交付。顺便提一下，文献中也常使用“尽力而为”的译名。这个译名固然较为简洁，但似不够准确。

表 4-1 虚电路服务与数据报服务的对比

对比的方面	虚电路服务	数据报服务
思路	可靠通信应当由网络来保证	可靠通信应当由用户主机来保证
连接的建立	必须有	不需要
终点地址	仅在连接建立阶段使用，每个分组使用短的虚电路号	每个分组都有终点的完整地址，即 IP 地址
分组的转发	属于同一条虚电路的分组均按照同一路由进行转发	每个分组独立查找转发表进行转发
当节点出故障时	所有通过出故障的节点的虚电路均不能工作	出故障的节点可能会丢失分组，一些路由可能会发生变化
分组的顺序	总是按发送顺序到达终点	到达终点的顺序不一定按发送的顺序
端到端的差错处理和流量控制	可以由网络负责，也可以由用户主机负责	由用户主机负责

4.1.2 网络层的两个层面

在上面 4.1.1 节中，我们已经讲过，不同网络中的两个主机之间的通信，要经过若干个路由器转发分组来完成，分组查找路由器中的转发表，从指明的接口转发到下一个路由器。但转发表是怎样得出的呢？是从路由表导出的，而路由表又是由互联网中许多的路由器，按照共同选定的路由选择协议，通过许多次的相互交换路由信息而产生的。由此可见，在路由器之间传送的信息有以下两大类：

第一类是转发源主机和目的主机之间所传送的数据，把源主机所发送的分组，像接力赛跑那样从一个路由器转发到下一个路由器，最后把分组传送到目的主机。

第二类则是传送路由信息，是根据路由选择协议所使用的路由算法，彼此不断地交换路由信息分组，目的是为了在路由器中创建路由表，并由此导出为转发分组而用的转发表。这一类信息的传送是为第一类数据的传送服务的。

用图 4-2 的方法来描述，也就是把网络层抽象地划分为数据层面（或转发层面）和控制层面。这里所说的“层面(plane)”和体系结构中的“层次(layer)”很相似，都是抽象的概念。此处的 plane 目前国内尚无标准译名，也可以译为“面”。曾有人译为“平面”，但本书不采用这个译名，因为这容易联想到是几何学中的平面（其实与这种平面并无关联）。名词“层面”是目前文献中通用的抽象术语。在一个路由器实体中，显然无法看见这种抽象的层面。




图 4-2 网络层的数据层面和控制层面

这两个层面的机制相差很大。在数据层面中，每一个路由器根据本路由器生成的转发表，把收到的分组，从查找到的对应接口转发出去。为了加快转发的速率，现在的路由器通常都采用硬件进行转发，转发一个分组的时间为纳秒（ 10^{-9} 秒）数量级。但在控制层面中的

情况则不同。一个路由器不可能独自创建出路由表。路由器必须和相邻的路由器经常交换路由信息, 然后才能创建出本路由器的路由表。根据路由选择协议所用的路由算法计算路由要使用软件, 这就慢多了, 一般是秒的数量级。从以上所述不难看出, 数据层面的问题比较单纯, 因为路由器在转发分组时, 是**独立地**根据本路由器的转发表转发分组的, 但控制层面就比较复杂, 因为路由器要创建路由表, 就必须依靠许多路由器**协同动作**。不同的路由选择协议定义了不同的协同动作方式。路由器的生产厂家在制造路由器时, 已经在路由器内部嵌入了路由选择的通信模块, 使得路由器之间能够按照路由选择算法进行相互之间的通信。

从互联网诞生之日起, 路由器就是按照图 4-2 所示的模式工作的。本教材过去的几个版本在讲解路由器的结构时, 虽然没有使用控制层面和数据层面的概念, 但已经把路由器划分为路由选择和分组转发两大部分。其实这两部分的位置就分别处在图 4-2 所示的控制层面和数据层面之中。现在介绍网络层中控制层面和数据层面的概念, 是因为最近在网络界提出的**软件定义网络 SDN (Software Defined Network)**^①, 正在对这两个层面的结构进行了重大的改变。图 4-3 就是 SDN 提出的这两个层面的构成。




图 4-3 软件定义网络 SDN 中的控制层面和数据层面

我们注意到, 在传统的互联网中, 每一个路由器中, 既有转发表又有路由选择软件, 因此在图 4-2 中所画的虚线长方形方框也强调了这个特点。也就是说, 每个路由器中, 既有数据层面也有控制层面。但在图 4-3 所示的 SDN 结构中, 所有的路由器都变简单了。路由器中的路由选择软件都不存在了, 因此路由器之间不再相互交换路由信息。在网络的控制层面有一个在逻辑上集中的**远程控制器** (但在物理上可以由不同地点的多个服务器组成)。远程控制器掌握各主机和整个网络的状态, 能够为每一个分组计算出最佳的路由, 然后在每一个路由器中生成其正确的转发表。路由器的工作很单纯, 即收到分组, 查找转发表, 转发分组。

这样, 网络又变成为集中控制的。本来互联网是分散控制的, 为什么现在又提出集中控制呢? 其实, 软件定义网络 SDN 的提出, 并非现在要把整个互联网都改造为如图 4-3 所示的集中控制模式, 这是不现实的。然而在某些具体条件下, 特别是像一些大型的专用数据中心之间的广域网, 若使用 SDN 模式来建造, 就可以使网络运行的效率提高, 同时还可以获得更好的经济效益。因此, 建议读者关注这一新动向。在本书 4.10 节将简要介绍 SDN。

下面我们仍然按照传统互联网的机制, 陆续介绍属于数据层面的协议 IP, 然后再讨论

^① 注: 目前文献上出现的名词 SDN 尚无公认的权威定义。而 SDN 的英文写法也还有另外一种, 即 Software Defined Networking, 按照这种写法, 中文的译名似应为“软件定义的连网”, 即突出强调了连网的方式。考虑到目前中文的文献资料都是使用“软件定义网络”, 故本书也采用这样的译名。

属于控制层面的各种路由选择协议。

4.2 网际协议 IP

网际协议 IP (Internet Protocol)是 TCP/IP 体系中两个最主要的协议之一[STEV94][COME06][FORO10]，也是最重要的互联网标准协议之一[RFC 791, STD5]。网际协议 IP 又称为 Kahn-Cerf 协议，因为这个重要协议正是 Robert Kahn 和 Vint Cerf 二人共同研发的。这两位学者在 2004 年获得图灵奖（其地位相当于计算机科学领域的“诺贝尔奖”）。严格来说，这里所讲的 IP 其实是 IP 的第 4 个版本，记为 IPv4。但在讲述协议 IP 的各种原理时，常省略 IP 后面的版本号。在后面的 4.5 节我们再介绍较新的版本 IPv6（版本 1 ~ 3 和版本 5 都未曾使用过。顺便指出，所谓的 IPv9 只不过是某些人故意的炒作而已，不值一提）。

与协议 IP 配套使用的还有三个协议：

- 地址解析协议 ARP (Address Resolution Protocol)
- 网际控制报文协议 ICMP (Internet Control Message Protocol)
- 网际组管理协议 IGMP (Internet Group Management Protocol)

本来还有一个协议叫作逆地址解析协议 RARP (Reverse Address Resolution Protocol)，是和协议 ARP 配合使用的，但现在已被淘汰不使用了。

图 4-4 画出了这三个协议和网际协议 IP 的关系。在这一层中，ARP 画在最下面^①，因为 IP 经常要使用这个协议。ICMP 和 IGMP 画在这一层的上部，因为它们要使用协议 IP。这三个协议将在后面陆续介绍。由于网际协议 IP 是用来使互连起来的许多计算机网络能够进行通信的，因此 TCP/IP 体系中的网络层常常被称为网际层(internet layer)，或 IP 层。使用“网际层”这个名词的好处是强调了这是由很多网络构成的互连网络。目前比较普遍使用“网络层”这个名词。

在讨论网际协议 IP 之前，必须了解什么是虚拟互连网络。

4.2.1 虚拟互连网络

我们知道，如果要在全世界范围内把数以百万计的网络都互连起来，并且能够互相通信，那么这样的任务一定非常复杂。其中会遇到许多需要解决的问题，如：




图 4-4 网际协议 IP 及其配套协议



视频讲解

^① 注：在互联网标准中，ARP 被列入链路层协议[RFC 1122, STD3]，因此有些教科书就把 ARP 放在链路层中介绍[COME06][STEV94][KURO17]。但是 ARP 并不知道自己是处在协议栈的哪一层。从程序调用的关系看，ARP 实际上处在链路层和网络层之间[KOZI05]，但不少著名教材都是把 ARP 放在网络层中讲授的[TANE11][PETE12][FORO10][STAL10]。从教学的观点看，如果从协议的底层自下往上讲授，那么在学习链路层时就讲解 ARP 的工作原理，因涉及到 IP 地址的转换，似不易理解。编者的意见是，既然协议 ARP 实际上处于链路层和网络层之间，从教学法的角度考虑，对于自底层开始讲的教材，放在网络层讲述似较为方便。实际上，重要的是搞清 ARP 的工作原理，不必过于纠缠 ARP 究竟属于哪一层。

- 不同的寻址方案;
- 不同的最大分组长度;
- 不同的网络接入机制;
- 不同的超时控制;
- 不同的差错恢复方法;
- 不同的状态报告方法;
- 不同的路由选择技术;
- 不同的用户接入控制;
- 不同的服务 (面向连接服务和无连接服务);
- 不同的管理与控制方式; 等等。

能不能让大家使用相同的网络, 这样可使网络互连变得比较简单。答案是不行的。因为用户的需求是多种多样的, 没有一种单一的网络能够适应所有用户的需求。另外, 网络技术是不断发展的, 网络的制造厂家也要经常推出新的网络, 在竞争中求生存。因此客观讲在市场上总是有很多种不同性能、不同网络协议的网络, 供不同的用户选用。

从一般的概念来讲, 将网络互相连接起来要使用一些中间设备。根据中间设备所在的层次, 可以有以下四种不同的中间设备:

- (1) 物理层使用的中间设备叫作转发器(repeater)。
- (2) 数据链路层使用的中间设备叫作网桥或桥接器(bridge), 以及交换机(switch)。
- (3) 网络层使用的中间设备叫作路由器(router)^①。
- (4) 在网络层以上使用的中间设备叫作网关(gateway)。用网关连接两个不兼容的系统需要在高层进行协议的转换。

当中间设备是转发器或网桥时, 这仅仅是把一个网络扩大了, 而从网络层的角度看, 这仍然是一个网络, 一般并不称之为网络互连。网关由于比较复杂, 目前使用得较少。因此现在我们讨论网络互连时, 都是指用路由器进行网络互连和路由选择。路由器其实就是一台专用计算机, 用来在互联网中进行路由选择。由于历史的原因, 许多有关 TCP/IP 的文献曾经把网络层使用的路由器称为网关 (本书有时也这样用), 对此请读者加以注意。

图 4-5(a)表示有许多计算机网络通过一些路由器进行互连。由于参加互连的计算机网络都使用相同的网际协议 IP (Internet Protocol), 因此可以把互连以后的计算机网络看成为如图 4-5(b)所示的一个虚拟互连网络(internet)。所谓虚拟互连网络也就是逻辑互连网络, 它的意思就是互连起来的各种物理网络的异构性本来是客观存在的, 但是我们利用协议 IP 就可以使这些性能各异的网络在网络层上看起来好像是一个统一的网络。这种使用协议 IP 的虚拟互连网络可简称为 IP 网 (IP 网是虚拟的, 但平常不必每次都强调“虚拟”二字)。使用 IP 网的好处是: 当 IP 网上的主机进行通信时, 就好像在一个单个网络上通信一样, 它们看不见互连的各网络的具体异构细节 (如具体的编址方案、路由选择协议, 等等)。如果在这种覆盖全球的 IP 网的上层使用 TCP 协议, 那么就是现在的互联网(Internet)。

^① 注: 还有一种网桥和路由器的混合物桥路由器(brouter), 它是兼有网桥和路由器的功能的产品。实际上, 严格的网桥或严格的路由器产品是较少见的。不过桥路由器名词用得普遍。请注意 router 的读音是[rauter]。





图 4-5 IP 网的概念

当很多异构网络通过路由器互连起来时，如果所有的网络都使用相同的协议 IP，那么在网络层讨论问题就显得很方便。现在用一个例子来说明。

在图 4-6 所示的互联网中的源主机 H_1 要把一个 IP 数据报发送给目的主机 H_2 。根据第 1 章中讲过的分组交换的存储转发概念，主机 H_1 先要查找自己的转发表，看目的主机 H_2 是否就在本网络上。如是，则不需要经过任何路由器而是**直接交付**，任务就完成了。如不是，则必须把 IP 数据报发送给某个路由器（图中的 R_1 ）。 R_1 在查找了自己的转发表后，知道应当把数据报转发给 R_2 进行**间接交付**。这样一直转发下去，最后由路由器 R_5 知道自己是和 H_2 连接在同一个网络上，不需要再使用别的路由器转发了，于是就把数据报**直接交付**目的主机 H_2 。总之，分组从源节点 A 发送到目的节点 B，若中间必须经过一个或几个路由器（这表示 A 和 B 不在同一个网络上），则是间接交付。但若不需要经过路由器（这表示 A 和 B 在同一个网络上），则是直接交付。



图中的协议栈中的数字 1~5 分别表示物理层、数据链路层、网络层、运输层和应用层

图 4-6 分组在互联网中的传送

在图中画出了源主机、目的主机以及各路由器的协议栈。我们注意到，主机的协议栈共有五层，但路由器的协议栈只有下三层。图中还画出了数据在各协议栈中流动的方向（用黑色粗线表示）。我们还可注意到，在 R_4 和 R_5 之间使用了卫星链路，而 R_5 所连接的是个无线局域网（ R_5 和主机 H_2 都在同一个局域网中）。在 R_1 到 R_4 之间的三个网络则可以是任意类型的网络。总之，这里强调的是：**互联网可以由多种异构网络互连组成**。

有时可以把问题简化。我们可以想象 IP 数据报就在网络层中传送，传输路径可省略路由器之间的网络以及连接在这些网络上的许多无关主机。图 4-7 表示了这样的传输路径。




图 4-7 源主机 H_1 向目的主机 H_2 发送分组

在互联网的词汇中，分组在传送途中的每一次转发都称为一“跳(hop)”。也有人把 hop 译为跃点。路由器在转发分组时也常常使用“下一跳(next hop)”的说法。例如， R_1 的下一跳是 R_2 ，而 R_4 的下一跳是 R_5 。对于本例， H_1 向 H_2 发送分组需要经过 6 跳。我们还注意到，每一跳两端的两个节点都必定直接连接在同一个网络上。例如，在图 4-7 中从 R_2 到 R_3 的一跳，其两端的两个节点 R_2 和 R_3 都是连接在同一个网络上的。在上面所举的例子中，前 5 跳都是间接交付，只有最后一跳是直接交付。

4.2.2 IP 地址

在 TCP/IP 体系中，IP 地址是一个最基本的概念。一个连接在互联网上的设备，如果没有 IP 地址，就无法和网上的其他设备进行通信。因此应当首先学好有关 IP 地址的内容。

1. IP 地址及其表示方法

整个的互联网就是一个单一的、抽象的网络。IP 地址就是给连接到互联网上的每一台主机（或路由器）的每一个接口，分配一个在全世界范围内是唯一的 32 位的标识符。IP 地址的结构使我们可以在互联网上很方便地进行寻址。IP 地址现在由互联网名字和数字分配机构 ICANN (Internet Corporation for Assigned Names and Numbers) 进行分配^①。

对主机或路由器来说，IP 地址都是 32 位的二进制代码。为了提高可读性，我们常常把 32 位的 IP 地址中的每隔 8 位插入一个空格（但在机器中并没有这样的空格）。为了便于人们书写和记忆，常用其等效的十进制数字表示，并且在每段数字之间加上一个小数点。这就叫作点分十进制记法(dotted decimal notation)。图 4-8 是一个 IP 地址表示方法的例子。显然，把 IP 地址用 4 段十进制数字来表示是个很好的方法。

^① 注：IP 地址要按级申请分配。互联网号码分配机构 IANA 把大块 IP 地址按地区先分配给全球五个信息中心。中国互联网信息中心 CNNIC 再向其中的亚太网络信息中心 APNIC (Asia Pacific Network Information Center) 申请地址。我国的 ISP 则必须向 CNNIC 申请地址。IP 地址都是有偿租用的。



图 4-8 采用点分十进制记法能够提高可读性

前面所讲的给每个主机（或路由器）的接口分配一个 IP 地址，其含义就是这个 IP 地址不但标志了这个主机（或路由器），而且还标志了此接口所连接的网络。因此，32 位的 IP 地址采用两级结构，由两个字段组成。第一个字段是**网络号**，它标志主机（或路由器）所连接到的网络。一个网络号在整个互联网范围内必须是唯一的。第二个字段是**主机号**，它标志该主机（对路由器来说，就是标志该路由器）。一个主机号在所连接的网络（即前面的网络号所指明的网络）中必须是唯一的。由此可见，一个 IP 地址在整个互联网范围内是唯一的。因此，IP 地址可以记为：

$$\text{IP 地址} ::= \{ \langle \text{网络号} \rangle, \langle \text{主机号} \rangle \} \quad (4-1)$$

式(4-1)中的符号“ $::=$ ”表示“定义为”。IP 地址中包含网络号就表明，不连网的主机就没有 IP 地址。一定要记住，IP 地址指明了连接到某个网络上的一个主机（或路由器）。为简单起见，当不涉及路由器时，后面我们都以主机为例来介绍 IP 地址。

图 4-9 表示 IP 地址中的网络号和主机号的位置。具体的规定是：IP 地址中的前 n 位是主机所连接的网络号，而 IP 地址中后面的 $(32 - n)$ 位是主机号。现在的问题是，当我们看到一个 IP 地址时，怎样知道它的网络号的位数 n 是多少？下面我们就来讨论这个问题。




图 4-9 IP 地址中的网络号和主机号字段

2. 分类的 IP 地址

在互联网发展早期采用的是分类的 IP 地址，也就是在图 4-9 中的 n 是固定的几个数之一。分类的方法如图 4-10(a)所示。分类的方法非常简单。这里 A 类 ($n = 8$)、B 类 ($n = 16$) 和 C 类 ($n = 24$) 地址都是**单播地址**

（一对一通信），是最常用的。D 类是多播地址（一对多通信，我们将在 4.7 节讨论 IP 多播），而 E 类是保留地址。

32 位的 IP 地址空间共有 2^{32} （即 4294967296，接近 43 亿）个地址。A 类地址空间共有 2^{31} 个地址，占整个 IP 地址空间的 50%。B 类地址空间共有 2^{30} 个地址，占整个 IP 地址空间的 25%。整个 C 类地址空间共有 2^{29} 个地址，占整个 IP 地址的 12.5%。D 类和 E 类地址各占整个 IP 地址的 6.25%。图 4-10(b)给出了各类地址占 IP 地址总数的比例。

从图 4-10(a)可以看出，如果给出一个二进制数表示的 IP 单播地址，那么就可以很容易知道是哪类地址，并且也能看出这个二进制数表示的网络号和主机号。

例如，给出一个 IP 地址 10000000 00001110 00100011 00000111。对比一下图 4-10(a)，不难看出，这是一个 B 类地址，前 16 位是网络号，后 16 位是主机号。

扫一扫



视频讲解




图 4-10 分类的 IP 地址(a)以及各类地址所占的比例(b)

A 类地址的网络号字段占 1 个字节，只有 7 位可供使用（该字段的第一位已固定为 0）。但要注意，第一，网络号为全 0 的 IP 地址有特殊的用途，它表示“本网络”；第二，网络号为 127（即 01111111）保留作为本地软件环回测试(loopback test)本主机的进程之间的通信之用。若主机发送一个目的地址为环回地址（例如 127.0.0.1）的 IP 数据报，则本主机中的协议软件就处理数据报中的数据，而不会把数据报发送到任何网络。因此 A 类地址可指派的网络号是 126 个（即 $2^7 - 2$ ）。

A 类地址的主机号占 3 个字节。但全 0 和全 1 的主机号一般不指派。全 0 的主机号表示该 IP 地址是“本主机”所连接到的单个网络地址（例如，若主机的 IP 地址为 5.6.7.8，则该主机所在的网络的网络号是 5，而该网络的网络地址就是 5.0.0.0）。全 1 表示“所有的”，因此全 1 的主机号字段表示该网络上的所有主机。因此每一个 A 类网络中的最大主机数是 $2^{24} - 2$ ，即 16777214。

B 类地址的网络号字段有 2 个字节。因此 B 类地址可指派的网络数为 2^{14} ，即 16384。B 类地址的每一个网络上的最大主机数是 $2^{16} - 2$ ，即 65534。这里需要减 2 是因为要扣除全 0 和全 1 的主机号。

C 类地址有 3 个字节的网络号字段。因此 C 类地址可指派的网络总数是 2^{21} ，即 2097152。每一个 C 类地址的最大主机数是 $2^8 - 2$ ，即 254。

本书的前几个版本曾提到，B 类地址中的网络地址 128.0.0.0 和 C 类地址中的网络地址 192.0.0.0 都是规定不指派的。但现在这两个网络地址都已经可以指派了[RFC 6890]。

表 4-2 给出了一般不指派的特殊 IP 地址，这些地址只能在特定的情况下使用。

表 4-2 一般不指派的特殊 IP 地址

网络号	主机号	源地址使用	目的地址使用	代表的意义
0	0	可以	不可	在本网络上的本主机（见 6.6 节 DHCP 协议）
0	X	可以	不可	在本网络上主机号为 X 的主机
全 1	全 1	不可	可以	只在本网络上进行广播（各路由器均不转发）
Y	全 1	不可	可以	对网络号为 Y 的网络上的所有主机进行广播
127	非全 0 或全 1 的任何数	可以	可以	用于本地软件环回测试

这里要指出，由于近年来已经广泛使用无分类 IP 地址进行路由选择，A 类、B 类和 C

类这种分类地址已成为历史[RFC 1812]。由于很多文献和资料现在都仍然引用传统的分类的 IP 地址，因此我们对分类的 IP 地址还要进行简单的叙述。

把 IP 地址划分为 A 类、B 类、C 类三个类别，当初是这样考虑的：各种网络的差异很大，有的网络拥有很多主机，而有的网络上的主机则很少。把 IP 地址划分为 A 类、B 类和 C 类是为了更好地满足不同用户的需求。

这种分类的 IP 地址由于网络号的位数是固定的，因此管理简单、使用方便、转发分组迅速，完全可以满足当时互联网在美国的科研需求。后来，为了更加灵活地使用 IP 地址，出现了划分子网的方法，在 IP 地址的主机号中，插入一个子网号，把两级的 IP 地址变为三级的 IP 地址。但是，谁也没有预料到，互联网在 20 世纪 90 年代突然迅速地发展起来了。互联网从美国专用的科研实验网演变到世界范围开放的商用网！互联网用户的猛增，使得 IP 地址的数量面临枯竭的危险。这时，人们才注意到原来分类的 IP 地址在设计上确实有很不合理的地方。例如，一个 A 类网络地址块的主机号数目超过了 1677 万个！当初美国的很多大学都可以分配到一个 A 类网络地址块。一个大学怎么会需要这样多的 IP 地址？但在互联网出现早期，人们就是认为 IP 地址是用不完的，不需要精打细算地分配。又如，一个 C 类网络地址块可指派的主机号只有 254 个。但不少单位需要有 300 个以上的 IP 地址，那么干脆申请一个 B 类网络地址块（可以指派的主机号有 65534 个），宁可多要些 IP 地址，把多余的地址保留以后慢慢用。这样就浪费了不少的地址资源。即使后来采用了划分子网的方法，也无法解决 IP 地址枯竭的问题

于是，在 20 世纪 90 年代，当发现 IP 地址在不久后将会枯竭时，一种新的无分类编址方法就问世了。这种方法虽然也无法解决 IP 地址枯竭的问题，但可以推迟 IP 地址用尽的日子。下一节就介绍现在已普遍采用的这种编址方法。

3. 无分类编址 CIDR

这种编址方法的全名是无分类域间路由选择 CIDR (Classless Inter-Domain Routing, CIDR 的读音是“sider”)[RFC 4632]，其要点有以下三个。

(1) 网络前缀

CIDR 把图 4-9 中的网络号改称为“网络前缀”(network-prefix)（或简称为“前缀”），用来指明网络，剩下的后面部分仍然是主机号，用来指明主机。在有些文献中也把主机号字段称为后缀(suffix)。CIDR 的记法是：

$$\text{IP 地址} ::= \{ \langle \text{网络前缀} \rangle, \langle \text{主机号} \rangle \} \quad (4-2)$$

图 4-11 说明了 CIDR 的网络前缀和主机号的位置。看起来，这和图 4-9 也没有什么不同，只是把“网络号”换成为“网络前缀”。其实不然。这里最大的区别就是网络前缀的位数 n 不是固定的数，而是可以在 0~32 之间选取任意的值。




图 4-11 CIDR 表示的 IP 地址

CIDR 使用“斜线记法”(slash notation)，或称为 CIDR 记法，即在 IP 地址后面加上斜

扫一扫



视频讲解

线“/”，斜线后面是网络前缀所占的位数。例如，CIDR 表示的一个 IP 地址 128.14.35.7/20，二进制 IP 地址的前 20 位是**网络前缀**（相当于原来的网络号），剩下后面 12 位是主机号。

(2) 地址块

CIDR 把**网络前缀都相同**的所有连续的 IP 地址组成一个“CIDR 地址块”。一个 CIDR 地址块包含的 IP 地址数目，取决于网络前缀的位数。我们只要知道 CIDR 地址块中的任何一个地址，就可以知道这个地址块的起始地址（即最小地址）和最大地址，以及地址块中的地址数。例如，已知 IP 地址 128.14.35.7/20 是某 CIDR 地址块中的一个地址，现在把它写成二进制表示形式，其中的前 20 位是网络前缀（用粗体和下划线表示出），而前缀后面的 12 位是主机号：

$$128.14.35.7/20 = \underline{10000000\ 00001110\ 00100011\ 00000111}$$

可以很方便地得出这个地址所在的地址块中的最小地址和最大地址：

最小地址	128.14.32.0	10000000 00001110 00100000 00000000
最大地址	128.14.47.255	10000000 00001110 00101111 11111111

这个地址块的 IP 地址共有 2^{12} 个，扣除主机号为全 0 和全 1 的地址（最小地址和最大地址）后，**可指派的地址数**是 $2^{12} - 2$ 个。我们常使用地址块中的最小地址和网络前缀的位数指明一个地址块（不必每次都减 2 算出可指派的地址数，这样做太麻烦）。显然，上面导出的最小地址并不是该地址块 128.14.32.0/20 的网络地址。

也可以用二进制代码简要地表示此地址块：10000000 00001110 0010*。这里的星号*代表了主机号字段的所有的 0。星号前的二进制代码的个数，就是网络前缀的位数。

在不需要指明网络地址时，也可把这样的地址块简称为“/20 地址块”。

请读者注意：

128.14.32.7 是 IP 地址，但未指明网络前缀长度，因此不知道网络地址是什么。

128.14.32.7/20 也是 IP 地址，但同时指明了网络前缀为 20 位，由此可导出网络地址。

128.14.32.0/20 是包含多个 IP 地址的**地址块**或**网络前缀**，或更简单些，就称为**前缀**，同时也是这个地址块中主机号为全 0 的地址。请注意，上面地址块中 4 段十进制数字最后的 0 有时可以省略，即简写为 128.14.32/20。

我们不能仅用 128.14.32.0 来指明一个网络地址，因为无法知道**网络前缀是多少**。例如 128.14.32.0/19 或 128.14.32.0/21，也都是有效的网络地址。128.14.32.0 也可能是一个可以指派的 IP 地址（如果网络前缀的位数不超过 18）。

早期使用分类的 IP 地址时，A 类网络的前缀是 8 位，B 类网络的前缀是 16 位，而 C 类网络的前缀是 24 位，都是固定值，因此不需要重复指明其网络前缀。例如在使用分类地址时，一看 15.3.4.5 就知道是个 A 类地址，其网络地址为 15.0.0.0。但在使用 CIDR 记法时，15.3.4.5/30 则是一个很小的地址块 15.3.4.4/30 中的、不属于任何类别的一个 IP 地址。

总之，无分类编址 CIDR 具有很多优点，但一定要记住，采用 CIDR 后，仅从斜线左边的 IP 地址已无法知道其网络地址了。在这一点上，原来的分类地址还是比较方便的。

(3) 地址掩码

CIDR 使用斜线记法可以让我们知道网络前缀的数值。但是计算机看不见斜线记法，而是使用二进制来进行各种计算时必须使用 32 位的**地址掩**

扫一扫



视频讲解

码(address mask)能够从 IP 地址迅速算出网络地址。

地址掩码（常简称为掩码）由一连串 1 和接着的一连串 0 组成，而 1 的个数就是网络前缀的长度。地址掩码又称为子网掩码^①。在 CIDR 记法中，斜线后面的数字就是地址掩码中 1 的个数。例如，/20 地址块的地址掩码是：11111111 11111111 11110000 00000000（20 个连续的 1 和接着的 12 个连续的 0）。这个掩码用 CIDR 记法表示就是 255.255.240.0/20。

对于早期使用的分类 IP 地址，其地址掩码是固定的，常常不用专门指出。例如：

A 类网络，地址掩码为 255.0.0.0 或 255.0.0.0/8。

B 类网络，地址掩码为 255.255.0.0 或 255.255.0.0/16。

C 类网络，地址掩码为 255.255.255.0 或 255.255.255.0/24。

把二进制的 IP 地址和地址掩码进行按位 AND 运算，即可得出网络地址。图 4-12 说明了 AND 运算的过程。AND 运算就是逻辑乘法运算，其规则是：1 AND 1 = 1，1 AND 0 = 0，0 AND 0 = 0。点分十进制的 IP 地址是 128.14.35.7/20，前缀长度是 20（见图中的灰色背景）。请注意，从点分十进制的 IP 地址并不容易看出其网络地址。要使用二进制地址来运算。在本例中把二进制 IP 地址的前 20 位保留不变，剩下的 12 位全写为 0，即可得出网络地址。

	128 . 14 . 35 . 7
二进制 IP 地址	10000000 00001110 00100011 00000111
地址掩码	11111111 11111111 11110000 00000000
按位 AND 运算	10000000 00001110 00100000 00000000
网络地址	128 . 14 . 32 . 0 /20
	← 前缀 20 位 →

图 4-12 从 IP 地址算出网络地址

从上面的运算结果可以知道，IP 地址 128.14.35.7/20 所在的网络地址是 128.14.32.0/20。

表 4-3 给出了最常用的 CIDR 地址块。表中的 K 表示 2^{10} 即 1024。网络前缀长度在 13 到 27 之间是最常用的。在“包含的地址数”中把全 1 和全 0 的主机号都计算在内了。

表 4-3 常用的 CIDR 地址块

网络前缀长度	点分十进制	包含的地址数	相当于包含分类的网络数
/13	255.248.0.0	512 K	8 个 B 类或 2048 个 C 类
/14	255.252.0.0	256 K	4 个 B 类或 1024 个 C 类
/15	255.254.0.0	128 K	2 个 B 类或 512 个 C 类
/16	255.255.0.0	64 K	1 个 B 类或 256 个 C 类
/17	255.255.128.0	32 K	128 个 C 类
/18	255.255.192.0	16 K	64 个 C 类
/19	255.255.224.0	8 K	32 个 C 类
/20	255.255.240.0	4 K	16 个 C 类
/21	255.255.248.0	2 K	8 个 C 类
/22	255.255.252.0	1 K	4 个 C 类
/23	255.255.254.0	512	2 个 C 类

① 注：子网(subnet 或 subnetwork)是很常用的一个名词。某个网络的一部分就可以称为其子网。一个网络对整个互联网来说，就可以看成是一个子网。在本书中，“子网”和“网络”常常被认为是同义词，经常混用。

续表

网络前缀长度	点分十进制	包含的地址数	相当于包含分类的网络数
/24	255.255.255.0	256	1 个 C 类
/25	255.255.255.128	128	1/2 个 C 类
/26	255.255.255.192	64	1/4 个 C 类
/27	255.255.255.224	32	1/8 个 C 类

CIDR 地址中还有三个特殊地址块，即：

(1) 前缀 $n = 32$ ，即 32 位 IP 地址都是前缀，没有主机号。这其实就是一个 IP 地址。这个特殊地址用于主机路由（见 4.3.2 节）。

(2) 前缀 $n = 31$ ，这个地址块中只有两个 IP 地址，其主机号分别为 0 和 1。这个地址块用于点对点链路（见后面的第 4 小节）。

(3) 前缀 $n = 0$ 同时 IP 地址也是全 0，即 0.0.0.0/0。这用于默认路由（见 4.3.2 节）。

从表 4-3 可看出，每一个 CIDR 地址块中的地址数一定是 2 的整数次幂。除最后几行外，CIDR 地址块都包含了多个 C 类地址（是一个 C 类地址的 2^n 倍， n 是整数），因此在文献中有时称 CIDR 编址为“构造超网”。


使用 CIDR 的一个好处就是可以更加有效地分配 IP 地址空间，可根据客户的需要分配适当大小的 CIDR 地址块。然而在使用分类地址时，向一个部门分配 IP 地址，就只能以 /8、/16 或 /24 为单位来分配。这显然是很不灵活的。

一个大的 CIDR 地址块中往往包含很多小地址块，所以在路由器的转发表中就利用较大的一个 CIDR 地址块来代替许多较小的地址块。这种方法称为路由聚合(route aggregation)，它使得转发表中只用一个项目就可以表示原来传统分类地址的很多个（例如上千个）路由项目，因而大大压缩了转发表所占的空间，减少了查找转发表所需的时间。

图 4-13 给出的是 CIDR 地址块灵活分配的例子。假定某 ISP 已拥有地址块 206.0.64.0/18（相当于有 64 个 C 类网络）。现在某大学需要 800 个 IP 地址。ISP 可以给该大学分配一个地址块 206.0.68.0/22，它包括 1024（即 2^{10} ）个 IP 地址，相当于 4 个连续的 C 类 /24 地址块，占该 ISP 拥有的地址空间的 1/16。这个大学可灵活地对本校各系继续分配地址块，而各系还可再划分本系各教研室的小地址块。CIDR 的地址块的地址范围有时不易看清，这是因为网络前缀和主机号的界限不是恰好出现在整数字节处。但只要写出地址的二进制表示，弄清网络前缀的位数，就能够知道地址块的范围。

图 4-13 表示这个 ISP 共拥有 64 个 C 类网络。如果不采用 CIDR 技术，则在与该 ISP 的路由器交换路由信息的每一个路由器的转发表中，就需要有 64 行，每一行指出了到哪一个网络的下一跳。但采用地址聚合后，在转发表中只需要用一行来指出到 206.0.64.0/18 地址块的下一跳。这个大学共有 4 个系。在 ISP 内的路由器的转发表中，也仅需用 206.0.68.0/22 这一个项目，就能把外部发送到这个大学各系的所有分组，都转发到大学的路由器。这个路由器好比是大学的收发室。凡寄给大学任何一个系的邮件，邮递员都不必送到大学的各个系，而是把这些邮件集中投递到大学的收发室，然后由大学的收发室再进行下一步的分发。这样就加快了邮递员的投递工作（相当于缩短了转发表的查找时间）。

从图 4-13 的表格中可看出，网络前缀越短的地址块所包含的地址数就越多。



单位	地址块	二进制表示的地址块	相当于C类网络数
ISP	206.0.64.0/18	11001110 00000000 01*	64
大学	206.0.68.0/22	11001110 00000000 010001*	4
一系	206.0.68.0/23	11001110 00000000 0100010*	2
二系	206.0.70.0/24	11001110 00000000 01000110 *	1
三系	206.0.71.0/25	11001110 00000000 01000111 0*	1/2
四系	206.0.71.128/25	11001110 00000000 01000111 1*	1/2

表中星号*是一种常用的简写方式，表示星号后面的二进制主机号都省略了

图 4-13 CIDR 地址块划分举例

4. IP 地址的特点

IP 地址具有以下一些重要特点。

(1) 每一个 IP 地址都由网络前缀和主机号两部分组成。从这个意义上说，IP 地址是一种分等级的地址结构。分两个等级的好处是：第一，IP 地址管理机构在分配 IP 地址时只分配网络前缀（第一级），而剩下的主机号（第二级）则由得到该网络前缀的单位自行分配。这样就方便了 IP 地址的管理；第二，路由器根据目的主机所连接的网络前缀（即地址块）来转发分组（而不考虑目的主机号），这样就可以使转发表中的项目数大幅度减少，从而减少转发表所占的存储空间，缩短查找转发表的时间。

(2) 实际上 IP 地址是标志一台主机（或路由器）和一条链路的接口。当一台主机同时连接到两个网络上时，该主机就必须同时具有两个相应的 IP 地址，其网络前缀必须是不同的。这种主机称为多归属主机(multihomed host)。由于一个路由器至少应当连接到两个网络，因此一个路由器至少应当有两个不同的 IP 地址。这好比一个建筑正好处在北京路和上海路的交叉口上，那么这个建筑就可以拥有两个门牌号码。例如，北京路 4 号和上海路 37 号。

(3) 按照互联网的观点，一个网络（或子网）是指具有相同网络前缀的主机的集合，因此，用转发器或交换机连接起来的若干个局域网仍为一个网络，因为这些局域网都具有同样的网络前缀。具有不同网络前缀的局域网必须使用路由器进行互连。

(4) 在 IP 地址中，所有分配到网络前缀的网络（不管是范围很小的局域网，还是可能覆盖很大地理范围的广域网）都是平等的。所谓平等，是指互联网同等对待每一个 IP 地址。

图 4-14 画出了三个局域网（LAN₁，LAN₂ 和 LAN₃）通过三个路由器（R₁，R₂ 和 R₃）互连构成的一个互连网络。其中局域网 LAN₂ 是由两个网段通过以太网交换机互连的。图中的小圆圈表示需要有一个 IP 地址。这是为了强调，IP 地址是标志一个主机连接在网络上的接口。如果我们把某条连接线断开，那么相应的 IP 地址也就不存在了。但通常为了方便，这

样的小圆圈可以不必画出。




图 4-14 需要 IP 地址的地方用小圆圈表示

我们应当注意到：

- 在同一个局域网上的主机或路由器的 IP 地址中的网络前缀必须是同样的，即必须具有同样的网络号。
- 图中的网络地址（用粗体字加下划线表示）里面的主机号必定是全 0。例如，LAN₁ 的网络地址 1.1.1.0/29 = 00000001 00000001 00000001 00000000，在二进制表示的 IP 地址中，前 29 位有下划线的数字是网络前缀，最后 3 位为主机号，是全 0。
- 图 4-14 中的所有设备都有自己的 MAC 地址（都未画出）。请注意，图中以太网交换机连线上画出的小圆圈，是主机或路由器的 IP 地址，并不是以太网交换机的 IP 地址。以太网交换机是链路层设备，只有 MAC 地址。
- 用以太网交换机（它只在链路层工作）连接的几个网段合起来仍然是一个局域网，只使用同样的网络前缀，例如 LAN₂。
- 路由器总是具有两个或两个以上的 IP 地址。即路由器每个接口的 IP 地址的网络前缀都不同。
- 当两个路由器直接相连时（例如通过一条租用线路），在连线两端的接口处，可以分配也可以不分配 IP 地址。如分配了 IP 地址，则这一段连线就构成了一种只包含一段线路的特殊“网络”（如图中的 N₁、N₂ 和 N₃）。之所以叫作“网络”，是因为它有 IP 地址。这种网络仅需两个 IP 地址，因此这里就使用了 /31 地址块。这种地址块专门为点对点链路的两端使用[RFC 3021]，主机号（只有 1 位）可以是 0 或 1。但为了节省 IP 地址资源，对于点对点链路构成的特殊“网络”，现在也常常不分配 IP 地址。通常把这样的特殊网络叫作无编号网络(unnumbered network)或匿名网络(anonymous network)[COME06]。

4.2.3 IP 地址与 MAC 地址

在学习 IP 地址时，很重要的一点就是要弄清主机的 IP 地址与 MAC 地址的区别。在局域网中，由于 MAC 地址已固化在网卡上的 ROM 中，因此常常将 MAC 地址称为硬件地址或物理地址。在本书中，物理地址、硬件地

扫一扫



视频讲解

址和 MAC 地址常常作为同义词出现。物理地址的反义词就是虚拟地址、软件地址或逻辑地址，IP 地址就属于这类地址。

图 4-15 说明了这两种地址的区别。从层次的角度看，MAC 地址是数据链路层使用的地址，而 IP 地址是网络层和以上各层使用的地址，是一种逻辑地址（称 IP 地址为逻辑地址是因为 IP 地址是用软件实现的）。



图 4-15 IP 地址与 MAC 地址的区别

在发送数据时，数据从高层下到低层，然后才到通信链路上传输。使用 IP 地址的 IP 数据报一旦交给数据链路层，就被封装成 MAC 帧。MAC 帧在传送时使用的源地址和目的地址都是 MAC 地址，这两个 MAC 地址都写在 MAC 帧的首部中。

连接在通信链路上的设备（主机或路由器）在收到 MAC 帧时，根据 MAC 帧首部中的 MAC 地址决定收下或丢弃。只有在剥去 MAC 帧的首部和尾部后把 MAC 层的数据上交给网络层后，网络层才能在 IP 数据报的首部中找到源 IP 地址和目的 IP 地址。

总之，IP 地址放在 IP 数据报的首部，而 MAC 地址则放在 MAC 帧的首部。在网络层和网络层以上使用的是 IP 地址，而数据链路层及以下使用的是 MAC 地址。在图 4-15 中，当 IP 数据报插入到数据链路层的 MAC 帧以后，整个的 IP 数据报就成为 MAC 帧的数据，因而在数据链路层看不见数据报的 IP 地址。

图 4-16(a)画的是三个局域网用两个路由器 R₁ 和 R₂ 互连起来。现在主机 H₁ 要和主机 H₂ 通信。这两台主机的 IP 地址分别是 IP₁ 和 IP₂，而它们的 MAC 地址分别为 MAC₁ 和 MAC₂。通信的路径是：H₁→经过 R₁ 转发→再经过 R₂ 转发→H₂。路由器 R₁ 因同时连接到两个局域网，因此它有两个 MAC 地址，即 MAC₃ 和 MAC₄。同理，路由器 R₂ 也有两个 MAC 地址 MAC₅ 和 MAC₆。

图 4-16(b)特别强调了 IP 地址与 MAC 地址所使用的位置的不同。表 4-4 归纳了这种区别。

表 4-4 图 4-16(b)中不同层次、不同区间的源地址和目的地址

	在网络层		在数据链路层	
	写入 IP 数据报首部的地址		写入 MAC 帧首部的地址	
	源地址	目的地址	源地址	目的地址
从 H ₁ 到 R ₁	IP ₁	IP ₂	MAC ₁	MAC ₃
从 R ₁ 到 R ₂	IP ₁	IP ₂	MAC ₄	MAC ₅
从 R ₂ 到 H ₂	IP ₁	IP ₂	MAC ₆	MAC ₂




图 4-16 从不同层次上看 IP 地址和 MAC 地址

这里要强调指出以下几点：

(1) 在 IP 层抽象的互联网上只能看到 IP 数据报。虽然 IP 数据报要经过路由器 R_1 和 R_2 的两次转发，但在它的首部中的源地址和目的地址始终分别是 IP_1 和 IP_2 。图中的数据报上写的“从 IP_1 到 IP_2 ”就表示前者是源地址而后者是目的地址。数据报中间经过的两个路由器的 IP 地址并不出现在 IP 数据报的首部中。

(2) 虽然在 IP 数据报首部有源站 IP 地址，但路由器只根据目的站的 IP 地址进行转发。

(3) 在局域网的链路层，只能看见 MAC 帧。IP 数据报被封装在 MAC 帧中。MAC 帧在不同网络上传送时，其 MAC 帧首部中的源地址和目的地址要发生变化，如图 4-16(b)所示。开始在 H_1 到 R_1 间传送时，MAC 帧首部中写的是从 MAC 地址 MAC_1 发送到 MAC 地址 MAC_3 ，路由器 R_1 收到此 MAC 帧后，在数据链路层，要剥去原来的 MAC 帧的首部和尾部。在转发时，在数据链路层，要重新添加上 MAC 帧的首部和尾部。这时首部中的源地址和目的地址分别变成为 MAC_4 和 MAC_5 。路由器 R_2 收到此帧后，再次更换 MAC 帧的首部和尾部，首部中的源地址和目的地址分别变成为 MAC_6 和 MAC_2 。MAC 帧的首部的这种变化，在上面的 IP 层上是看不见的。

(4) 尽管互连在一起的网络的 MAC 地址体系各不相同，但 IP 层抽象的互联网却屏蔽了这些很复杂的细节。只要我们在网络层上讨论问题，就能够使用统一的、抽象的 IP 地址研究主机和主机或路由器之间的通信。

以上这些概念是计算机网络的精髓所在，对这些重要概念务必仔细思考和掌握。

细心的读者会发现，还有两个重要问题没有解决：

- (1) 主机或路由器怎样知道应当在 MAC 帧的首部填入什么样的 MAC 地址？
- (2) 路由器中的转发表是怎样得出的？

第一个问题就是下一节所要讲的内容，而第二个问题将在后面的 4.5 节详细讨论。

4.2.4 地址解析协议 ARP

在实际应用中，我们经常会遇到这样的问题：已经知道了一个机器（主机或路由器）的 IP 地址，需要找出其相应的 MAC 地址。地址解析协议 ARP [RFC 826, STD37]就是用来解决这样的问题的。图 4-17 说明了协议 ARP 的作用。



视频讲解




图 4-17 协议 ARP 的作用

还有一个旧的协议叫作逆地址解析协议 RARP，它的作用是使只知道自己 MAC 地址的主机能够通过协议 RARP 找出其 IP 地址。现在的协议 DHCP（见第 6 章的 6.6 节）已经包含了协议 RARP 的功能。因此本书不再介绍协议 RARP。

下面就介绍协议 ARP 的要点。

我们知道，网络层使用的是 IP 地址，但在实际网络的链路上传送数据帧时，最终还是必须使用链路层的 MAC 地址。IP 地址和下面链路层的 MAC 地址之间由于格式不同而不存在简单的映射关系（例如，IP 地址有 32 位，而链路层的 MAC 地址是 48 位）。此外，在一个网络上可能经常会有新的主机加入进来，或撤走一些主机。更换网络适配器也会使主机的 MAC 地址改变（请注意，主机的 MAC 地址实际上就是其网络适配器的 MAC 地址）。地址解析协议 ARP 解决这个问题的方法是在主机的 ARP 高速缓存中存放一个从 IP 地址到 MAC 地址的映射表，并且这个映射表还经常动态更新（新增或超时删除）。

每一台主机都设有一个 ARP 高速缓存(ARP cache)，里面存有本局域网上的各主机和路由器的 IP 地址到 MAC 地址的映射表，这些都是该主机目前知道的一些 MAC 地址。那么主机怎样知道这些 MAC 地址呢？我们可以通过下面的例子来说明。

当主机 A 要向本局域网上的某台主机 B 发送 IP 数据报时，就先在其 ARP 高速缓存中查看有无主机 B 的 IP 地址。如有，就在 ARP 高速缓存中查出其对应的 MAC 地址，再把这个 MAC 地址写入 MAC 帧，然后通过局域网把该 MAC 帧发往此 MAC 地址。

也有可能查不到主机 B 的 IP 地址。这可能是主机 B 才入网，也可能是主机 A 刚刚加电，其高速缓存还是空的。在这种情况下，主机 A 就自动运行 ARP，然后按以下步骤找出主机 B 的 MAC 地址。

(1) ARP 进程在本局域网广播发送一个 ARP 请求分组（具体格式可参阅[COME06]的第 23 章）。图 4-18(a)是主机 A 广播发送 ARP 请求分组的示意图。ARP 请求分组的主要内容是：“我的 IP 地址是 209.0.0.5，MAC 地址是 00-00-C0-15-AD-18。我想知道 IP 地址为 209.0.0.6 的主机的 MAC 地址。”

(2) 在本局域网上的所有主机上运行的 ARP 进程都收到此 ARP 请求分组。

(3) 主机 B 的 IP 地址与 ARP 请求分组中要查询的 IP 地址一致，就收下这个 ARP 请求分组，并向主机 A 发送 ARP 响应分组，同时在这个 ARP 响应分组中写入自己的 MAC 地址。由于其余所有主机的 IP 地址都与 ARP 请求分组中要查询的 IP 地址不一致，因此都不理睬这个 ARP 请求分组，如图 4-18(b)所示。ARP 响应分组的主要内容是：“我的 IP 地址是 209.0.0.6，我的 MAC 地址是 08-00-2B-00-EE-0A。”请注意：虽然 ARP 请求分组是广播发送的，但 ARP 响应分组是普通的单播，即从一个源地址发送到一个目的地址。




图 4-18 地址解析协议 ARP 的工作原理

(4) 主机 A 收到主机 B 的 ARP 响应分组后，就在其 ARP 高速缓存中写入主机 B 的 IP 地址到 MAC 地址的映射。

当主机 A 向 B 发送数据报时，很可能以后不久主机 B 还要向 A 发送数据报，因而主机 B 也可能要向 A 发送 ARP 请求分组。为了减少网络上的通信量，主机 A 在发送其 ARP 请求分组时，就把自己的 IP 地址到 MAC 地址的映射写入 ARP 请求分组。当主机 B 收到 A 的 ARP 请求分组时，就把主机 A 的这一地址映射写入主机 B 自己的 ARP 高速缓存中。以后主机 B 向 A 发送数据报时就很方便了。

可见 ARP 高速缓存非常有用。如果不使用 ARP 高速缓存，那么任何一台主机只要进行一次通信，就必须在网络上用广播方式发送 ARP 请求分组，这就会使网络上的通信量大大增加。ARP 把已经得到的地址映射保存在高速缓存中，这样就使得该主机下次再和具有同样目的地址的主机通信时，可以直接从高速缓存中找到所需的 MAC 地址而不必再用广播方式发送 ARP 请求分组。

ARP 对保存在高速缓存中的每一个映射地址项目都设置生存时间（例如，10 ~ 20 分钟）。凡超过生存时间的项目就从高速缓存中删除掉。设置这种地址映射项目的生存时间是很重要的。设想有一种情况：主机 A 和 B 通信。A 的 ARP 高速缓存里保存有 B 的 MAC 地址，但 B 的网络适配器突然坏了，B 立即更换了一块，因此 B 的 MAC 地址就改变了。假

定 A 还要和 B 继续通信。A 在其 ARP 高速缓存中查找到 B 原先的 MAC 地址，并使用该 MAC 地址向 B 发送数据帧。但 B 原先的 MAC 地址已经失效了，因此 A 无法找到主机 B。但是过了一段不长的生存时间，A 的 ARP 高速缓存中已经删除了 B 原先的 MAC 地址，于是 A 重新广播发送 ARP 请求分组，又找到了 B。

请注意，ARP 用于解决同一个局域网上的主机或路由器的 IP 地址和 MAC 地址的映射问题。如果所要找的主机和源主机不在同一个局域网，例如，在前面的图 4-16 中，主机 H_1 就无法解析出另一个局域网上的主机 H_2 的 MAC 地址（实际上主机 H_1 也不需要知道远程主机 H_2 的 MAC 地址）。主机 H_1 发送给 H_2 的 IP 数据报首先需要通过主机 H_1 连接在同一个局域网上的路由器 R_1 来转发，因此主机 H_1 必须知道路由器 R_1 的 IP 地址。于是 H_1 使用 ARP 把路由器 R_1 的 IP 地址 IP_3 解析为 MAC 地址 MAC_3 ，然后把 IP 数据报传送到路由器 R_1 。以后， R_1 从转发表知道应把 IP 数据报转发到路由器 R_2 ，再使用 ARP 解析出 R_2 的 MAC 地址 MAC_5 ，把 IP 数据报转发到路由器 R_2 。路由器 R_2 用同样方法解析出目的主机 H_2 的 MAC 地址 MAC_2 ，使 IP 数据报最终交付主机 H_2 。

从 IP 地址到 MAC 地址的解析是自动进行的，主机的用户对这种地址解析过程是不知道的。只要主机或路由器要和本网络上的另一个已知 IP 地址的主机或路由器进行通信，协议 ARP 就会自动地把这个 IP 地址解析为链路层所需要的 MAC 地址，然后插入到 MAC 帧中。

下面我们归纳出使用 ARP 的四种典型情况（如图 4-19 所示）。




图 4-19 使用 ARP 的四种典型情况

(1) 发送方是主机（如 H_1 ），要把 IP 数据报发送到同一个网络上的另一台主机（如 H_2 ）。这时 H_1 发送 ARP 请求分组（在网络 N_1 上广播），找到目的主机 H_2 的 MAC 地址。

(2) 发送方是主机（如 H_1 ），要把 IP 数据报发送到另一个网络上的一台主机（如 H_3 或 H_4 ）。这时 H_1 发送 ARP 请求分组（在网络 N_1 上广播），找到 N_1 上的一个路由器 R_1 的 MAC 地址。剩下的工作由路由器 R_1 来完成。 R_1 要做的事情是下面的(3)或(4)。

(3) 发送方是路由器（如 R_1 ），要把 IP 数据报转发到与 R_1 连接在同一个网络 N_2 上的主机（如 H_3 ）。这时 R_1 发送 ARP 请求分组（在 N_2 上广播），找到目的主机 H_3 的 MAC 地址。

(4) 发送方是路由器（如 R_1 ），要把 IP 数据报转发到网络 N_3 上的一台主机（如 H_4 ）。 H_4 与 R_1 不是连接在同一个网络上的。这时 R_1 发送 ARP 请求分组（在 N_2 上广播），找到连接在 N_2 上的一个路由器 R_2 的 MAC 地址。剩下的工作由这个路由器 R_2 来完成。

在许多情况下需要多次使用 ARP，但这只是以上几种情况的反复使用而已。

有的读者可能会产生这样的问题：既然在网络链路上传送的帧最终是按照 MAC 地址找到目的主机的，那么为什么我们还要使用两种地址（IP 地址和 MAC 地址），而不直接使用 MAC 地址进行通信？只用一个 MAC 地址进行通信似乎可以免除使用 ARP。

这个问题必须弄清楚。

由于全世界存在着各式各样的网络，它们使用不同的 MAC 地址。要使这些异构网络

能够互相通信就必须进行非常复杂的 MAC 地址转换工作，因此由用户或用户主机来完成这项工作几乎是不可能的事。即使是对分布在全世界的以太网 MAC 地址进行寻址，也是极其困难的。然而 IP 编址把这个复杂问题解决了。连接到互联网的主机只需各自拥有一个 IP 地址，它们之间的通信就像连接在同一个网络上那样简单方便，即使必须多次调用 ARP 来找到 MAC 地址，但这个过程都是由计算机软件自动进行的，对用户来说是看不见的。

因此，在虚拟的 IP 网络上用 IP 地址进行通信给广大的计算机用户带来了很大的方便。

4.2.5 IP 数据报的格式

IP 数据报的格式说明协议 IP 都具有什么功能。在协议 IP 的标准中，描述首部格式的宽度是 32 位（即 4 字节）。图 4-20 是 IP 数据报的完整格式 [RFC 791, STD5]。



图 4-20 IP 数据报的格式

从图 4-20 可看出，一个 IP 数据报由首部和数据两部分组成。首部的前一部分长度是固定的，共 20 字节，是所有 IP 数据报必须具有的。在首部的固定部分的后面是一些可选字段，其长度是可变的。下面介绍首部各字段的意义。

1. IP 数据报首部的固定部分中的各字段

(1) 版本 占 4 位，指协议 IP 的版本。通信双方使用的协议 IP 的版本必须一致。这里讨论的协议 IP 版本号为 4（即 IPv4）。关于 IPv6（即版本 6 的协议 IP），我们将在后面的 4.5 节讨论。

(2) 首部长度 占 4 位，可表示的最大十进制数值是 15。请注意，首部长度字段所表示数的单位是 32 位字长（1 个 32 位字长是 4 字节）。因为 IP 首部的固定部分是 20 字节，因此首部长度字段的最小值是 5（即二进制表示的首部长度是 0101）。而当首部长度字段为最大值 1111 时（即十进制的 15），就表明首部长度达到最大值——15 个 32 位字长，即 60 字节。当 IP 分组的首部长度不是 4 字节的整数倍时，必须利用最后的填充字段加以填充。因此 IP 数据报的数据部分永远在 4 字节的整数倍时开始，这样在实现协议 IP 时较为方便。首部长度限制为 60 字节的缺点是有时可能不够用，但这样做是希望用户尽量减少开销。最常用的首部长度是 20 字节，不使用任何可选字段。

(3) 区分服务 占 8 位, 用来获得更好的服务。这个字段在旧标准中叫作**服务类型**, 但实际上一直没有被使用过。1998 年 IETF 把这个字段改名为**区分服务 DS (Differentiated Services)**。只有在使用区分服务时, 这个字段才起作用 (见 8.4.4 节)。在一般的情况下都不使用这个字段[RFC 2474, RFC 3168, RFC 3260]。

(4) 总长度 总长度指首部和数据之和的长度, 单位为字节。总长度字段为 16 位, 因此数据报的最大长度为 $2^{16} - 1 = 65535$ 字节。然而实际上传送这样长的数据报在现实中是极少遇到的。

我们知道, 在 IP 层下面的每一种数据链路层协议都规定了一个数据帧中的**数据字段的最大长度**, 这称为**最大传送单元 MTU (Maximum Transfer Unit)**。当一个 IP 数据报封装成链路层的帧时, 此数据报的总长度 (即首部加上数据部分) 一定不能超过下面的数据链路层所规定的 MTU 值。例如, 最常用的以太网就规定其 MTU 值是 1500 字节。若所传送的数据报长度超过数据链路层的 MTU 值, 就必须把过长的数据报进行分片处理。

虽然使用尽可能长的 IP 数据报会使传输效率得到提高 (这样每一个 IP 数据报中首部长度占数据报总长度的比例就会小些), 但数据报短些也有好处。IP 数据报越短, 路由器转发的速度就越快。为此, 协议 IP 规定, 在互联网中所有的主机和路由器必须能够接受长度不超过 576 字节的数据报。这是假定上层交下来的数据长度有 512 字节 (合理的长度), 加上最长的 IP 首部 60 字节, 再加上 4 字节的富余量, 就得到 576 字节。当主机需要发送长度超过 576 字节的数据报时, 应当先了解一下, 目的主机能否接受所要发送的数据报长度。否则, 就要进行分片。

在进行分片时 (见后面的“片偏移”字段), 数据报首部中的“总长度”字段是指分片后的每一个分片的首部长度与该分片的数据长度的总和。

(5) 标识(identification) 占 16 位。IP 软件在存储器中维持一个计数器, 每产生一个数据报, 计数器就加 1, 并将此值赋给标识字段。但这个“标识”并不是序号, 因为 IP 是无连接服务, 数据报不存在按序接收的问题。当数据报由于长度超过网络的 MTU 而必须分片时, 这个标识字段的值就被复制到所有的数据报片的标识字段中。相同的标识字段的值使分片后的各数据报片最后能正确地重装成为原来的数据报。

(6) 标志(flag) 占 3 位, 但目前只有两位有意义。

- 标志字段中的最低位记为 **MF (More Fragment)**。MF = 1 即表示后面“还有分片”的数据报。MF = 0 表示这已是若干数据报片中的最后一个。
- 标志字段中间的一位记为 **DF (Don't Fragment)**, 意思是“不能分片”。只有当 DF = 0 时才允许分片。

(7) 片偏移 占 13 位。片偏移指出: 较长的分组在分片后, 某片在原分组中的相对位置。也就是说, 相对于用户数据字段的起点, 该片从何处开始。片偏移以 8 个字节为偏移单位。这就是说, 除最后一个数据报片外, 其他每个分片的长度一定是 8 字节 (64 位) 的整数倍。

下面举一个例子。

【例 4-1】 一个数据报的总长度为 3820 字节, 其数据部分为 3800 字节长 (使用固定首部), 需要分片为长度不超过 1420 字节的数据报片。因固定首部长度为 20 字节, 因此每个数据报片的数据部分长度不能超过 1400 字节。于是分为 3 个数据报片, 其数据部分的长度分别为 1400、1400 和 1000 字节。原始数据报首部被复制为各数据报片的首部, 但必须修

改有关字段的值。图 4-21 给出分片后得出的结果（请注意片偏移的数值）。




图 4-21 数据报的分片举例

表 4-5 是本例中数据报首部与分片有关的字段中的数值，其中标识字段的值是任意给定的（12345）。具有相同标识的数据报片在目的站就可无误地重装成原来的数据报。

表 4-5 IP 数据报首部中与分片有关的字段中的数值

	总长度	标识	MF	DF	片偏移
原始数据报	3820	12345	0	0	0
数据报片 1	1420	12345	1	0	0
数据报片 2	1420	12345	1	0	175
数据报片 3	1020	12345	0	0	350

现在假定数据报片 2 经过某个网络时还需要再进行分片，即划分为数据报片 2-1（携带数据 800 字节）和数据报片 2-2（携带数据 600 字节）。那么这两个数据报片的总长度、标识、MF、DF 和片偏移分别为：820, 12345, 1, 0, 175；620, 12345, 1, 0, 275。

(8) 生存时间 占 8 位，生存时间字段常用的英文缩写是 TTL (Time To Live)，表明这是数据报在网络中的寿命。由发出数据报的源点设置这个字段。其目的是防止无法交付的数据报无限制地在互联网中兜圈子（例如从路由器 R_1 转发到 R_2 ，再转发到 R_3 ，然后又转发到 R_1 ），因而白白消耗网络资源。最初的设计以秒作为 TTL 值的单位。每经过一个路由器时，就把 TTL 减去数据报在路由器所消耗掉的一段时间。若数据报在路由器消耗的时间小于 1 秒，就把 TTL 值减 1。当 TTL 值减为零时，就丢弃这个数据报。

然而随着技术的进步，路由器处理数据报所需的时间不断在缩短，一般都远远小于 1 秒，后来就把 TTL 字段的功能改为“跳数限制”（但名称不变）。路由器在每次转发数据报之前就把 TTL 值减 1。若 TTL 值减小到零，就丢弃这个数据报，不再转发。因此，现在 TTL 的单位不再是秒，而是跳数。TTL 的意义是指明数据报在互联网中至多可经过多少个路由器。显然，数据报能在互联网中经过的路由器的最大数值是 255。若把 TTL 的初始值设置为 1，就表示这个数据报只能在本局域网中传送。因为这个数据报一传送到局域网上的某个路由器，在被转发之前 TTL 值就减小到零，所以会被这个路由器丢弃。

(9) 协议 占 8 位，协议字段指出此数据报携带的数据使用何种协议，以便使目的主机的 IP 层知道应将数据部分上交给哪个协议进行处理。

常用的一些协议和相应的协议字段值如下[W-IANA]^①：

协议名	ICMP	IGMP	IP ^②	TCP	EGP	IGP	UDP	IPv6	ESP	AH	ICMP-IPv6	OSPF
协议字段值	1	2	4	6	8	9	17	41	50	51	58	89

(10) **首部检验和** 占 16 位。这个字段只检验数据报的首部，但不包括数据部分。这是因为数据报每经过一个路由器，路由器都要重新计算一下首部检验和（一些字段，如生存时间、标志、片偏移等都可能发生变化）。不检验数据部分可减少计算的工作量。为了进一步减少计算检验和的工作量，IP 首部的检验和不采用复杂的 CRC 检验码而采用下面的简单计算方法：在发送方，先把 IP 数据报首部划分为许多 16 位字的序列，并把检验和字段置零。用反码算术运算^③把所有 16 位字相加后，将得到的和的反码写入检验和字段。接收方收到数据报后，把首部的所有 16 位字再使用反码算术运算相加一次。将得到的和取反码，即得出接收方检验和的计算结果。若首部未发生任何变化，则此结果必为 0，于是就保留这个数据报；否则即认为出差错，并将此数据报丢弃。图 4-22 说明了 IP 数据报首部检验和的计算过程。




图 4-22 IP 数据报首部检验和的计算过程

(11) **源地址** 占 32 位。发送 IP 数据报的主机的 IP 地址。

(12) **目的地址** 占 32 位。接收 IP 数据报的主机的 IP 地址。

① 注：原来如协议字段值这样的数值都是由互联网赋号管理机构 IANA 负责指派，并公布在有关的 RFC 文档中的。IANA 由美国政府建立，开始由 Jon Postel 负责管理。由于 Jon Postel 于 1998 年去世，同时也由于互联网的商业化和国际化，许多国家希望由一个新的、私营的、非营利的国际公司——互联网名称与数字地址分配机构 ICANN [W-ICANN] 取代 IANA。但后来 ICANN 并没有取代 IANA，而是保留了 IANA，并且和 IANA 进行了分工。因此现在就出现了 IANA/ICANN 或 ICANN/IANA 这样的写法。这两个机构都负责 IP 地址和一些重要参数的管理。现在有关互联网的重要参数已经不在 RFC 文档公布[RFC 3232]，而改为在网址 www.iana.org 上查询在线的数据库。从 2016 年起，开始进行 IANA 的管理权逐步向 ICANN 转移的工作。

② 注：这里的 IP 表示特殊的 IP 数据报——IP 数据报再封装到 IP 数据报中（IP Encapsulation within IP）。

③ 注：两个数进行二进制反码求和的运算很简单。它的规则是从低位到高位逐列进行计算。0 和 0 相加是 0，0 和 1 相加是 1，1 和 1 相加是 0 但要产生一个进位 1，加到下一列。若最高位相加后产生进位，则最后得到的结果要在最低位加 1。请注意，反码（one's complement）和补码（two's complement）是不一样的。

2. IP 数据报首部的可变部分

IP 数据报首部的可变部分就是一个选项字段。选项字段用来支持排错、测量以及安全措施，内容很丰富。此字段的长度可变，从 1 字节到 40 字节不等，取决于所选择的项目。某些选项项目只需要 1 字节，它只包括 1 字节的选项代码。而有些选项需要多个字节，这些选项一个个拼接起来，中间不需要有分隔符，最后用全 0 的填充字段补齐为 4 字节的整数倍。

增加首部的可变部分是为了增加 IP 数据报的功能，但这同时也使得 IP 数据报的首部长度成为可变的。这就增加了每一个路由器处理数据报的开销。实际上这些选项很少被使用。很多路由器都不考虑 IP 首部的选项字段，因此新的 IP 版本 IPv6 就把 IP 数据报的首部长度做成固定的了。这里就不讨论这些选项的细节了。有兴趣的读者可参阅 RFC 791。

4.3 IP 层转发分组的过程

4.3.1 基于终点的转发

我们在图 4-7 中已经描述了分组在互联网中逐跳转发的概念。分组在互联网上传送和转发是基于分组首部中的目的地址的，因此这种转发方式称为**基于终点的转发**。

因此，分组每到达一个路由器，路由器就根据分组中的终点（目的地址）查找转发表，然后就得知下一跳应当到哪一个路由器。

但是，路由器中的转发表却不是按目的 IP 地址来直接查出下一跳路由器的。这是因为互联网中的主机数目实在太大了。如果用目的地址直接查找转发表，那么这种结构的转发表就会非常庞大，使得查找过程非常之慢。这样的转发表也就没有实用价值了。因此必须想办法压缩转发表的大小。

我们知道，32 位的 IP 地址是由两级组成的。前一部分是前缀，表示网络，后一部分表示主机。所以可以把查找目的主机的方法变通一下，即不是直接查找目的主机，而是先查找目的网络（网络前缀），在找到了目的网络之后，就把分组在这个网络上直接交付目的主机。由于互联网上的网络数远远小于主机数，这样就可以大大压缩转发表的大小，加速分组在路由器中的转发。这就是基于终点的转发过程。

读者可能还会想到一个问题，就是分组首部中没有地方可以用来指明“下一跳路由器的 IP 地址”，那么待转发的分组又怎样能够找到下一跳路由器呢？

当路由器收到一个待转发的分组，在从转发表得出下一跳路由器的 IP 地址后，不是把这个地址填入分组首部，而是送交数据链路层的网络接口软件。网络接口软件负责把下一跳路由器的 IP 地址转换成 MAC 地址（必须使用 ARP），并将此 MAC 地址放在链路层的 MAC 帧的首部，然后利用这个 MAC 地址传送到下一跳路由器的链路层，再取出 MAC 帧的数据部分，交给网络层。由此可见，当发送一连串的分组时，上述的这种查找转发表、调用 ARP 解析出 MAC 地址、把 MAC 地址写入 MAC 帧的首部等过程，都是必须做的（当然都是由机器自动完成的）。

那么，能不能在转发表中不使用 IP 地址而直接使用 MAC 地址呢？不行。我们一定要弄清楚，使用抽象的 IP 地址，本来就是为了隐蔽各种底层网络的复杂性而便于分析和研究问题，这样就不可避免地要付出些代价，例如在选择路由时多了一些开销。但反过来，如果

扫一扫



视频讲解

在转发表中直接使用 MAC 地址，那就会带来更多的麻烦，甚至无法找到对方的机器。

下面用具体例子来说明分组的转发过程。

【例 4-2】 图 4-23 中有三个子网通过两个路由器互连在一起。主机 H_1 发送出一个分组，其目的地址是 128.1.2.132。现在源主机是 H_1 而目的主机是 H_2 。试讨论分组怎样从源主机传送到目的主机。




图 4-23 源主机 H_1 向目的地址 H_2 发送分组

【解】 主机 H_1 首先必须确定：目的主机是否连接在本网络上？如果是，那么问题很简单，就直接交付，根本不需要利用路由器；如果不是，就间接交付，把分组发送给连接在本网络上的路由器，以后要做的事情都由这个路由器来处理。

主机 H_1 先把要发送的分组的地址和本网络 N_1 的子网掩码按位进行 AND 运算，得出运算结果。如果运算结果等于本网络 N_1 的前缀，就表明目的主机连接在本网络上；否则，就必须把分组发送到路由器 R_1 ，由路由器 R_1 完成后续的任务。

由于采用了 CIDR 记法，转发表中给出的都是网络前缀，而没有明显给出子网掩码。其实只要细心观察斜线后面的数字，就可知道相应的子网掩码。例如，/26 的子网掩码就是点分十进制的 255.255.255.192。现在，要发送的分组的地址是 128.1.2.132，本网络的掩码是 26 个 1，后面有 6 个 0。如图 4-24(a)所示，按位 AND 运算的结果是 128.1.2.128，不等于本网络 N_1 的前缀。这说明目的主机没有连接在本网络上。源主机 H_1 必须把分组发送给路由器 R_1 ，让路由器 R_1 根据其转发表来处理这个分组。

		128	.	1	.	2	.	132
(a)	目的主机 IP 地址	10000000	00000001	00000010	10000100			
	128.1.2.192/26的掩码	11111111	11111111	11111111	11000000			
	按位 AND 运算	10000000	00000001	00000010	10000000			
	得出结果	128	.	1	.	2	.	128 /26
		128	.	1	.	2	.	132
(b)	目的主机 IP 地址	10000000	00000001	00000010	10000100			
	128.1.2.128/26的掩码	11111111	11111111	11111111	11000000			
	按位 AND 运算	10000000	00000001	00000010	10000000			
	得出结果	128	.	1	.	2	.	128 /26

图 4-24 目的地址和本网络的子网掩码按位进行 AND 运算

路由器 R₁ 的部分转发表已在图 4-23 右上方给出了。转发表中第 1 列就是“前缀匹配”，这是因为查找转发表的过程就是寻找前缀匹配的过程。

现在先检查路由器 R₁ 的转发表中的第 1 行。

源主机 H₁ 要发送的分组的地址是 128.1.2.132。本网络 128.1.2.192/26 的前缀有 26 位，因此本网络的掩码是 26 个 1，后面是 6 个 0。目的地址和子网掩码按位 AND 运算的结果是 128.1.2.128/26（见图 4-24(a)）。很明显，AND 运算结果与转发表第 1 行的前缀不匹配。

接着检查路由器 R₁ 的转发表中的第 2 行。运算结果是 128.1.2.128/26，如图 4-24(b) 所示。这个结果和转发表第 2 行的前缀相匹配。因此按照转发表第 2 行指出的，在网络 N₂ 上进行分组的直接交付（通过路由器 R₁ 的接口 1）。这时路由器 R₁ 调用 ARP，解析出目的主机 H₂ 的 MAC 地址，再封装成链路层的帧，直接交付连接在本网络 N₂ 上的目的主机 H₂。

如果按照同样的方法，检查路由器 R₁ 的转发表中的第 3 行，不难得出不匹配的结果。

从以上例子可看出，查找转发表的过程就是逐行寻找前缀匹配的过程。我们再看下一个例子。

4.3.2 最长前缀匹配

【例 4-3】假定在图 4-25 的例子中，路由器 R₁ 收到一个目的地址为 128.1.24.1 的分组，请给出分组的转发接口。请注意，公司 B 包含三个子网，但这些网络前缀并没有出现在路由器 R₁ 的转发表中。这是因为公司 B 采用了路由聚合，把三个子网的所有地址聚合为一个网络前缀 128.1.24.0/22。




图 4-25 分组交给路由器 R₁ 进行转发

【解】我们把进入路由器 R₁ 的分组的地址分别和路由器 R₁ 的转发表第 1 行、第 2 行子网掩码进行按位 AND 运算。运算结果都是“匹配”（建议读者自行验算一下）。那么，哪一个结果是正确的呢？现在就来分析这个问题。

网络前缀 128.1.24.0/22 可以划分为 4 个更小的 /24 前缀（图 4-26）。其中的一个前缀 128.1.24.0/24 分配给公司 A，另外 3 个前缀分配给公司 B。公司 B 把得到的 3 个前缀聚合成一个更大的前缀 128.1.24.0/22，作为路由器 R₁ 的转发表中的一个项目。请注意，这个前缀和原来的前缀在形式上是一样的，但实际的区别是很大的：在图 4-26 左边的网络前缀中包含地址 128.1.24.1，但公司 B 的聚合后的网络前缀则不包含这个地址。因此在本例中，即分组应当从接口 1 转发到公司 A。

那么为什么地址 128.1.24.1 不在公司 B 的聚合前缀 128.1.24.0/22 中，但匹配运算的结果却是匹配呢？这是因为在转发表中的项目 128.1.24.0/22 并未说明是由哪几个子网聚合而成的。



扫一扫

视频讲解




图 4-26 公司 A 和 B 分到的前缀

十分明显，进入路由器 R_1 的分组的地址 128.1.24.1 处于公司 A 拥有的地址范围中，而不在公司 B 的地址范围内。分组应当通过接口 1 转发到公司 A。

为了减少路由器 R_1 中的项目数，公司 B 采用了地址聚合，把三个地址块聚合为一个地址块 128.1.24.0/22。这个聚合后得出的前缀和图中左边所示的前缀在形式上是一样的。这样就导致图 4-26 所示的出现和两个网络前缀都匹配的现象。

我们可以注意到，现在公司 B 三个地址块得出的聚合地址块是 128.1.24.0/22，但如果公司 B 只分到两个地址块 128.1.25.0/24 和 128.1.26.0/24，那么其聚合地址块仍然是 128.1.24.0/22。如果把公司 A 和公司 B 的地址块都聚合起来，得出的聚合地址块还是 128.1.24.0/22。这样的地址聚合可以发生在路由器 R_2 中。

因此，在采用 CIDR 编址时，如果一个分组在转发表中可以找到多个匹配的前缀，那么就应当选择前缀最长的一个作为匹配的前缀。这个原则称为最长前缀匹配(longest prefix match)。网络前缀越长，其地址块就越小，因而路由就越具体(more specific)。为了更加迅速地查找转发表，可以按照前缀的长短，把前缀最长的排在第 1 行，然后按前缀长短的顺序往下排列。用这种方法从第 1 行前缀最长的开始查找，只要检查到匹配的，就不必再继续往下查找，可以立即结束查找。

实际的转发表有时还可能增加两种特殊的路由，就是主机路由和默认路由。

主机路由(host route)又叫作**特定主机路由**，这是对特定目的主机的 IP 地址专门指明的一个路由。采用特定主机路由可使网络管理人员更方便地控制网络和测试网络，同时也可在需要考虑某种安全问题时采用这种特定主机路由。在对网络的连接或转发表进行排错时，指明到某一台主机的特殊路由就十分有用。假定这个特定主机的点分十进制 IP 地址是 a.b.c.d，那么在转发表中对应于主机路由的网络前缀就是 a.b.c.d/32。我们知道，/32 表示的子网掩码是 32 个 1。实际的网络不可能使用 32 位的前缀，因为没有主机号的 IP 地址是没有实际意义的。但这个特殊的前缀却可以用在转发表中。不难看出，32 个 1 的子网掩码和 IP 地址 a.b.c.d 按位进行 AND 运算后，得出的结果必定是 a.b.c.d，也就是说，找到了匹配。这时就把收到的分组转发到转发表所指出的下一跳。主机路由在转发表中都放在最前面。

还有一种特殊路由是**默认路由(default route)**。这就是不管分组的最终目的网络在哪里，都由指定的路由器 R 来处理。这在网络只有很少的对外连接时非常有用。在实际的转发表中，用一个特殊前缀 0.0.0.0/0 来表示默认路由。这个前缀的掩码是全 0 (/0 表示网络前缀是 0 位，因此掩码是 32 个 0)。用全 0 的掩码和任何目的地址进行按位 AND 运算，结果一定是全 0，即必然是和转发表中的 0.0.0.0/0 相匹配的。这时就按照转发表的指示，把分组送交下一跳路由器 R 来处理（即间接交付）。

综上所述，可归纳出**分组转发算法**如下（假定转发表按照前缀的长短排列，把前缀长的放在前面）：

(1) 从收到的分组的首部提取目的主机的 IP 地址 D (即目的地址)。

(2) 若查找到有特定主机路由 (目的地址为 D)，就按照这条路由的下一跳转发分组；否则从转发表中下一行 (也就是前缀最长的一行) 开始检查，执行(3)。

(3) 把这一行的子网掩码与目的地址 D 按位进行 AND 运算。

若运算结果与本行的前缀匹配，则查找结束，按照“下一跳”所指出的进行处理 (或直接交付本网络上的目的主机，或通过指定接口发送到下一跳路由器)。

否则，若转发表还有下一行，则对下一行进行检查，重新执行(3)。

否则，执行(4)。

(4) 若转发表中有一个默认路由，则按照指明的接口，把分组传送到指明的默认路由器；否则，报告转发分组出错。

可以用一个简单的比喻来说明查找转发表和转发分组的过程。例如，从家门口开车到机场，但没有地图，不知道应当走哪条路线。好在每一个道路岔口都有一个警察可以询问。因此，每到一个岔口 (相当于到了一个路由器)，就问：“到机场应当朝哪个方向走？” (相当于查找转发表)。该警察并不告诉你去机场的详细路径。他仅仅指出到机场途经的下一个警察位置的方向。其回答可能是：“向左转方向走。”你左转到了下一个岔口，再询问警察，回答可能是：“直行。”这样，每到一个岔口，就询问下一步走的方向。这样，在没有地图的情况下，我们最终也可以到达目的地——机场。

顺便指出，在过去使用分类地址时，不存在最长前缀匹配的问题。在转发表中，不会出现目的地址和转发表中的两行或两行以上的网络地址匹配的情况。

4.3.3 使用二叉线索查找转发表

使用 CIDR 后，由于不知道目的网络的前缀，使转发表的查找过程变得更加复杂了。当转发表的项目数很大时，怎样设法缩短转发表的查找时间就成为一个非常重要的问题。例如，连接路由器的线路的速率为 10 Gbit/s，而分组的平均长度为 2000 bit，那么路由器就应当平均每秒钟能够处理 500 万个分组 (常记为 5 Mpps)。或者说，路由器处理一个分组的平均时间只有 200 ns ($1 \text{ ns} = 10^{-9} \text{ s}$)。因此，查找每一个路由所需的时间是非常短的。可见在转发表中必须使用很好的数据结构和先进的快速查找算法，这一直是人们积极研究的热门课题。

对无分类编址的转发表的最简单的查找算法就是对所有可能的前缀进行循环查找，从最长的前缀开始查找。例如，给定一个目的地址。对每一个可能的网络前缀，进行目的地址和子网掩码的按位 AND 运算，得出一个网络前缀，然后逐行查找转发表中的网络前缀。所找到的最长匹配就对应于要查找的路由。

这种最简单的算法的明显缺点就是查找的次数太多。最坏的情况是转发表中没有这个路由。在这种情况下，算法仍要进行 32 次 (第 1 次用 32 位的前缀查找转发表中所有的行，第 2 次用 31 位的前缀查找所有的行，这样一直查找下去)。

为了进行更加有效的查找，通常是把无分类编址的转发表存放在一种层次的数据结构中，然后自上而下地按层次进行查找。这里最常用的就是**二叉线索(binary trie)**^①，它是一种

① 注：线索(trie)来自 retrieval (检索)，读音与“try”相同。

4.4 网际控制报文协议 ICMP

为了更有效地转发 IP 数据报和提高交付成功的机会，在网际层使用了网际控制报文协议 ICMP (Internet Control Message Protocol) [RFC 792, STD5]。ICMP 允许主机或路由器报告差错情况和提供有关异常情况的报告。ICMP 是互联网的标准协议。但 ICMP 不是高层协议（看起来好像是高层协议，因为 ICMP 报文装在 IP 数据报中，作为其中的数据部分），而是 IP 层的协议。ICMP 报文作为 IP 层数据报的数据，加上数据报的首部，组成 IP 数据报发送出去。ICMP 报文格式如图 4-28 所示。




图 4-28 ICMP 报文的格式

4.4.1 ICMP 报文的种类

ICMP 报文有两种，即 ICMP 差错报告报文和 ICMP 询问报文。

ICMP 报文的前 4 字节是统一的格式，共有三个字段：类型、代码和校验和。接着的 4 字节的内容与 ICMP 的类型有关。最后面是数据字段，其长度取决于 ICMP 的类型。表 4-6 给出了几种常用的 ICMP 报文类型。

表 4-6 几种常用的 ICMP 报文类型

ICMP 报文种类	类型的值	ICMP 报文的类型
差错报告报文	3	终点不可达
	11	时间超过
	12	参数问题
	5	改变路由(Redirect)
询问报文	8 或 0	回送(Echo)请求或回送回答
	13 或 14	时间戳(Timestamp)请求或时间戳回答

ICMP 标准在不断更新。已不再使用的 ICMP 报文有：“信息请求与回答报文”“地址掩码请求与回答报文”“路由器请求与通告报文”以及“源点抑制报文”[RFC 6633]。

ICMP 报文的代码字段用于进一步区分某种类型中的几种不同情况。校验和字段用来检验整个 ICMP 报文。我们应当还记得，IP 数据报首部的校验和并不检验 IP 数据报的内容，因此不能保证经过传输的 ICMP 报文不产生差错。

表 4-6 给出的 ICMP 差错报告报文共有四种，即：

- (1) 终点不可达 当路由器或主机不能交付数据报时就向源点发送终点不可达报文。



(2) **时间超过** 当路由器收到生存时间为零的数据报时，除丢弃该数据报外，还要向源点发送时间超过报文。当终点在预先规定的时间内不能收到一个数据报的全部数据报片时，就把已收到的数据报片都丢弃，并向源点发送时间超过报文。

(3) **参数问题** 当路由器或目的主机收到的数据报的首部中有的字段的值不正确时，就丢弃该数据报，并向源点发送参数问题报文。

(4) **改变路由（重定向）** 路由器把改变路由报文发送给主机，让主机知道下次应将数据报发送给另外的路由器（也就是说，找到了更好的路由）。

下面对改变路由报文进行简短的解释。我们知道，在互联网的主机中也要有一个转发表。当主机要发送数据报时，首先查找主机自己的转发表，看应当从哪一个接口把数据报发送出去。在互联网中主机的数量远大于路由器的数量，出于效率的考虑，这些主机不和连接在网络上的路由器定期交换路由信息。在主机刚开始工作时，一般都在转发表中设置一个默认路由器的 IP 地址。不管数据报要发送到哪个目的地址，都一律先把数据报传送给这个默认路由器，而这个默认路由器知道到每一个目的网络的最佳路由（通过和其他路由器交换路由信息）。如果默认路由器发现主机发往某个目的地址的数据报的最佳路由应当经过网络上的另一个路由器 R，就用改变路由报文把这情况告诉主机。于是，该主机就在其转发表中增加一个项目：到某某目的地址应经过路由器 R（而不是默认路由器）。

所有的 ICMP 差错报告报文中的数据字段都具有同样的格式（如图 4-29 所示）。把收到的需要进行差错报告的 IP 数据报的首部和数据字段的前 8 个字节提取出来，作为 ICMP 报文的数据字段。再加上相应的 ICMP 差错报告报文的前 8 个字节，就构成了 ICMP 差错报告报文。提取收到的数据报的数据字段前 8 个字节是为了得到运输层的端口号（对于 TCP 和 UDP）以及运输层报文的发送序号（对于 TCP）。这些信息对源点通知高层协议是有用的（端口的作用将在 5.1.3 节中介绍）。整个 ICMP 报文作为 IP 数据报的数据字段发送给源点。




图 4-29 ICMP 差错报告报文的数据字段的内容

下面是不应发送 ICMP 差错报告报文的几种情况：

- 对 ICMP 差错报告报文，不再发送 ICMP 差错报告报文。
- 对第一个分片的数据报片的所有后续数据报片，都不发送 ICMP 差错报告报文。
- 对具有多播地址的数据报，都不发送 ICMP 差错报告报文。
- 对具有特殊地址（如 127.0.0.0 或 0.0.0.0）的数据报，不发送 ICMP 差错报告报文。

常用的 ICMP 询问报文有两种，即：

(1) **回送请求或回送回答** ICMP 回送请求报文是由主机或路由器向一个特定的目的

主机发出的询问。收到此报文的主机必须给源主机或路由器发送 ICMP 回送回答报文。这种询问报文用来测试目的站是否可达以及了解其有关状态。

(2) 时间戳请求或时间戳回答 在 ICMP 时间戳请求报文发出后, 就能够收到对方响应的 ICMP 时间戳回答报文。利用在报文中记录的时间戳 (如报文的发送时间和接收时间), 发送方很容易计算出当前网络的往返时延。

4.4.2 ICMP 的应用举例

ICMP 的一个重要应用就是分组网间探测 **PING** (Packet InterNet Groper), 用来测试两台主机之间的连通性。PING 使用了 ICMP 回送请求与回送回答报文。PING 是应用层直接使用网络层 ICMP 的一个例子。它没有通过运输层的 TCP 或 UDP。

Windows 操作系统的用户可在接入互联网后转入 MS DOS (点击“开始”, 点击“运行”, 再键入“cmd”)。看见屏幕上的提示符后, 就键入“ping hostname”(这里的 hostname 是要测试连通性的主机名或它的 IP 地址), 按回车键后就可看到结果。

图 4-30 给出了从南京的一台 PC 到新浪网的邮件服务器 mail.sina.com.cn 的连通性的测试结果。PC 一连发出 4 个 ICMP 回送请求报文。如果邮件服务器 mail.sina.com.cn 正常工作而且响应这个 ICMP 回送请求报文 (有的主机为了防止恶意攻击就不理睬外界发送过来的这种报文), 那么它就发回 ICMP 回送回答报文。由于往返的 ICMP 报文上都有时间戳, 因此很容易得出往返时间。最后显示出的是统计结果: 发送到哪个机器 (IP 地址), 发送的、收到的和丢失的分组数 (但不给出分组丢失的原因), 以及往返时间的最小值、最大值和平均值。从得到的结果可以看出, 第三个测试分组丢失了。

```
C:\Documents and Settings\XXR>ping mail.sina.com.cn

Pinging mail.sina.com.cn [202.108.43.230] with 32 bytes of data:

Reply from 202.108.43.230: bytes=32 time=368ms TTL=242
Reply from 202.108.43.230: bytes=32 time=374ms TTL=242
Request timed out.
Reply from 202.108.43.230: bytes=32 time=374ms TTL=242

Ping statistics for 202.108.43.230:
    Packets: Sent = 4, Received = 3, Lost = 1 (25% loss),
    Approximate round trip times in milli-seconds:
        Minimum = 368ms, Maximum = 374ms, Average = 372ms
```

图 4-30 用 PING 测试主机的连通性

另一个非常有用的应用是 traceroute (这是 UNIX 操作系统中的命令), 用来跟踪一个分组从源点到终点的路径。在 Windows 操作系统中这个命令是 tracert。下面简单介绍这个命令的工作原理。

traceroute 从源主机向目的主机发送一连串的 IP 数据报, 数据报中封装的是无法交付的 UDP 用户数据报^①。第一个数据报 P_1 的生存时间 TTL 设置为 1。当 P_1 到达路径上的第一个

^① 注: 无法交付的 UDP 用户数据报使用了非法的端口号 (见下一章 5.2.2 节)。

路由器 R_1 时, 路由器 R_1 先收下它, 接着把 TTL 的值减 1。由于 TTL 等于零了, 因此 R_1 就把 P_1 丢弃, 并向源主机发送一个 ICMP 时间超过差错报告报文。

源主机接着发送第二个数据报 P_2 , 并把 TTL 设置为 2。 P_2 先到达路由器 R_1 , R_1 收下后把 TTL 减 1 再转发给路由器 R_2 。 R_2 收到 P_2 时 TTL 为 1, 但减 1 后 TTL 变为零了。 R_2 就丢弃 P_2 , 并向源主机发送一个 ICMP 时间超过差错报告报文。这样一直继续下去。当最后一个数据报刚刚到达目的主机时, 数据报的 TTL 是 1。主机不转发数据报, 也不把 TTL 值减 1。但因 IP 数据报中封装的是无法交付的运输层的 UDP 用户数据报, 因此目的主机要向源主机发送 ICMP 终点不可达差错报告报文 (见 5.2.2 节)。

这样, 源主机达到了自己的目的, 因为这些路由器和最后目的主机发来的 ICMP 报文正好给出了源主机想知道的路由信息——到达目的主机所经过的路由器的 IP 地址, 以及到达其中的每一个路由器的往返时间。图 4-31 是从南京的一个 PC 向新浪网的邮件服务器 mail.sina.com.cn 发出 tracert 命令后所获得的结果。图中每一行有三个时间出现, 是因为对应于每一个 TTL 值, 源主机要发送三次同样的 IP 数据报。

我们还应注意到, 从原则上讲, IP 数据报经过的路由器越多, 所花费的时间也会越长。但从图 4-31 可看出, 有时正好相反。这是因为互联网的拥塞程度随时都在变化, 也很难预料到。因此, 完全有这样的可能: 经过更多的路由器反而花费更短的时间。

```
C:\Documents and Settings\XXR>tracert mail.sina.com.cn

Tracing route to mail.sina.com.cn [202.108.43.230]
over a maximum of 30 hops:

  1  24 ns    24 ns    23 ns    222.95.172.1
  2  23 ns    24 ns    22 ns    221.231.204.129
  3  23 ns    22 ns    23 ns    221.231.206.9
  4  24 ns    23 ns    24 ns    202.97.27.37
  5  22 ns    23 ns    24 ns    202.97.41.226
  6  28 ns    28 ns    28 ns    202.97.35.25
  7  50 ns    50 ns    51 ns    202.97.36.86
  8  308 ns   311 ns   310 ns    219.158.32.1
  9  307 ns   305 ns   305 ns    219.158.13.17
 10 164 ns   164 ns   165 ns    202.96.12.154
 11 322 ns   320 ns  2988 ns    61.135.148.50
 12 321 ns   322 ns   320 ns   freenail43-230.sina.com [202.108.43.230]

Trace complete.
```

图 4-31 用 tracert 命令获得目的主机的路由信息

4.5 IPv6

协议 IP 是互联网的核心协议。现在使用的协议 IP (即 IPv4) 是在 20 世纪 70 年代末期设计的。互联网经过几十年的飞速发展, 在 2011 年 2 月 3 日, IANA 开始停止向地区互联网注册机构 RIR 分配 IPv4 地址, 因为 IPv4 地址已经全部耗尽了。不久, 各地区互联网地址分配机构也相继宣布地址耗尽。我国在 2014 年至 2015 年也逐步停止了向新用户和应用分配 IPv4 地址, 同时全面开始商用部署 IPv6。

解决 IP 地址耗尽的根本措施就是采用具有更大地址空间的新版本的 IP, 即 IPv6。经过多年的研究和试验, 2017 年 7 月终于发布了 IPv6 的正式标准[RFC 8200, STD86]。