

个结点不传输的概率。一个给定结点传输的概率是 p ；剩余结点不传输的概率是 $(1 - p)^{N-1}$ 。因此，一个给定结点成功传送的概率是 $p(1 - p)^{N-1}$ 。因为有 N 个结点，任意一个结点成功传送的概率是 $Np(1 - p)^{N-1}$ 。

因此，当有 N 个活跃结点时，时隙 ALOHA 的效率是 $Np(1 - p)^{N-1}$ 。为了获得 N 个活跃结点的最大效率，我们必须求出使这个表达式最大化的 p^* 。（对这个推导的一个大体描述参见课后习题。）而且对于大量活跃结点，为了获得最大效率，当 N 趋于无穷时，我们取 $Np^*(1 - p^*)^{N-1}$ 的极限。（同样参见课后习题。）在完成这些计算之后，我们会发现这个协议的最大效率为 $1/e = 0.37$ 。这就是说，当有大量结点有很多帧要传输时，则（最多）仅有 37% 的时隙做有用的工作。因此该信道有效传输速率不是 R bps，而仅为 $0.37R$ bps！相似的分析还表明 37% 的时隙是空闲的，26% 的时隙有碰撞。试想一个蹩脚的网络管理员购买了一个 100Mbps 的时隙 ALOHA 系统，希望能够使用网络在大量的用户之间以总计速率如 80Mbps 来传输数据。尽管这个信道能够以信道的全速 100Mbps 传输一个给定的帧，但从长时间范围看，该信道的成功吞吐量将小于 37Mbps。

2. ALOHA

时隙 ALOHA 协议要求所有的结点同步它们的传输，以在每个时隙开始时开始传输。第一个 ALOHA 协议 [Abramson 1970] 实际上是一个非时隙、完全分散的协议。在纯 ALOHA 中，当一帧首次到达（即一个网络层数据报在发送结点从网络层传递下来），结点立刻将该帧完整地传输进广播信道。如果一个传输的帧与一个或多个传输经历了碰撞，这个结点将立即（在完全传输完它的碰撞帧之后）以概率 p 重传该帧。否则，该结点等待一个帧传输时间。在此等待之后，它则以概率 p 传输该帧，或者以概率 $1 - p$ 在另一个帧时间等待（保持空闲）。

为了确定纯 ALOHA 的最大效率，我们关注某个单独的结点。我们的假设与在时隙 ALOHA 分析中所做的相同，取帧传输时间为时间单元。在任何给定时间，某结点传输一个帧的概率是 p 。假设该帧在时刻 t_0 开始传输。如在图 5-11 中所示，为了使这帧能成功地传输，在时间间隔 $[t_0 - 1, t_0]$ 中不能有其他结点开始传输。这种传输将与结点 i 的帧传输起始部分相重叠。所有其他结点在这个时间间隔不开始传输的概率是 $(1 - p)^{N-1}$ 。类似地，当结点 i 在传输时，其他结点不能开始传输，因为这种传输将与结点 i 传输的后面部分相重叠。所有其他结点在这个时间间隔不开始传输的概率也是 $(1 - p)^{N-1}$ 。因此，一个给定的结点成功传输一次的概率是 $p(1 - p)^{2(N-1)}$ 。通过与时隙 ALOHA 情况一样来取极限，我们求得纯 ALOHA 协议的最大效率仅为 $1/(2e)$ ，这刚好是时隙 ALOHA 的一半。这就是完全分散的 ALOHA 协议所要付出的代价。




图 5-11 纯 ALOHA 中的干扰传输

历史事件

Norm Abramson 和 ALOHAnet

Norm Abramson 是一名有博士学位的工程师，对冲浪运动很有激情，而且对分组交换很感兴趣。这些兴趣的结合使他在 1969 年到了夏威夷大学。夏威夷是由许多巨大的岛屿组成的，安装和运营基于陆地的网络是困难的。当不冲浪的时候，Abramson 思考如何设计一种在无线信道上完成分组交互的网络。他设计的网络有一个中心主机和几个分散在夏威夷各个岛上的二级结点。该网络有两个信道，每个信道使用不同的频段。下行链路信道从中心主机向二级主机广播分组；上行信道从二级主机向中心主机发送分组。除了发送信息分组，中心主机还在下行信道上对从二级主机成功接收到的每个分组发送确认。

因为二级主机以分散的方式传输分组，在上行信道上出现碰撞是不可避免的。这个观察导致 Abramson 设计了如本章所描述的那种纯 ALOHA 协议。在 1970 年，通过不断从 ARPA 获得的资助，Abramson 将他的 ALOHAnet 与 ARPAnet 相连。Abramson 的工作是很重要的，不仅因为它是无线分组网络的第一个例子，而且因为它激励了 Bob Metcalfe。几年之后，Metcalfe 修改了 ALOHA 协议，创造了 CSMA/CD 协议和以太网局域网。

3. 载波侦听多路访问 (CSMA)

在时隙和纯 ALOHA 中，一个结点传输的决定独立于连接到这个广播信道上的其他结点的活动。特别是，一个结点不关心在它开始传输时是否有其他结点碰巧在传输，而且即使有另一个结点开始干扰它的传输也不会停止传输。在我们的鸡尾酒会类比中，ALOHA 协议非常像一个粗野的聚会客人，他喋喋不休地讲话而不顾是否其他人在说话。作为人类，我们有人类的协议，它要求我们不仅要更为礼貌，而且在谈话中要减少与他人“碰撞”的时间，从而增加我们谈话中交流的数据量。具体而言，有礼貌的人类谈话有两个重要的规则：

- 说话之前先听。如果其他人正在说话，等到他们说完话为止。在网络领域中，这被称为载波侦听 (carrier sensing)，即一个结点在传输前先听信道。如果来自另一个结点的帧正向信道上发送，结点则等待直到检测到一小段时间没有传输，然后开始传输。
- 如果与他人同时开始说话，停止说话。在网络领域中，这被称为碰撞检测 (collision detection)，即当一个传输结点在传输时一直在侦听此信道。如果它检测到另一个结点正在传输干扰帧，它就停止传输，在重复“侦听 - 当空闲时传输”循环之前等待一段随机时间。

这两个规则包含在载波侦听多路访问 (Carrier Sense Multiple Access, CSMA) 和具有碰撞检测的 CSMA (CSMA with Collision Detection, CSMA/CD) 协议族中 [Kleinrock 1975b; Metcalfe 1976; Lam 1980; Rom 1990]。人们已经提出了 CSMA 和 CSMA/CD 的许多变种。这里，我们将考虑一些 CSMA 和 CSMA/CD 最重要的和基本的特性。

关于 CSMA 你可能要问的第一个问题是，如果所有的结点都进行载波侦听了，为什么当初会发生碰撞？毕竟，某结点无论何时侦听到另一个结点在传输，它都会停止传输。对于这个问题的答案最好能够用时空图来说明 [Molle 1987]。图 5-12 显示了连接到一个线

状广播总线的 4 个结点 (A、B、C、D) 的时空图。横轴表示每个结点在空间的位置；纵轴表示时间。

在时刻 t_0 ，结点 B 侦听到信道是空闲的，因为当前没有其他结点在传输。因此结点 B 开始传输，沿着广播媒体在两个方向上传播它的比特。图 5-12 中 B 的比特随着时间的增加向下传播，这表明 B 的比特沿着广播媒体传播所实际需要的时间不是零（虽然以接近光的速度）。在时刻 t_1 ($t_1 > t_0$)，结点 D 有一个帧要发送。尽管结点 B 在时刻 t_1 正在传输，但 B 传输的比特还没有到达 D，因此 D 在 t_1 侦听到信道空闲。根据 CSMA 协议，从而 D 开始传输它的帧。一个短暂的时间之后，B 的传输开始在 D 干扰 D 的传输。从图 5-12 中可以看出，显然广播信道的端到端信道传播时延 (channel propagation delay)（信号从一个结点传播到另一个结点所花费的时间）在决定其性能方面起着关键的作用。该传播时延越长，载波侦听结点不能侦听到网络中另一个结点已经开始传输的机会就越大。

4. 具有碰撞检测的载波侦听多路访问 (CSMA/CD)

在图 5-12 中，结点没有进行碰撞检测；即使已经出现了碰撞，B 和 D 都将继续完整地传输它们的帧。当某结点执行碰撞检测时，一旦它检测到碰撞将立即停止传输。图 5-13 表示了和图 5-12 相同的情况，只是这两个结点在检测到碰撞后很短的时间内都放弃了它们的传输。显然，在多路访问协议中加入碰撞检测，通过不传输一个无用的、（由来自另一个结点的帧干扰）损坏的帧，将有助于改善协议的性能。





图 5-12 发生碰撞传输的两个 CSMA 结点的时空图

图 5-13 具有碰撞检测的 CSMA

在分析 CSMA/CD 协议之前，我们现在从与广播信道相连的适配器（在结点中）的角度总结它的运行：

- 1) 适配器从网络层一条获得数据报，准备链路层帧，并将其放入帧适配器缓存中。
- 2) 如果适配器侦听到信道空闲（即无信号能量从信道进入适配器），它开始传输帧。在另一方面，如果适配器侦听到信道正在忙，它将等待，直到侦听到没有信号能量时才开始传输帧。
- 3) 在传输过程中，适配器监视来自其他使用该广播信道的适配器的信号能量的存在。

4) 如果适配器传输整个帧而未检测到来自其他适配器的信号能量, 该适配器就完成了该帧。在另一方面, 如果适配器在传输时检测到来自其他适配器的信号能量, 它中止传输 (即它停止了传输帧)。

5) 中止传输后, 适配器等待一个随机时间量, 然后返回步骤 2。

等待一个随机 (而不是固定) 的时间量的需求是明确的——如果两个结点同时传输帧, 然后这两个结点等待相同固定的时间量, 它们将持续碰撞下去。但选择随机回退时间的时间间隔多大为好呢? 如果时间间隔大而碰撞结点数量小, 在重复“侦听 - 当空闲时传输”的步骤前, 结点很可能等待较长的时间 (使信道保持空闲)。在另一方面, 如果时间间隔小而碰撞结点数量大, 很可能选择的随机值将几乎相同, 传输结点将再次碰撞。我们希望时间间隔应该这样: 当碰撞结点数量较少时, 时间间隔较短; 当碰撞结点数量较大时, 时间间隔较长。

用于以太网以及 DOCSIS 电缆网络多路访问协议 [DOCSIS 2011] 中的二进制指数后退 (binary exponential backoff) 算法, 简练地解决了这个问题。特别是, 当传输一个给定帧时, 在该帧经历了一连串的 n 次碰撞后, 结点随机地从 $\{0, 1, 2, \dots, 2^n - 1\}$ 中选择一个 K 值。因此, 一个帧经历的碰撞越多, K 选择的间隔越大。对于以太网, 一个结点等待的实际时间量是 $K \cdot 512$ 比特时间 (即发送 512 比特进入以太网所需时间量的 K 倍), n 能够取的最大值在 10 以内。

我们看一个例子。假设一个适配器首次尝试传输一个帧, 并在传输中它检测到碰撞。然后该结点以概率 0.5 选择 $K=0$, 以概率 0.5 选择 $K=1$ 。如果该结点选择 $K=0$, 则它立即开始侦听信道。如果这个适配器选择 $K=1$, 它在开始“侦听 - 当空闲时传输”。周期前等待 512 比特时间 (例如对于 100Mbps 以太网来说为 5.12 毫秒)。在第 2 次碰撞之后, 从 $\{0, 1, 2, 3\}$ 中等概率地选择 K 。在第 3 次碰撞之后, 从 $\{0, 1, 2, 3, 4, 5, 6, 7\}$ 中等概率地选择 K 。在 10 次或更多次碰撞之后, 从 $\{0, 1, 2, \dots, 1023\}$ 中等概率地选择 K 。因此从中选择 K 的集合长度随着碰撞次数呈指数增长; 正是由于这个原因, 该算法被称为二进制指数后退。

这里我们还要注意到, 每次适配器准备传输一个新的帧时, 它要运行 CSMA/CD 算法。不考虑近期过去的时间内可能已经发生的任何碰撞。因此, 当几个其他适配器处于指数后退状态时, 有可能一个具有新帧的结点能够立刻插入一次成功的传输。

5. CSMA/CD 效率

当只有一个结点有一个帧发送时, 该结点能够以信道全速率进行传输 (例如 10Mbps、100Mbps 或者 1Gbps)。然而, 如果很多结点都有帧要发送, 信道的有效传输速率可能会小得多。我们将 CSMA/CD 效率 (efficiency of CSMA/CD) 定义为: 当有大量的活跃结点, 且每个结点有大量的帧要发送时, 帧在信道中无碰撞地传输的那部分时间在长期运行时间中所占的份额。为了给出效率的一个闭式的近似表示, 令 d_{prop} 表示信号能量在任意两个适配器之间传播所需的最大时间。令 d_{trans} 表示传输一个最大长度的以太网帧的时间 (对于 10Mbps 的以太网, 该时间近似为 1.2 毫秒)。CSMA/CD 效率的推导超出了本书的范围 (见 [Lam 1980] 和 [Bertsekas 1991])。这里我们只是列出下面的近似式:

$$\text{效率} = \frac{1}{1 + 5d_{\text{prop}}/d_{\text{trans}}}$$

从这个公式我们看到，当 d_{prop} 接近 0 时，效率接近 1。这和我们的直觉相符，如果传播时延是 0，碰撞的结点将立即中止而不会浪费信道。同时，当 d_{trans} 变得很大时，效率也接近于 1。这也和直觉相符，因为当一个帧取得了信道时，它将占有信道很长时间；因此信道在大多数时间都会有效地工作。

5.3.3 轮流协议

前面讲过多路访问协议的两个理想特性是：①当只有一个结点活跃时，该活跃结点具有 R bps 的吞吐量；②当有 M 个结点活跃时，每个活跃结点的吞吐量接近 R/M bps。ALOHA 和 CSMA 协议具备第一个特性，但不具备第二个特性。这激发研究人员创造另一类协议，也就是**轮流协议**（taking-turns protocol）。和随机接入协议一样，有几十种轮流协议，其中每一个协议又都有很多变种。这里我们要讨论两种比较重要的协议。第一种是**轮询协议**（polling protocol）。轮询协议要求这些结点之一要被指定为主结点。主结点以循环的方式轮询（poll）每个结点。特别是，主结点首先向结点 1 发送一个报文，告诉它（结点 1）能够传输的帧的最多数量。在结点 1 传输了某些帧后，主结点告诉结点 2 它（结点 2）能够传输的帧的最多数量。（主结点能够通过观察在信道上是否缺乏信号，来决定一个结点何时完成了帧的发送。）上述过程以这种方式继续进行，主结点以循环的方式轮询了每个结点。

轮询协议消除了困扰随机接入协议的碰撞和空时隙，这使得轮询取得高得多的效率。但是它也有一些缺点。第一个缺点是该协议引入了轮询时延，即通知一个结点“它可以传输”所需的时间。例如，如果只有一个结点是活跃的，那么这个结点将以小于 R bps 的速率传输，因为每次活跃结点发送了它最多数量的帧时，主结点必须依次轮询每一个非活跃的结点。第二个缺点可能更为严重，就是如果主结点有故障，整个信道都变得不可操作。

第二种轮流协议是**令牌传递协议**（token-passing protocol）。在这种协议中没有主结点。一个称为**令牌**（token）的小的特殊帧在结点之间以某种固定的次序进行交换。例如，结点 1 可能总是把令牌发送给结点 2，结点 2 可能总是把令牌发送给结点 3，而结点 N 可能总是把令牌发送给结点 1。当一个结点收到令牌时，仅当它有一些帧要发送时，它才持有这个令牌；否则，它立即向下一个结点转发该令牌。当一个结点收到令牌时，如果它确实有帧要传输，它发送最大数目的帧数，然后把令牌转发给下一个结点。令牌传递是分散的，并有很高的效率。但是它也有自己的一些问题。例如，一个结点的故障可能会使整个信道崩溃。或者如果一个结点偶然忘记了释放令牌，则必须调用某些恢复步骤使令牌返回到循环中来。经过多年，人们已经开发了许多令牌传递协议，包括光纤分布式数据接口（FDDI）协议 [Jain 1994] 和 IEEE 802.5 令牌环协议 [IEEE 802.5 2012]，每一种都必须解决这些和其他一些棘手的问题。

5.3.4 DOCSIS：用于电缆因特网接入的链路层协议

在前面 3 小节中，我们已经学习了 3 大类多路访问协议：信道划分协议、随机接入协议和轮流协议。这里的电缆接入网将作为一种很好的学习案例，因为在电缆接入网中我们将看到这三类多路访问协议中的每一种！

1.2.1 节讲过，一个电缆接入网通常在电缆网头端将几千个住宅电缆调制解调器与一个电缆调制解调器端接系统（Cable Modem Termination System, CMTS）连接。数据经电缆服务接口（Data-Over-Cable Service Interface, CMTS）规范（DOCSIS）[DOCSIS 2012] 定

义了电缆数据网络体系结构及其协议。DOCSIS 使用 FDM 将下行（CMTS 到调制解调器）和上行（调制解调器到 CMTS）网络段划分为多个频率信道。每个下行信道宽 6MHz，每个信道具有大约 40Mbps 吞吐量（尽管这种数据率在实践中很少在电缆调制解调器中见到）；每个上行信道具有 6.4MHz 的最大信道带宽，并且最大的上行吞吐量约为 30Mbps。每个上行和下行信道均为广播信道。CMTS 在下行信道中传输的帧被所有在信道上做接收的电缆调制解调器接收到；然而因为仅有单一的 CMTS 在下行信道上传输，不存在多路访问问题。但在上行方向，存在着多个有趣的技术挑战，因为多个电缆调制解调器共享到 CMTS 的相同上行信道（频率），因此能够潜在地出现碰撞。

如图 5-14 所示，每条上行信道被划分为时间间隔（类似于 TDM），每个时间间隔包含一序列微时隙，电缆调制解调器可在该微时隙中向 CMTS 传输。CMTS 显式地准许各个电缆调制解调器在特定的微时隙中进行传输。CMTS 在下行信道上通过发送称为 MAP 报文的控制报文，指定哪个电缆调制解调器（带有要发送的数据）能够在微时隙中传输由控制报文指定的时间间隔。由于微时隙明确分配给电缆调制解调器，故 CMTS 能够确保在微时隙中没有碰撞传输。




图 5-14 CMTS 和电缆调制解调器之间的上行和下行信道

但是 CMTS 一开始是如何知道哪个电缆调制解调器有数据要发送呢？通过让电缆调制解调器在专用于此目的的一组特殊的微时隙间隔内向 CMTS 发送微时隙请求帧来完成该任务，如图 5-14 所示。这些微时隙请求帧以随机接入方式传输，故可能相互碰撞。电缆调制解调器既不能侦听上行信道是否忙，也不能检测碰撞。相反，该电缆调制解调器如果没有在下一个下行控制报文中收到对请求分配的响应的話，就推断出它的微时隙请求帧经历了一次碰撞。当推断出一次碰撞，电缆调制解调器使用二进制指数回退将其微时隙请求帧延缓到以后的时隙重新发送。当在上行信道上有很少的流量，电缆调制解调器可能在名义上分配给微时隙请求帧的时隙内实际传输数据帧（因此避免不得不等待微时隙分配）。

因此，电缆接入网可作为应用多路访问协议（即 FDM、TDM、随机接入和集中分配时隙都用于一个网络中）的一个极好例子。

5.4 交换局域网

前面一节涉及了广播网络和多路访问协议，我们现在将注意力转向交换局域网。图 5-15

显示了一个交换局域网连接了 3 个部门，两台服务器和一台与 4 台交换机连接的路由器。因为这些交换机运行在链路层，所以它们交换链路层帧（而不是网络层数据报），不识别网络层地址，不使用如 RIP 或 OSPF 这样的路由选择算法来确定通过第 2 层交换机网络的路径。我们马上就会看到，它们使用链路层地址而不是 IP 地址来转发链路层帧通过交换机网络。我们首先以讨论链路层寻址（5.4.1 节）来开始对交换机局域网的学习。然后仔细学习著名的以太网协议（5.4.2 节）。在仔细学习链路层寻址和以太网后，我们将考察链路层交换机的工作方式（5.4.3 节），并随后考察通常是如何用这些交换机构建大规模局域网的（5.4.4 节）。




图 5-15 由 4 台交换机连接起来的某机构网络

5.4.1 链路层寻址和 ARP

主机和路由器具有链路层地址。现在你也许会感到惊讶，第 4 章中不是讲过主机和路由器也具有网络层地址吗？你也许会问：为什么我们在网络层和链路层都需要地址呢？除了描述链路层地址的语法和功能，在本节中我们希望明明白白地搞清楚两层地址都有用的原因，事实上这些地址是必不可少的。我们还将学习地址解析协议（ARP），该协议提供了将 IP 地址转换为链路层地址的机制。

1. MAC 地址

事实上，并不是主机或路由器具有链路层地址，而是它们的适配器（即网络接口）具有链路层地址。因此，具有多个网络接口的主机或路由器将具有与之相关联的多个链路层地址，就像它也具有与之相关联的多个 IP 地址一样。然而，重要的是注意到链路层交换机并不具有与它们的接口（这些接口是与主机和路由器相连的）相关联的链路层地址。这是因为链路层交换机的任务是在主机与路由器之间承载数据报；交换机透明地执行该项任务，这就是说，主机或路由器不必明确地将帧寻址到其间的交换机。图 5-16 中说明了这种情况。链路层地址有各种不同的称呼：LAN 地址（LAN address）、物理地址（physical

address) 或 MAC 地址 (MAC address)。因为 MAC 地址似乎是最为流行的术语, 所以我们此后就将链路层地址称为 MAC 地址。对于大多数局域网 (包括以太网和 802.11 无线局域网) 而言, MAC 地址长度为 6 字节, 共有 2^{48} 个可能的 MAC 地址。如图 5-16 所示, 这些 6 个字节地址通常用十六进制表示法, 地址的每个字节被表示为一对十六进制数。尽管 MAC 地址被设计为永久的, 但用软件改变一块适配器的 MAC 地址现在是可能的。然而, 对于本节的后面部分而言, 我们将假设某适配器的 MAC 地址是固定的。

MAC 地址的一个有趣性质是没有两块适配器具有相同的地址。考虑到适配器是由许多不同国家和地区的不同公司生产的, 这看起来似乎是件神奇之事。中国台湾生产适配器的公司如何能够保证与比利时生产适配器的公司使用不同的地址呢? 答案是 IEEE 在管理着该 MAC 地址空间。特别是, 当一个公司要生产适配器时, 它支付象征性的费用购买组成 2^{24} 个地址的一块地址空间。IEEE 分配这块 2^{48} 个地址的方式是: 固定一个 MAC 地址的前 24 比特, 让公司自己为每个适配器生成后 24 比特的唯一组合。

适配器的 MAC 地址具有扁平结构 (这与层次结构相反), 而且不论适配器到哪里用都不会变化。带有以太网接口的便携机总具有同样的 MAC 地址, 无论该计算机位于何方。具有 802.11 接口的一台智能手机总是具有相同的 MAC 地址, 无论该智能手机到哪里。与之形成对照的是, 前面说过的 IP 地址具有层次结构 (即一个网络部分和一个主机部分), 而且当主机移动时, 主机的 IP 地址需要改变, 即改变它所连接到的网络。适配器的 MAC 地址与人的社会保险号相似, 后者也具有扁平寻址结构, 而且无论人到哪里该号码都不会变化。IP 地址则与一个人的邮政地址相似, 它是有层次的, 无论何时当人搬家时, 该地址都必须改变。就像一个人可能发现邮政地址和社会保险号都有用那样, 一台主机具有一个网络层地址和一个 MAC 地址是有用的。

当某适配器要向某些目的适配器发送一个帧时, 发送适配器将目的适配器的 MAC 地址插入到该帧中, 并将该帧发送到局域网上。如我们马上要看到的那样, 一台交换机偶尔将一个入帧广播到它的所有接口。我们将在第 6 章中看到 802.11 也广播帧。因此一块适配器可以接收一个并非向它寻址的帧。这样, 当适配器接收到一个帧时, 将检查该帧中的目的 MAC 地址是否与它自己的 MAC 地址匹配。如果匹配, 该适配器提取出封装的数据报, 并将该数据报沿协议栈向上传递。如果不匹配, 该适配器丢弃该帧, 而不会向上传递该网络层数据报。所以, 仅当收到该帧时, 才会中断目的地。

然而, 有时某发送适配器确实要让局域网上所有其他适配器来接收并处理它打算发送的帧。在这种情况下, 发送适配器在该帧的目的地址字段中插入一个特殊的 MAC 广播地址 (broadcast address)。对于使用 6 字节地址的局域网 (例如以太网和 802.11) 来说, 广播地址是 48 个连续的 1 组成的字符串 (即以十六进制表示法表示的 FF-FF-FF-FF-FF-FF)。




图 5-16 与局域网相连的每个接口都有一个唯一的 MAC 地址

实践原则

保持各层独立

主机和路由器接口除了网络层地址之外还有 MAC 地址，这有如下几个原因。首先，局域网是为任意网络层协议而设计的，而不只是用于 IP 和因特网。如果适配器被指派 IP 地址而不是“中性的”MAC 地址的话，则适配器将不能够方便地支持其他网络层协议（例如，IPX 或者 DECnet）。其次，如果适配器使用网络层地址而不是 MAC 地址的话，网络层地址必须存储在适配器的 RAM 中，并且在每次适配器移动（或加电）时要重新配置。另一种选择是在适配器中不使用任何地址，让每个适配器将它收到的每帧数据（通常是 IP 数据报）沿协议栈向上传递。然后网络层则能够核对网络地址层是否匹配。这种选择带来的一个问题是，主机将被局域网上传送的每个帧中断，包括被目的地是在相同广播局域网上的其他结点的帧中断。总之，为了使网络体系结构中各层次成为极为独立的构建模块，不同的层次需要有它们自己的寻址方案。我们现在已经看到 3 种类型的地址：应用层的主机名、网络层的 IP 地址以及链路层的 MAC 地址。

2. 地址解析协议

因为存在网络层地址（例如，因特网的 IP 地址）和链路层地址（即 MAC 地址），所以需要在它们之间进行转换。对于因特网而言，这是地址解析协议（Address Resolution Protocol, ARP）[RFC 826] 的任务。

为了理解对于诸如 ARP 这样协议的需求，考虑如图 5-17 所示的网络。在这个简单的例子中，每台主机和路由器有一个单一的 IP 地址和单一的 MAC 地址。与以往一样，IP 地址以点分十进制表示法表示，MAC 地址以十六进制表示法表示。为了便于讨论，我们在本节中将假设交换机广播所有帧；这就是说，无论何时交换机在一个接口接收一个帧，它将在其所有其他接口上转发该帧。在下一节中，我们将更为准确地解释交换机操作的过程。




图 5-17 局域网上的每个接口都有一个 IP 地址和一个 MAC 地址

现在假设 IP 地址为 222.222.222.220 的主机要向主机 222.222.222.222 发送 IP 数据报。在本例中，源和目的均位于相同的子网中（在 4.4.2 节中的寻址意义下）。为了发送数

据报，该源必须要向它的适配器不仅提供 IP 数据报，而且要提供目的主机 222. 222. 222. 222 的 MAC 地址。然后发送适配器将构造一个包含目的地的 MAC 地址的链路层帧，并把该帧发送进局域网。

在本节中要处理的重要问题是，发送主机如何确定 IP 地址为 222. 222. 222. 222 的目的主机的 MAC 地址呢？正如你也许已经猜想的那样，它使用 ARP。在发送主机中的 ARP 模块将取在相同局域网上的任何 IP 地址作为输入，然后返回相应的 MAC 地址。在眼下的这个例子中，发送主机 222. 222. 222. 220 向它的 ARP 模块提供了 IP 地址 222. 222. 222. 222，并且其 ARP 模块返回了相应的 MAC 地址 49-BD-D2-C7-56-2A。

因此我们看到了 ARP 将一个 IP 地址解析为一个 MAC 地址。在很多方面它和 DNS（在 2.5 节中研究过）类似，DNS 将主机名解析为 IP 地址。然而，这两种解析器之间的一个重要区别是，DNS 为在因特网中任何地方的主机解析主机名，而 ARP 只为在同一个子网上的主机和路由器接口解析 IP 地址。如果美国加利福尼亚州的一个结点试图用 ARP 为美国密西西比州的一个结点解析 IP 地址，ARP 将返回一个错误。

既然已经解释了 ARP 的用途，我们再来看看它是如何工作的。每台主机或路由器在其内存中具有一个 **ARP 表**（ARP table），这张表包含 IP 地址到 MAC 地址的映射关系。图 5-18 显示了在主机 222. 222. 222. 220 中可能看到的 ARP 表中的内容。该 ARP 表也包含一个寿命（TTL）值，它指示了从表中删除每个映射的时间。注意到这张表不必为该子网上的每台主机和路由器都包含一个表项；某些可能从来没有进入到该表中，某些可能已经过期。从一个表项放置到某 ARP 表中开始，一个表项通常的过期时间是 20 分钟。

IP 地址	MAC 地址	TTL
222. 222. 222. 221	88-B2-2F-54-1A-0F	13:45:00
222. 222. 222. 223	5C-66-AB-90-75-B1	13:52:00

图 5-18 在主机 222. 222. 222. 220 中的一个可能的 ARP 表

现在假设主机 222. 222. 222. 220 要发送一个数据报，该数据报要 IP 寻址到本子网上另一台主机或路由器。发送主机需要获得给定 IP 地址的目的主机的 MAC 地址。如果发送方的 ARP 表具有该目的结点的表项，这个任务是很容易完成的。但如果 ARP 表中当前没有该目的主机的表项，又该怎么办呢？特别是假设 222. 222. 222. 220 要向 222. 222. 222. 222 发送数据报。在这种情况下，发送方用 ARP 协议来解析这个地址。首先，发送方构造一个称为 **ARP 分组**（ARP packet）的特殊分组。一个 ARP 分组有几个字段，包括发送和接收 IP 地址及 MAC 地址。ARP 查询分组和响应分组都具有相同的格式。ARP 查询分组的目的是询问子网上所有其他主机和路由器，以确定对应于要解析的 IP 地址的那个 MAC 地址。

回到我们的例子上来，222. 222. 222. 220 向它的适配器传递一个 ARP 查询分组，并且指示适配器应该用 MAC 广播地址（即 FF-FF-FF-FF-FF-FF）来发送这个分组。适配器在链路层帧中封装这个 ARP 分组，用广播地址作为帧的目的地址，并将该帧传输进子网中。回想我们的社会保险号/邮政地址的类比，一次 ARP 查询等价于一个人在某公司（比方说 AnyCorp）一个拥挤的房间大喊：“邮政地址是加利福尼亚州帕罗奥图市 AnyCorp 公司 112 房间 13 室的那个人的社会保险号是什么？”包含该 ARP 查询的帧被子网上的所有其他适配器接收到，并且（由于广播地址）每个适配器都把在该帧中的 ARP 分组向上传递给 ARP 模块。这些 ARP 模块中的每个都检查它的 IP 地址是否与 ARP 分组中的目的 IP 地址

相匹配。与之匹配的一个给查询主机发送回一个带有所希望映射的响应 ARP 分组。然后查询主机 222.222.222.220 能够更新它的 ARP 表，并发送它的 IP 数据报，该数据报封装在一个链路层帧中，并且该帧的目的 MAC 就是对先前 ARP 请求进行响应的主机或路由器的 MAC 地址。

关于 ARP 协议有两件有趣的事情需要注意。首先，查询 ARP 报文是在广播帧中发送的，而响应 ARP 报文在一个标准帧中发送。在继续阅读之前，你应该思考一下为什么这样。其次，ARP 是即插即用的，这就是说，一个 ARP 表是自动建立的，即它不需要系统管理员来配置。并且如果某主机与子网断开连接，它的表项最终会从留在子网中的结点的表中删除掉。

学生们常常想知道 ARP 是一个链路层协议还是一个网络层协议。如我们所见，一个 ARP 分组封装在链路层帧中，因而在体系结构上位于链路层之上。然而，一个 ARP 分组具有包含链路层地址的字段，因而可认为是链路层协议，但它也包含网络层地址，因而也可认为是为网络层协议。所以，可能最好把 ARP 看成是跨越链路层和网络层边界两边的协议，即不完全符合我们在第 1 章中学习的简单的分层协议栈。现实世界协议就是这样复杂！

3. 发送数据报到子网以外

现在应该搞清楚当一台主机要向相同子网上的另一台主机发送一个数据报时 ARP 的操作过程。但是现在我们来看更复杂的情况，即当子网中的某主机要向子网之外（也就是跨越路由器的另一个子网）的主机发送网络层数据报的情况。我们在图 5-19 的环境中来讨论这个问题，该图显示了一个由一台路由器互联两个子网所组成的简单网络。




图 5-19 由一台路由器互联的两个子网

有关图 5-19 需要注意几件有趣的事情。每台主机仅有一个 IP 地址和一个适配器。但是，如第 4 章所讨论，一台路由器对它的每个接口都有一个 IP 地址。对路由器的每个接口，（在路由器中）也有一个 ARP 模块和一个适配器。在图 5-19 中的路由器有两个接口，所以它有两个 IP 地址、两个 ARP 模块和两个适配器。当然，网络中的每个适配器都有自己的 MAC 地址。

还要注意到子网 1 的网络地址为 111.111.111/24，子网 2 的网络地址为 222.222.222/24。因此，与子网 1 相连的所有接口都有格式为 111.111.111.xxx 的地址，与子网 2 相连的所有接口都有格式为 222.222.222.xxx 的地址。

现在我们考察子网 1 上的一台主机将向子网 2 上的一台主机发送数据报。特别是，假设主机 111.111.111.111 要向主机 222.222.222.222 发送一个 IP 数据报。和往常一样，发送主机向它的适配器传递数据报。但是，发送主机还必须向它的适配器指示一个适当的目的 MAC 地址。该适配器应该使用什么 MAC 地址呢？有人也许大胆猜测，这个适当的 MAC

地址就是主机 222.222.222.222 的适配器地址，即 49-BD-D2-C7-56-2A。然而，这个猜测是错误的！如果发送适配器要用那个 MAC 地址，那么子网 1 上所有的适配器都不会费心将该 IP 数据报传递到它的网络层，因为该帧的目的地址与子网 1 上所有适配器的 MAC 地址都将不匹配。这个数据报将只有死亡，到达数据报天国。

如果我们仔细地观察图 5-19，我们发现为了使一个数据报从 111.111.111.111 到子网 2 上的主机，该数据报必须首先发送给路由器接口 111.111.111.110，它是通往最终目的地路径上的第一跳路由器的 IP 地址。因此，对于该帧来说，适当的 MAC 地址是路由器接口 111.111.111.110 的适配器地址，即 E6-E9-00-17-BB-4B。但发送主机怎样获得 111.111.111.110 的 MAC 地址呢？当然是通过使用 ARP！一旦发送适配器有了这个 MAC 地址，它创建一个帧（包含了寻址到 222.222.222.222 的数据报），并把该帧发送到子网 1 中。在子网 1 上的路由器适配器看到该链路层帧是向它寻址的，因此把这个帧传递给路由器的网络层。万岁！该 IP 数据报终于被成功地从源主机移动到这台路由器了！但是我们的任务还没有结束。我们仍然要将该数据报从路由器移动到目的地。路由器现在必须决定该数据报要被转发的正确接口。如在第 4 章中所讨论的，这是通过查询路由器中的转发表来完成的。转发表告诉这台路由器该数据报要通过路由器接口 222.222.222.220 转发。然后该接口把这个数据报传递给它的适配器，适配器把该数据报封装到一个新的帧中，并且将帧发送进子网 2 中。这时，该帧的目的 MAC 地址确实是最终目的地 MAC 地址。路由器又是怎样获得这个目的地 MAC 地址的呢？当然是用 ARP 获得的！

用于以太网的 ARP 定义在 RFC 826 中。在 TCP/IP 指南 RFC 1180 中对 ARP 进行了很好的介绍。我们将在课后习题中更为详细地研究 ARP。

5.4.2 以太网

以太网几乎占领着现有的有线局域网市场。在 20 世纪 80 年代和 90 年代早期，以太网面临着来自其他局域网技术包括令牌环、FDDI 和 ATM 的挑战。多年来，这些其他技术中的一些成功地抓住了部分局域网市场份额。但是自从 20 世纪 70 年代中期发明以太网以来，它就不断演化和发展，并保持了它的支配地位。今天，以太网是到目前为止最流行的有线局域网技术，而且到可能预见的将来它可能仍保持这一位置。可以这么说，以太网对本地区域网的重要性就像因特网对全球联网所具有的地位那样。

以太网的成功有很多原因。首先，以太网是第一个广泛部署的高速局域网。因为它部署得早，网络管理员非常熟悉以太网（它的奇迹和它的奇思妙想），并当其他局域网技术问世时，他们不愿意转而用之。其次，令牌环、FDDI 和 ATM 比以太网更加复杂、更加昂贵，这就进一步阻碍了网络管理员改用其他技术。第三，改用其他局域网技术（例如 FDDI 和 ATM）的最引人注目的原因通常是这些新技术具有更高数据速率；然而以太网总是奋起抗争，产生了运行在相同或更高数据速率下的版本。20 世纪 90 年代初期还引入了交换以太网，这就进一步增加了它的有效数据速率。最后，由于以太网已经很流行了，所以以太网硬件（尤其是适配器和交换机）成为了一个普通商品，而且极为便宜。

Bob Metcalfe 和 David Boggs 在 20 世纪 70 年代中期发明初始的以太局域网。初始的以太局域网使用同轴电缆总线来互联结点。以太网的总线拓扑实际上从 20 世纪 80 年代到 90 年代中期一直保持不变。使用总线拓扑的以太网是一种广播局域网，即所有传输的帧传送到与该总线连接的所有适配器并被其处理。回忆一下，我们在 5.3.2 节中讨论了以太网的

具有二进制指数回退的 CSMA/CD 多路访问协议。

到了 20 世纪 90 年代后期，大多数公司和大学使用一种基于集线器的星形拓扑以太网安装替代了它们的局域网。在这种安装中，主机（和路由器）直接用双绞对铜线与一台集线器相连。集线器（hub）是一种物理层设备，它作用于各个比特而不是作用于帧。当表示一个 0 或一个 1 的比特到达一个接口时，集线器只是重新生成这个比特，将其能量强度放大，并将该比特向其他所有接口传输出去。因此，采用基于集线器的星形拓扑的以太网也是一个广播局域网，即无论何时集线器从它的一个接口接收到一个比特，它向其所有其他接口发送该比特的副本。特别是，如果某集线器同时从两个不同的接口接收到帧，将出现一次碰撞，生成该帧的结点必须重新传输该帧。

在 21 世纪早期，以太网又经历了一次重要的革命性变化。以太网安装继续使用星形拓扑，但是位于中心的集线器被交换机（switch）所替代。在本章后面我们将深入学习交换以太网。眼下我们仅知道交换机不仅是“无碰撞的”，而且也是名副其实的存储转发分组交换机就可以了；但是与运行在高至第 3 层的路由器不同，交换机仅运行在第 2 层。

1. 以太网帧结构

以太网帧如图 5-20 所示。通过仔细研究以太网的帧，我们能够学到许多有关以太网的知识。




图 5-20 以太网帧结构

为了将对以太网帧的讨论放到切实的环境中，考虑从一台主机向另一台主机发送一个 IP 数据报，且这两台主机在相同的以太局域网（例如，如图 5-17 所示的以太局域网）。（尽管以太网帧的负载是一个 IP 数据报，但我们注意到以太网帧也能够承载其他网络层分组。）设发送适配器（即适配器 A）的 MAC 地址是 AA-AA-AA-AA-AA-AA，接收适配器（即适配器 B）的 MAC 地址是 BB-BB-BB-BB-BB-BB。发送适配器在一个以太网帧中封装了一个 IP 数据报，并把该帧传递到物理层。接收适配器从物理层收到这个帧，提取出 IP 数据报，并将该 IP 数据报传递给网络层。我们现在在这种情况下考察如图 5-20 所示的以太网帧的 6 个字段：

- 数据字段（46 ~ 1500 字节）。这个字段承载了 IP 数据报。以太网的最大传输单元（MTU）是 1500 字节。这意味着如果 IP 数据报超过了 1500 字节，则主机必须将该数据报分片，如 4.4.1 节所讨论。数据字段的最小长度是 46 字节。这意味着如果 IP 数据报小于 46 字节，数据报必须被填充到 46 字节。当采用填充时，传递到网络层的数据包括 IP 数据报和填充部分。网络层使用 IP 数据报首部中的长度字段来去除填充部分。
- 目的地址（6 字节）。这个字段包含目的适配器的 MAC 地址，即 BB-BB-BB-BB-BB-BB。当适配器 B 收到一个以太网帧，帧的目的地址无论是 BB-BB-BB-BB-BB-BB，还是 MAC 广播地址，它都将该帧的数据字段的内容传递给网络层；如果它收到了具有任何其他 MAC 地址的帧，则丢弃之。
- 源地址（6 字节）。这个字段包含了传输该帧到局域网上的适配器的 MAC 地址，在本例中为 AA-AA-AA-AA-AA-AA。

- 类型字段（2 字节）。类型字段允许以太网复用多种网络层协议。为了理解这点，我们需要记住主机能够使用除了 IP 以外的其他网络层协议。事实上，一台给定的主机可以支持多种网络层协议，以对不同的应用采用不同的协议。因此，当以太网帧到达适配器 B，适配器 B 需要知道它应该将数据字段的内容传递给哪个网络层协议（即分解）。IP 和其他链路层协议（例如，Novell IPX 或 AppleTalk）都有它们各自的、标准化的类型编号。此外，ARP 协议（在上一节讨论过）有自己的类型编号，并且如果到达的帧包含 ARP 分组（即类型字段的值为十六进制的 0806），则该 ARP 分组将被多路分解给 ARP 协议。注意到该类型字段和网络层数据报中的协议字段、运输层报文段的端口号字段相类似；所有这些字段都是为了把一层中的某协议与上一层的某协议结合起来。
- CRC（4 字节）。如 5.2.3 节中讨论的那样，CRC（循环冗余检测）字段的目的是使得接收适配器（适配器 B）检测帧中是否引入了差错。
- 前同步码（8 字节）。以太网帧以一个 8 字节的前同步码（Preamble）字段开始。该前同步码的前 7 字节的值都是 10101010；最后一个字节是 10101011。前同步码字段的前 7 字节用于“唤醒”接收适配器，并且将它们的时钟和发送方的时钟同步。为什么这些时钟会不同步呢？记住适配器 A 的目的是根据以太局域网类型的不同，分别以 10Mbps、100Mbps 或者 1Gbps 的速率传输帧。然而，没有什么完美无缺的，因此适配器 A 不会以精确的额定速率传输帧；相对于额定速率总有一些漂移，局域网上的其他适配器不会预先知道这种漂移的。接收适配器只需通过锁定前同步码的前 7 字节的比特，就能够锁定适配器 A 的时钟。前同步码的第 8 个字节的最后两个比特（第一个出现的两个连续的 1）警告适配器 B，“重要的内容”就要到来了。

所有的以太网技术都向网络层提供无连接服务。这就是说，当适配器 A 要向适配器 B 发送一个数据报时，适配器 A 在一个以太网帧中封装该数据报，并且把该帧发送到局域网上，没有先与适配器 B 握手。这种第二层的无连接服务类似于 IP 的第三层数据报服务和 UDP 的第 4 层无连接服务。

以太网技术都向网络层提供不可靠服务（unreliable service）。特别是，当适配器 B 收到一个来自适配器 A 的帧，它对该帧执行 CRC 校验，但是当该帧通过 CRC 校验时它既不发送确认帧；而当该帧没有通过 CRC 校验时它也不发送否定确认帧。当某帧没有通过 CRC 校验，适配器 B 只是丢弃该帧。因此，适配器 A 根本不知道它传输的帧是否到达了 B 并通过了 CRC 校验。（在链路层）缺乏可靠的传输有助于使得以太网简单和便宜。但是它也意味着传递到网络层的数据报流能够有间隙。

如果由于丢弃了以太网帧而存在间隙，主机 B 上的应用也会看见这个间隙吗？如我们在第 3 章中学习的那样，这只取决于该应用是使用 UDP 还是使用 TCP。如果应用使用的是 UDP，则主机 B 中的应用的确会看到数据中的间隙。另一方面，如果应用使用的是 TCP，则主机 B 中的 TCP 将不会确认包含在丢弃帧中的数据，从而引起主机 A 的 TCP 重传。注意到当 TCP 重传数据时，数据最终将回到曾经丢弃它的以太网适配器。因此，从这种意义上来说，以太网的确重传了数据，尽管以太网并不知道它是正在传输一个具有全新数据的全新数据报，还是一个包含已经被传输过至少一次的数据的数据报。

历史事件

Bob Metcalfe 和以太网

作为 20 世纪 70 年代早期哈佛大学的一名博士生，Bob Metcalfe 在 MIT 从事 ARPAnet 的研究。在他学习期间，他还受到了 Abramson 有关 ALOHA 和随机接入协议工作的影响。在完成了他的博士学位，并在开始 Xerox Palo Alto 研究中心（Xerox PARC）的工作之前，他用 3 个月访问了 Abramson 和他在夏威夷大学的同事，获得了 ALOHAnet 的第一手资料。在 Xerox PARC，Metcalfe 受到了 Alto 计算机的影响，这种计算机在很多方面是 20 世纪 80 年代个人计算机的先驱。Metcalfe 看到了对这些计算机以一种不昂贵的方式组网的需求。因此，基于他在 APRAnet、ALOHAnet 和随机接入协议方面的知识，Metcalfe 和他的同事 David Boggs 一起发明了以太网。

Metcalfe 和 Boggs 的初始以太网运行速度为 2.94Mbps，连接长达一英里范围的多达 256 台主机。Metcalfe 和 Boggs 成功地使得 Xerox PARC 的大多数研究人员通过他们的 Alto 计算机互相通信。然后 Metcalfe 推进了 Xerox、Digital 和 Intel 联盟，创建了以太网作为一种 10Mbps 的以太网标准，该标准后被 IEEE 认可。Xerox 对以太网商业化没有表现出太多的兴趣。1979 年，Metcalfe 建立了自己的公司 3Com，它发展和商业化包括以太网技术在内的联网技术。特别是，3Com 在 20 世纪 80 年代早期为非常流行的 IBM PC 开发了以太网网卡并使之市场化。1990 年，Metcalfe 离开了 3Com，当时 3Com 有 2000 名员工和 4 亿美元的年收入。

2. 以太网技术

在以上的讨论中我们已经提到以太网，仿佛它有单一的协议标准似的。但事实上，以太网具有许多不同的特色，具有某种令人眼花缭乱的首字母缩写词，如 10BASE-T、10BASE-2、100BASE-T、1000BASE-LX 和 10GBASE-T。这些以及许多其他的以太网技术在多年中已经被 IEEE 802.3 CSMA/CD (Ethernet) 工作组标准化了 [IEEE 802.3 2012]。尽管这些首字母缩写词看起来眼花缭乱，实际上其中非常有规律性。首字母缩写词的第一部分指该标准的速率：10、100、1000 或 10G，分别代表 10Mbps、100Mbps、1000Mbps（或 1Gbps）和 10Gbps 以太网。“BASE”指基带以太网，这意味着该物理媒体仅承载以太网流量；几乎所有的 802.3 标准都适用于基带以太网。该首字母缩写词的最后一部分指物理媒体本身；以太网是链路层也是物理层的规范，并且能够经各种物理媒体（包括同轴电缆、铜线和光纤）承载。一般而言，“T”指双绞铜线。

从历史上讲，以太网最初被构想为一段同轴电缆。早期的 10BASE-2 和 10BASE-5 标准规定了在两种类型的同轴电缆之上的 10Mbps 以太网，每种标准都限制在 500 米长度之内。通过使用转发器（repeater）能够得到更长的运行距离，而转发器是一种物理层设备，它能在输入端接收信号并在输出端再生该信号。同轴电缆很好地对应于我们将作为一种广播媒体的以太网视图，即由一个接口传输的所有帧可在其他接口收到，并且以太网的 CSMA/CD 协议很好地解决了多路访问问题。结点直接附着在电缆上，万事大吉啦，我们有了一个局域网了！

多年来以太网已经经历了一系列演化步骤，今天的以太网非常不同于使用同轴电缆的

初始总线拓扑的设计。在今天大多数的安装中，结点经点对点的由双绞铜线或光纤线缆构成的线段与一台交换机相连，如图 5-15 至图 5-17 所示。

在 20 世纪 90 年代中期，以太网被标准化为 100Mbps，比 10Mbps 以太网快 10 倍。初始的以太网 MAC 协议和帧格式保留了下来，但更高速率的物理层被定义为用铜线（100BASE-T）和用光纤（100BASE-FX、100BASE-SX、100BASE-BX）。图 5-21 显示了这些不同的标准和共同的以太网 MAC 协议和帧格式。100Mbps 以太网用双绞线距离限制为 100 米，用光纤距离限制为几千米，允许把不同建筑物中的以太网交换机连接起来。




图 5-21 100Mbps 以太网标准：共同的链路层，不同的物理层

吉比特以太网是对极为成功的 10Mbps 和 100Mbps 以太网标准的扩展。吉比特以太网提供 1000Mbps 的总数据速率，与大量已经安装的以太网设备基础保持完全兼容。吉比特以太网的标准称为 IEEE 802.3z，它完成以下工作：

- 使用标准以太网帧格式（参见图 5-20），并且后向兼容 10BASE-T 与 100BASE-T 技术。这使得吉比特以太网和现已安装的以太网设备基础很容易集成。
- 允许点对点链路以及共享的广播信道。如前所述，点对点链路使用交换机，而广播信道使用集线器。在吉比特以太网术语中，集线器被称为“带缓存的分配器”。
- 使用 CSMA/CD 来共享广播信道。为了得到可接受的效率，结点之间的最大距离必须严格限制。
- 对于点对点信道，允许在两个方向上都以 1000Mbps 全双工操作。

吉比特以太网最初工作于光纤之上，现在能够工作在 5 类 UTP 线缆上。10Gbps 以太网（10GBASE-T）于 2007 年已被标准化了，可提供更高的以太局域网能力。

我们通过提出一个问题来结束有关以太网技术的讨论，这个问题开始可能会难倒你。在总线拓扑和基于集线器的星形拓扑技术时代，以太网很显然是一种广播链路（如 5.3 节所定义），其中多个结点同时传输时会出现帧碰撞。为了处理这些碰撞，以太网标准包括了 CSMA/CD 协议，该协议对于跨越一个小的地理半径的有线广播局域网特别有效。但是对于今天广为使用的以太网是基于交换机的星形拓扑，采用的是存储转发分组交换，是否还真正需要一种以太网 MAC 协议呢？如我们很快所见，交换机协调其传输，在任何时候决不会向相同的接口转发超过一个帧。此外，现代交换机是全双工的，这使得一台交换机和一个结点能够在同时向对方发送帧而没有干扰。换句话说，在基于交换机的以太局域网中，不会有碰撞，因此没有必要使用 MAC 协议了！

如我们所见，今天的以太网与 Metcalfe 和 Boggs 在 30 多年前构想的初始以太网有非常大的不同，即速度已经增加了 3 个数量级，以太网帧承载在各种各样的媒体之上，交换以太网已经成为主流，此时甚至连 MAC 协议也经常是不必要的了！所有这些还真正是以太网吗？答案当然是：“是的，根据定义如此。”然而，注意到下列事实是有趣的：通过所有

这些改变，的确还有一个历经 30 年保持未变的持久不变量，即以太网帧格式。也许这才是以太网标准的一个真正重要的特征。

5.4.3 链路层交换机

到目前为止，我们有意对交换机实际要做的工作以及它是怎样工作的含糊其辞。交换机的任务是接收入链路层帧并将它们转发到出链路；我们将在这一节中详细学习这种转发功能。我们将看到交换机自身对子网中的主机和路由器是透明的（transparent）；这就是说，某主机/路由器向另一个主机/路由器寻址一个帧（而不是向交换机寻址该帧），顺利地将该帧发送进局域网，并不知道某交换机将会接收该帧并将它转发到另一个结点。这些帧到达该交换机的任何输出接口之一的速率可能暂时会超过该接口的链路容量。为了解决这个问题，交换机输出接口设有缓存，这非常类似于路由器接口为数据报设有缓存。现在我们来仔细考察交换机运行的原理。

1. 交换机转发和过滤

过滤（filtering）是决定一个帧应该转发到某个接口还是应当将其丢弃的交换机功能。转发（forwarding）是决定一个帧应该被导向哪个接口，并把该帧移动到那些接口的交换机功能。交换机的过滤和转发借助于交换机表（switch table）完成。该交换机表包含某局域网上某些主机和路由器的但不必是全部的表项。交换机表中的一个表项包含：①一个 MAC 地址；②通向该 MAC 地址的交换机接口；③表项放置在表中的时间。图 5-22 中显示了图 5-15 中最上方交换机的交换机表的一个例子。

地址	接口	时间
62-FE-F7-11-89-A3	1	9:32
7C-BA-B2-B4-91-10	3	9:36
...	...	...

图 5-22 图 5-15 中最上面交换机的交换机表的一部分

尽管帧转发的描述听起来类似于第 4 章讨论的数据转发，但我们将很快看到它们之间有重要的差异。一个重要差异是交换机转发分组基于 MAC 地址而不是基于 IP 地址。我们也将看到交换机表与路由器的转发表构造方式有很大差别。

为了理解交换机过滤和转发的工作过程，假定目的地址为 DD-DD-DD-DD-DD-DD 的帧从交换机接口 x 到达。交换机用 MAC 地址 DD-DD-DD-DD-DD-DD 索引它的表。有 3 种可能的情况：

- 表中没有对于 DD-DD-DD-DD-DD-DD 的表项。在这种情况下，交换机向除接口 x 外的所有接口前面的输出缓存转发该帧的副本。换言之，如果没有对于目的地址的表项，交换机广播该帧。
- 表中有一个表项将 DD-DD-DD-DD-DD-DD 与接口 x 联系起来。在这种情况下，该帧从包括适配器 DD-DD-DD-DD-DD-DD 的局域网网段到来。无需将该帧转发到任何其他接口，交换机通过丢弃该帧执行过滤功能即可。
- 表中有一个表项将 DD-DD-DD-DD-DD-DD 与接口 $y \neq x$ 联系起来。在这种情况下，该帧需要被转发到与接口 y 相连的局域网网段。交换机通过将该帧放到接口 y 前面的输出缓存完成转发功能。

我们大致地看一下用于图 5-15 中最上面交换机的这些规则以及图 5-22 中所示的它的交换机表。假设目的地址为 62-FE-F7-11-89-A3 的一个帧从接口 1 到达该交换机。交换机检查它的表并且发现其目的地是在与接口 1 相连的局域网网段上（即电子工程系的局域网）。这意味着该帧已经在包含目的地的局域网网段广播过了。因此该交换机过滤（即丢弃）了该帧。现在假设有同样目的地址的帧从接口 2 到达。交换机再次检查它的表并且发现其目的地址在接口 1 的方向上；因此它向接口 1 前面的输出缓存转发该帧。这个例子清楚地表明，只要交换机的表是完整和准确的，该交换机无需任何广播就向着目的地转发帧。

在这种意义上，交换机比集线器更为“聪明”。但是一开始这个交换机表是如何配置起来的呢？链路层有与网络层路由选择协议等价的协议吗？或者必须要一名超负荷工作的管理员人工地配置交换机表吗？

2. 自学习

交换机具有令人惊奇的特性（特别是对于早已超负荷工作的网络管理员），那就是它的表是自动、动态和自治地建立的，即没有来自网络管理员或来自配置协议的任何干预。换句话说，交换机是自学习（self-learning）的。这种能力是以如下方式实现的：

- 1) 交换机表初始为空。
- 2) 对于在每个接口接收到的每个入帧，该交换机在其表中存储：①在该帧源地址字段中的 MAC 地址；②该帧到达的接口；③当前时间。交换机以这种方式在它的表中记录了发送结点所在的局域网网段。如果在局域网上的每个结点最终都发送了一个帧，则每个结点最终将在这张表中留有记录。
- 3) 如果在一段时间（称为老化期（aging time））后，交换机没有接收到以该地址作为源地址的帧，就在表中删除这个地址。以这种方式，如果一台 PC 被另一台 PC（具有不同的适配器）代替，原来 PC 的 MAC 地址将最终从该交换机表中被清除掉。

我们粗略地看一下用于图 5-15 中最上面交换机的自学习性质以及在图 5-22 中它对应的交换机表。假设在时刻 9:39，源地址为 01-12-23-34-45-56 的一个帧从接口 2 到达。假设这个地址不在交换机表中。于是交换机在其表中增加一个新的表项，如图 5-23 中所示。

地址	接口	时间
01-12-23-34-45. 56	2	9:39
62-FE-F7-11-89-A3	1	9:32
7C-BA-B2-B4-91-10	3	9:36
...	...	...

图 5-23 交换机学习到地址为 01-12-23-34-45-56 的适配器所在的位置

继续这个例子，假设该交换机的老化期是 60 分钟，在 9:32 ~ 10:32 期间源地址是 62-FE-F7-11-89-A3 的帧没有到达该交换机。那么在时刻 10:32，这台交换机将从它的表中删除该地址。

交换机是即插即用设备（plug-and-play device），因为它们不需要网络管理员或用户的干预。要安装交换机的网络管理员除了将局域网网段与交换机的接口相连外，不需要做其他任何事。管理员在安装交换机或者当某主机从局域网网段之一被去除时，他没有必要配置交换机表。交换机也是双工的，这意味着任何交换机接口能够同时发送和接收。

3. 链路层交换机的性质

在描述了链路层交换机的基本操作之后，我们现在来考虑交换机的特色和性质。我们能够指出使用交换机的几个优点，它们不同于如总线或基于集线器的星形拓扑那样的广播链路：

- 消除碰撞。在使用交换机（不使用集线器）构建的局域网中，没有因碰撞而浪费的带宽！交换机缓存帧并且决不会在网段上同时传输多于一个帧。就像使用路由器一样，交换机的最大聚合带宽是该交换机所有接口速率之和。因此，交换机提供了比使用广播链路的局域网高得多的性能改善。
- 异质的链路。交换机将链路彼此隔离，因此局域网中的不同链路能够以不同的速率运行并且能够在不同的媒体上运行。例如，图 5-22 中最上面的交换机有 3 条 1Gbps 1000BASE-T 铜缆链路、2 条 100Mbps 10BASE-FX 光缆链路和 1 条 100BASE-T 铜缆链路。因此，对于原有的设备与新设备混用，交换机是理想的。
- 管理。除了提供强化的安全性（参见插入材料“关注安全性”），交换机也易于进行网络管理。例如，如果一个适配器工作异常并持续发送以太网帧（称为快而含糊的（jabbering）适配器），交换机能够检测到该问题，并在内部断开异常适配器。有了这种特色，网络管理员不用起床并开车到工作场所去解决这个问题。类似地，一条割断的缆线仅使得使用该条缆线连接到交换机的主机断开连接。在使用同轴电缆的时代，许多网络管理员花费几个小时“沿线巡检”（或者更准确地说“在天花板上爬行”），以找到使整个网络瘫痪的电缆断开之处。如在第 9 章（网络管理）中讨论的那样，交换机也收集带宽使用的统计数据、碰撞率和流量类型，并使这些信息为网络管理者使用。这些信息能够用于调试和解决问题，并规划该局域网在未来应当演化的方式。研究人员还在原型系统部署中探讨在以太局域网中增加更多的管理功能 [Casado 2007; Koponen 2011]。

关注安全性

嗅探交换局域网：交换机毒化

当一台主机与某交换机相连时，它通常仅接收到明确发送给它的帧。例如，考虑在图 5-17 中的一个交换局域网。当主机 A 向主机 B 发送帧时，在交换机表中有用于主机 B 的表项，则该交换机将仅向主机 B 转发该帧。如果主机 C 恰好在运行嗅探器，主机 C 将不能够嗅探到 A 到 B 的帧。因此，在交换局域网的环境中（与如 802.11 局域网或基于集线器的以太局域网的广播链路环境形成对比），攻击者嗅探帧更为困难。然而，因为交换机广播那些目的地址不在交换机表中的帧，位于 C 上的嗅探器仍然能嗅探某些不是明确寻址到 C 的帧。此外，嗅探器将能够嗅探到具有广播地址 FF-FF-FF-FF-FF-FF 的广播帧。一个众所周知的对抗交换机的攻击称为交换机毒化（switch poisoning），它向交换机发送大量的具有不同伪造源 MAC 地址的分组，因而用伪造表项填满了交换机表，没有为合法主机留下空间。这使该交换机广播大多数帧，这些帧则能够由嗅探器俘获到 [Skoudis 2006]。由于这种攻击只有技艺高超的攻击者才能做到，因此交换机比起集线器和无线局域网来更难受到嗅探。

4. 交换机和路由器比较

如我们在第 4 章学习的那样，路由器是使用网络层地址转发分组的存储转发分组交换机。尽管交换机也是一个存储转发分组交换机，但它和路由器是根本不同的，因为它用 MAC 地址转发分组。交换机是第二层的分组交换机，而路由器是第三层的分组交换机。

即使交换机和路由器从根本上是不同的，网络管理员在安装互联设备时也经常必须在它们之间进行选择。例如，对于图 5-15 中的网络，网络管理员本来可以很容易地使用路由器而不是交换机来互联各个系的局域网、服务器和互联网网关路由器。路由器的确使得各系之间通信而不产生碰撞。既然交换机和路由器都是候选的互联设备，那么这两种方式的优点和缺点各是什么呢？

首先考虑交换机的优点和缺点。如上面提到的那样，交换机是即插即用的，这是世界上所有超负荷工作的网络管理员都喜爱的特性。交换机还能够具有相对高的分组过滤和转发速率，就像图 5-24 中所示的那样，交换机必须处理高至第二层的帧，而路由器必须处理高至第三层的数据报。在另一方面，为了防止广播帧的循环，交换网络的活跃拓扑限制为一棵生成树。另外，一个大型交换网络将要求在主机和路由器中有大的 ARP 表，这将生成可观的 ARP 流量和处理量。而且，交换机对于广播风暴并不提供任何保护措施，即如果某主机出了故障并传输出没完没了的以太网广播帧流，该交换机将转发所有这些帧，使得整个以太网的崩溃。




图 5-24 在交换机、路由器和主机中分组的处理

现在考虑路由器的优点和缺点。因为网络寻址通常是分层次的（不像 MAC 寻址那样是扁平的），即使当网络中存在冗余路径时，分组通常也不会通过路由器循环。（然而，当路由器表被误配置时，分组可能循环；但是如我们在第 4 章所知，IP 用一个特殊的报文首部字段来限制循环。）所以，分组就不会被限制到一棵生成树上，并可以使用源和目的地之间的最佳路径。因为路由器没有生成树限制，所以它们允许以丰富的拓扑结构构建因特网，例如包括欧洲和北美之间的多条活跃链路。路由器的另一个特色是它们对第二层的广播风暴提供了防火墙保护。尽管也许路由器最重要的缺点就是它们不是即插即用的，即路由器和连接到它们的主机都需要人为地配置 IP 地址。而且路由器对每个分组的处理时间通常比交换机更长，因为它们必须处理高达第三层的字段。最后，路由器一词有两种不同的发音方法，或者发音为“rootor”或发音为“rowter”，人们浪费了许多时间争论正确的发音 [Perlman 1999]。

给出了交换机和路由器各自具有的优点和缺点后（总结在表 5-1 中），一个机构的网络（例如，大学校园网或者公司园区网）什么时候应该使用交换机，什么时候应该使用路

由器呢？通常，由几百台主机组成的小网络通常有几个局域网网段。对于这些小网络，交换机就足够了，因为它们不要求 IP 地址的任何配置就能使流量局部化并增加总计吞吐量。但是在由几千台主机组成的更大网络中，通常在网络中（除了交换机之外）还包括路由器。路由器提供了更健壮的流量隔离方式和对广播风暴的控制，并在网络的主机之间使用更“智能的”路由。

对于交换网络和路由网络的优缺点的进一步讨论，以及如何能够将交换局域网技术扩展为比今天的以太网容纳多两个数量级以上的主机，参见 [Meyers 2004；Kim 2008]。

表 5-1 流行的互联设备的典型特色的比较

	集线器	路由器	交换机
流量隔离	无	有	有
即插即用	有	无	有
优化路由	无	有	无

5. 4. 4 虚拟局域网

在前面图 5-15 的讨论中，我们注意到现代机构的局域网常常是配置为等级结构的，每个工作组（部门）有自己的交换局域网，经过一个交换机等级结构与其他工作组的交换局域网互联。虽然这样的配置在理想世界中能够很好地工作，但在现实世界常常不尽如人意。在图 5-15 中的配置中，能够发现 3 个缺点：

- 缺乏流量隔离。尽管该等级结构把组流量局部化到一个单一交换机中，但广播流量（例如携带 ARP 和 DHCP 报文或那些目的地还没有被自学习交换机学习到的帧）仍然必须跨越整个机构网络。限制这些广播流量的范围将改善局域网的性能。也许更为重要的是，为了安全/隐私的目的也可能希望限制局域网广播流量。例如，如果一个组包括公司的行政管理团队，另一个组包括运行着 Wireshark 分组嗅探器的心怀不满的雇员，网络管理员也许非常希望行政流量无法到达该雇员的主机。通过用路由器代替图 5-15 中的中心交换机，能够提供这种类型的隔离。我们很快看到这种隔离也能够经过一种交换（第 2 层）解决方案来取得。
- 交换机的无效使用。如果该机构不止有 3 个组，而是有 10 个组，则将要求有 10 个第一级交换机。如果每个组都较小，比如说少于 10 个人，则单台 96 端口的交换机将足以容纳每个人，但这台单一的交换机将不能提供流量隔离。
- 管理用户。如果一个雇员在不同组间移动，必须改变物理布线，以将该雇员连接到图 5-15 中的不同的交换机上。属于两个组的雇员将使问题更为困难。

幸运的是，这些难题中的每个都能够通过支持虚拟局域网（Virtual Local Network, VLAN）的交换机来处理。顾名思义，支持 VLAN 的交换机允许经一个单一的物理局域网基础设施定义多个虚拟局域网。在一个 VLAN 内的主机彼此通信，仿佛它们（并且没有其他主机）与交换机连接。在一个基于端口的 VLAN 中，交换机的端口（接口）由网络管理员划分为组。每个组构成一个 VLAN，在每个 VLAN 中的端口形成一个广播域（即来自一个端口的广播流量仅能到达该组中的其他端口）。图 5-25 显示了具有 16 个端口的单一交换机。端口 2 ~ 8 属于电子工程系（EE）VLAN，而端口 9 ~ 15 属于计




图 5-25 配置了两个 VLAN 的单台交换机

计算机科学系 (CS) VLAN (端口 1 和 16 未分配)。这个 VLAN 解决了上面提到的所有困难, 即 EE VLAN 帧和 CS VLAN 帧彼此隔离, 图 5-15 中的两台交换机已由一台交换机替代, 并且在交换机端口 8 的用户加入计算机科学系时, 网络操作员只需重新配置 VLAN 软件, 使得端口 8 与 CS VLAN 相关联即可。人们容易想象到 VLAN 交换机配置和操作的方法, 即网络管理员使用交换机管理软件声明一个端口属于某个给定的 VLAN (其中未声明的端口属于一个默认的 VLAN), 在交换机中维护一张端口到 VLAN 的映射表; 交换机软件仅在属于相同 VLAN 的端口之间交付帧。

但完全隔离两个 VLAN 带来了新的困难! 来自电子工程系的流量怎样才能发送到计算机科学系呢? 解决这个问题的一种方式是将 VLAN 交换机的一个端口 (例如在图 5-25 中的端口 1) 与一台外部的路由器相连, 并且将该端口配置为属于 EE VLAN 和 CS VLAN。在此情况下, 即使电子工程系和计算机科学系共享相同的物理交换机, 其逻辑配置看起来也仿佛是电子工程系和计算机科学系具有分离的经路由器连接的交换机。从电子工程系发往计算机科学系的数据报将首先跨越 EE VLAN 到达路由器, 然后由该路由器转发跨越 CS VLAN 到达 CS 主机。幸运的是交换机厂商使这种配置变得容易, 网络管理员通过构建包含一台 VLAN 交换机和一台路由器的单一设备, 这样就不再需要分离的外部路由器了。本章后面的课后习题中更为详细地探讨了这种情况。

再次返回到图 5-15, 我们现在假设计算机工程系没有分离开来, 某些电子工程和计算机科学教职员工位于一座建筑物中, 他们当然需要网络接入, 并且他们希望成为他们系 VLAN 的一部分。图 5-26 显示了第二台 8 端口交换机, 其中交换机端口已经根据需要定义为属于 EE VLAN 或 CS VLAN。但是这两台交换机应当如何互联呢? 一种容易的解决方案是在每台交换机上定义一个属于 CS VALN 的端口 (对 EE VLAN 也类似处理), 并且如图 5-26a 所示将这两个端口彼此互联起来。然而, 这种解决方案不具有扩展性, 因为在每台交换机上 N 个 VLAN 将要求 N 个端口直接互联这两台交换机。




图 5-26 连接具有两个 VLAN 的两台 VLAN 交换机

一种更具扩展性互联 VLAN 交换机的方法称为 VLAN 干线连接 (VLAN trunking)。在图 5-26b 所示的 VLAN 干线方法中, 每台交换机上的一个特殊端口 (左侧交换机上的端口

16，右侧交换机上的端口 1) 被配置为干线端口，以互联这两台 VLAN 交换机。该干线端口属于所有 VLAN，发送到任何 VLAN 的帧经过干线链路转发到其他交换机。但这会引起另外的问题：一个交换机怎样知道到达干线端口的帧属于某个特定的 VLAN 呢？IEEE 定义了一种扩展的以太网帧格式——802.1Q，用于跨越 VLAN 干线的帧。如图 5-27 中所示，802.1Q 帧由标准以太网帧与加进首部的 4 字节 VLAN 标签（VLAN tag）组成，而 VLAN 标签承载着该帧所属的 VLAN 标识符。VLAN 标签由在 VLAN 干线发送侧的交换机加进帧中，解析后并由在 VLAN 干线接收侧的交换机删除。VLAN 标签自身由一个 2 字节的标签协议标识符（Tag Protocol Identifier, TPID）字段（具有固定的十六进制值 81-00）、一个 2 字节的标签控制信息字段（包含一个 12 比特的 VLAN 标识符字段）和一个 3 比特优先权字段（具有类似于 IP 数据报 TOS 字段的的目的）组成。




图 5-27 初始的以太网帧（上部），802.1Q 标签以太网 VLAN 帧（下部）

在这部分讨论中，我们仅仅简要地涉及了 VLAN，关注了基于端口的 VLAN。我们也应当提及 VLAN 能够以几种其他方式定义。在基于 MAC 的 VLAN 中，网络管理员指定属于每个 VLAN 的 MAC 地址的集合；无论何时一个设备与一个端口连接时，端口基于设备的 MAC 地址将其连接进适当的 VLAN。VLAN 也能基于网络层协议（例如 IPv4、IPv6 或 Appletalk）和其他准则进行定义。详情请参见 802.1Q 标准 [IEEE 802.1q 2005]。

5.5 链路虚拟化：网络作为链路层

因为本章关注链路层协议，所以在我们临近该章结束的时候，让我们反思一下对已经演化的词汇链路的理解。在本章开始时，我们将链路视为连接两台通信主机的物理线路。在学习多路访问协议时，我们看到了多台主机能够通过一条共享的线路连接起来，并且连接主机的这种“线路”能够是无线电频谱或其他媒体。这使我们将该链路更多地抽象为一条信道，而不是作为一条线路。在我们学习以太局域网时（图 5-15），我们看到互联媒体实际上能够是一种相当复杂的交换基础设施。然而，经过这种演化，主机本身维持着这样的视图，即互联媒体只是连接两台或多台主机的链路层信道。我们看到，例如一台以太网主机不知道它是通过单一短局域网网段（图 5-7）还是通过地理上分布的交换局域网（图 5-15）或通过 VLAN 与其他局域网主机进行连接，这是很幸福的事。

在两台主机之间由拨号调制解调器连接的场合，连接这两台主机的链路实际上是电话网，这是一个逻辑上分离的、全球性的电信网络，它有自己的用于数据传输和信令的交换机、链路和协议栈。然而，从因特网链路层的观点看，通过电话网的拨号连接被看做一根简单的“线路”。在这个意义上，因特网虚拟化电话网，将电话网看成为两台因特网主机之间提供链路层连接的链路层技术。你可能回想起在第 2 章中对于覆盖网络的讨论，类

似地，一个覆盖网络将因特网视为为覆盖结点之间提供连接性的一种手段，寻求以因特网覆盖电话网的相同方式来覆盖因特网。

在本节中，我们将考虑多协议标签交换（MPLS）网络。与电路交换的电话网不同，MPLS 客观上讲是一种分组交换的虚电路网络。它们有自己的分组格式和转发行为。因此，从教学法的观点看，有关 MPLS 的讨论既适合放在网络层的学习中，也适合放在链路层的学习中。然而，从因特网的观点看，我们能够认为 MPLS 像电话网和交换以太网一样，作为为 IP 设备提供互联服务的链路层技术。因此，我们将在链路层讨论中考虑 MPLS。帧中继和 ATM 网络也能用于互联 IP 设备，虽然这些技术看上去有些过时（但仍在部署），这里将不再讨论；详情请参见一本可读性强的书 [Goralski 1999]。我们对 MPLS 的讨论将是简明扼要的，因为有关这些网络每个都能够写（并且已经写了）整本书。有关 MPLS 详情我们推荐 [Davie 2000]。我们这里主要关注这些网络怎样为互联 IP 设备提供服务，尽管我们也将更深入一些探讨支撑基础技术。

多协议标签交换

通过采用虚电路网络领域的一个关键概念——固定长度标签，多协议标签交换（Multiprotocol Label Switching, MPLS）自 20 世纪 90 年代中后期在一些产业界的努力下进行演化，以改善 IP 路由器的转发速度。其目标是：对于基于固定长度标签和虚电路的技术，在不放弃基于目的地 IP 数据报转发的基础设施的前提下，当可能时通过选择性地标识数据报并允许路由器基于固定长度的标签（而不是目的地 IP 地址）转发数据报来增强其功能。重要的是，这些技术与 IP 协同工作，使用 IP 寻址和路由选择。IETF 在 MPLS 协议中统一了这些努力 [RFC 3031; RFC 3032]，有效地将虚电路技术综合进了路由选择的数据报网络。

首先考虑由 MPLS 使能的路由器处理的链路层帧格式，以此开始学习 MPLS。图 5-28 显示了在 MPLS 使能的路由器之间传输的一个链路层帧，该帧具有一个小的 MPLS 首部，该首部增加到第二层（如以太网）首部和第三层（即 IP）首部之间。RFC 3032 定义了用于这种链路的 MPLS 首部的格式；用于 ATM 和帧中继网络的首部也定义在其他的 RFC 文档中。包括在 MPLS 首部中的字段是：标签（它起着虚电路标识符的作用，我们已经在 4.2.1 节中讨论过该标识符）；3 比特的实验字段（保留用于实验）；单比特 S 字段用于指示一系列“成栈”的 MPLS 首部的结束（我们这里不讨论这个高级主题）；以及寿命字段。




图 5-28 MPLS 首部：位于链路层和网络层首部之间

从图 5-28 立即能够看出，一个 MPLS 加强的帧仅能在两个均为 MPLS 使能的路由器之间发送。（因为一个非 MPLS 使能的路由器，当它在期望发现 IP 首部的地方发现了一个 MPLS 首部时会相当混淆！）一个 MPLS 使能的路由器常被称为标签交换路由器（label-switched router），因为它通过在其转发表中查找 MPLS 标签，然后立即将数据报传递给适当的输出接口来转发 MPLS 帧。因此，MPLS 使能的路由器不需要提取目的 IP 地址和在转发表中执行最长前缀匹配的查找。但是路由器怎样才能知道它的邻居是否的确是 MPLS 使

能的呢？路由器如何知道哪个标签与给定 IP 目的地相联系呢？为了回答这些问题，我们需要看看一组 MPLS 使能路由器之间的交互过程。

在图 5-29 所示的例子中，路由器 R1 到 R4 都是 MPLS 使能的，R5 和 R6 是标准的 IP 路由器。R1 向 R2 和 R3 通告了它（R1）能够路由到目的地 A，并且具有 MPLS 标签 6 的接收帧将要转发到目的地 A。路由器 R3 已经向路由器 R4 通告了它能够路由到目的地 A 和 D，分别具有 MPLS 标签 10 和 12 的入帧将朝着这些目的地交换。路由器 R2 也向路由器 R4 通告了它（R2）能够到达目的地 A，具有 MPLS 标签 8 的接收帧将朝着 A 交换。注意到路由器 R4 现在处于一个到达 A 且有两个 MPLS 路径的令人感兴趣的位置上，经接口 0 具有出 MPLS 标签 10，经接口 1 具有出 MPLS 标签 8。在图 5-29 中画出的外围部分是 IP 设备 R5、R6、A 和 D，它们经过一个 MPLS 基础设施（MPLS 使能路由器 R1、R2、R3 和 R4）连接在一起，这与一个交换局域网或 ATM 网络能够将 IP 设备连接到一起的方式十分相似。并且与交换局域网或 ATM 网络相似，MPLS 使能路由器 R1 到 R4 完成这些工作时从没有接触分组的 IP 首部。




图 5-29 加强 MPLS 的转发

在我们上面的讨论中，我们并没有指定在 MPLS 使能路由器之间分布标签的特定协议，因为该信令的细节已经超出了本书的范围。然而，我们注意到，IETF 的 MPLS 工作组已经在 [RFC 3468] 中定义了 RSVP 协议的一种扩展，称之为 RSVP-TE [RFC 3209]，它将关注对 MPLS 信令所做的工作。我们也不讨论 MPLS 实际上是如何计算在 MPLS 使能路由器之间分组的路径的，也不讨论它如何收集链路状态信息（例如，未由 MPLS 预留的链路带宽量）以用于这些路径计算中。现有的链路状态路由选择算法（例如 OSPF）已经扩展为向 MPLS 使能路由器“洪泛”。令人感兴趣的是，实际路径计算算法没有标准化，它们当前是厂商特定的算法。

至今为止，我们关于 MPLS 的讨论重点基于这样的事实，MPLS 基于标签执行交换，而不必考虑分组的 IP 地址。然而，MPLS 的真正优点和当前对 MPLS 感兴趣的原因并不在于交换速度的潜在增加，而在于 MPLS 使能的新的流量管理能力。如前面所述，R4 到 A 具有两条 MPLS 路径。如果转发在 IP 层基于 IP 地址执行，我们在第 4 章中学习的 IP 路由选择协议将只指定到 A 的单一最小费用的路径。所以，MPLS 提供了沿着多条路由转发分组的能力，使用标准 IP 路由选择协议这些路由将是不可能的。这是使用 MPLS 的一种简单形式的流量工

程 (traffic engineering) [RFC 3346; RFC3272; RFC 2702; Xiao 2000], 其中网络运行者能够超越普通的 IP 路由选择, 迫使某些流量沿着一条路径朝着某给定的目的地引导, 并且朝着相同目的地的其他流量沿着另一条路径流动 (无论是由于策略、性能或某些其他原因)。

将 MPLS 用于其他目的也是可能的。能用于执行 MPLS 转发路径的快速恢复, 例如, 经过一条预计算的无故障路径重路由流量来对链路故障作出反应 [Kar 2000; Huang 2002; RFC 3469]。最后, 我们注意到 MPLS 能够并且已经被用于实现所谓虚拟专用网 (Virtual Private Network, VPN)。在为用户实现一个 VPNR 的过程中, ISP 使用它的 MPLS 使能网络将用户的各种网络连接在一起。MPLS 能被用于将资源和由用户的 VPN 使用的寻址方式相隔离, 其他用户利用该 VPN 跨越该 ISP 网络, 详情参见 [DeClercq 2002]。

这里有关 MPLS 的讨论是简要的, 我们鼓励读者参阅我们提到的这些文献。我们注意到对 MPLS 有许多可能的用途, 看起来它将迅速成为因特网流量工程的瑞士军刀!

5.6 数据中心网络

近年来, 因特网公司如谷歌、微软、脸谱 (Facebook) 和亚马逊 (以及它们在亚洲和欧洲的同业) 已经构建了大量的数据中心。每个数据中心都容纳了数万至数十万台主机, 并且同时支持着很多不同的云应用 (例如搜索、电子邮件、社交网络和电子商务)。每个数据中心都有自己的数据中心网络 (data center network), 这些数据中心网络将其内部主机彼此互联并与因特网中的数据中心互联。在本节中, 我们简要介绍用于云应用的数据中心网络。

大型数据中心的投资巨大, 一个有 100 000 台主机的数据中心每个月的费用超过 1200 万美元 [Greenberg 2009a]。在该费用中, 用于主机自身的开销占 45% (每 3~4 年需要更新一次); 变压器、不间断电源系统、长时间断电时使用的发电机以及冷却系统等基础设施的开销占 25%; 用于功耗的电力设施的开销占 15%; 用于联网的开销占 15%, 这包括了网络设备 (交换机、路由器和负载均衡设备)、外部链路以及传输流量的开销。(在这些比例中, 设备费用是分期偿还的, 因此费用通常是由一次性购买和持续开销 (如能耗) 构成的。) 尽管联网不是最大的费用, 但是网络创新是减少整体成本和性能最大化的关键 [Greenberg 2009a]。

主机就像是数据中心的工蜂: 它们负责提供内容 (例如, 网页和视频), 存储邮件和文档, 并共同执行大规模分布式计算 (例如, 为搜索引擎提供分布式索引计算)。数据中心中的主机称为刀片 (blade), 与比萨饼盒类似, 一般是包括 CPU、内存和磁盘存储的商用主机。主机被堆叠在机架上, 每个机架一般堆放 20~40 台刀片。在每一个机架顶部有一台交换机, 这台交换机被形象地称为机架顶部 (Top of Rack, TOR) 交换机, 它们与机架上的主机互联, 并与数据中心中的其他交换机互联。具体来说, 机架上的每台主机都有一块与 TOR 交换机连接的网卡, 每台 TOR 交换机有额外的端口能够与其他 TOR 交换机连接。尽管目前主机通常有 1Gbps 的以太网与其 TOR 交换机连接, 但 10Gbps 的连接也许成为标准。每台主机也会分配一个自己的数据中心内部的 IP 地址。

数据中心网络支持两种类型的流量: 在外部客户与内部主机之间流动的流量, 以及内部主机之间流动的流量。为了处理外部客户与内部主机之间流动的流量, 数据中心网络包括了一台或者多台边界路由器 (border router), 它们将数据中心网络与公共因特网相连。数据中心网络因此需要将所有机架彼此互联, 并将机架与边界路由器连接。图 5-30 显示了一个数据中心网络的例子。数据中心网络设计 (data center network design) 是互联网络和协议设计的

艺术，该艺术专注于机架彼此连接和与边界路由器相连。近年来，数据中心网络的设计已经成为计算机网络研究的重要分支 [Al-Fares 2008; Greenberg 2009a; Greenberg 2009b; Mydotr 2009; Guo 2009; Chen 2010; Abu-Lib-deh 2010; Alizadeh 2010; Wang 2010; Farrington 2010; Halperin2011; Wilson 2011; Mudigonda 2011; Ballani 2011; Curtis 2011; Raiciu 2011]。




图 5-30 具有等级拓扑的数据中心网络

5.6.1 负载均衡

一个云数据中心，如一个谷歌或者微软的数据中心，能够同时提供诸如搜索、电子邮件和视频应用等许多应用。为了支持来自外部客户的请求，每一个应用都与一个公开可见的 IP 地址关联，外部用户向该地址发送其请求并从该地址接收响应。在数据中心内部，外部请求首先被定向到一个负载均衡器（load balancer）。负载均衡器的任务是向主机分发请求，以主机当前的负载作为函数来在主机之间均衡负载。一个大型的数据中心通常会有几台负载均衡器，每台服务于一组特定的云应用。由于负载均衡器基于分组的目的端口号（第 4 层）以及目的 IP 地址做决策，因此它们常被称为“第 4 层交换机”。一旦接收到一个对于特定应用程序的请求，负载均衡器将该请求分发到处理该应用的某一台主机上（该主机可能再调用其他主机的服务来协助处理该请求）。当主机处理完该请求后，向负载均衡器回送响应，再由负载均衡器将其中继发回给外部客户。负载均衡器不仅平衡主机间的工作负载，而且还提供类似 NAT 的功能，将外部 IP 地址转换为内部适当主机的 IP 地址，然后将反方向流向客户的分组按照相反的转换进行处理。这防止客户直接接触主机，从而具有隐藏网络内部结构和防止客户直接与主机交互等安全性益处。

5.6.2 等级体系结构

对于仅有数千台主机的小型数据中心，一个简单的网络也许就足够了。这种简单网络由一台边界路由器、一台负载均衡器和几十个机架组成，这些机架由单一以太网交换机进行互联。但是当主机规模扩展到几万至几十万的时候，数据中心通常应用路由器和交换机等级结构（hierarchy of router and switch），图 5-30 显示了这样的拓扑。在该等级结构的顶端，边界路由器与接入路由器相连（在图 5-30 中仅仅显示了两台，但是能够有更多）。在每台接入路

由器下面，有3层交换机。每台接入路由器与一台顶层交换机相连，每台顶层交换机与多台二层交换机以及一台负载均衡器相连。每台二层交换机又通过机架的TOR交换机（第三层交换机）与多个机架相连。所有链路通常使用以太网作为链路层和物理层协议，并混合使用铜缆和光缆。通过这种等级式设计，可以将数据中心扩展到几十万台主机的规模。

因为云应用提供商持续地提供高可用性的应用是至关重要的，所以数据中心在它们的设计中也包含了冗余网络设备和冗余链路（在图5-30中没有显示出来）。例如，每台TOR交换机能够与两台二层交换机相连，每台接入路由器、一层交换机和二层交换机可以冗余并集成到设计中 [Cisco 2012; Greenberg 2009b]。在图5-30中的等级设计可以看到，每台接入路由器下的这些主机构成了单一子网。为了使ARP广播流量本地化，这些子网的每个都被进一步划分为更小的VLAN子网，每个由数百台主机组成 [Greenberg 2009a]。

尽管刚才描述的传统等级体系结构解决了扩展性问题，但是依然存在主机到主机容量受限的问题 [Greenberg 2009b]。为了理解这种限制，重新考虑图5-30，并且假设每台主机用1Gbps链路连接到它的TOR交换机，而交换机间的链路是10Gbps的以太网链路。在相同机架中的两台主机总是能够以1Gbps全速通信，而只受限于主机网络接口卡的速率。然而，如果在数据中心网络中同时存在多条并发流，则不同机架上的两台主机间的最大速率会小得多。为了深入理解这个问题，考虑不同机架上的40对不同主机间的40条并发流的情况。具体来说，假设图5-30中机架1上10台主机都向机架5上对应的主机发送一条流。类似地，在机架2和机架6的主机对上有10条并发流，机架3和机架7间有10条并发流，机架4和机架8间也有10条并发流。如果每一条流和其他流经同一条链路的流平均地共享链路容量，则经过10Gbps的A到B链路（以及10Gbps的B到C链路）的40条流中每条流获得的速率为 $10\text{Gbps}/40 = 250\text{Mbps}$ ，显著小于1Gbps的网络接口卡速率。如果主机间的流量需要穿过该等级结构的更高层，这个问题会变得更加严重。对这个限制的一种可行的解决方案是部署更高速率的交换机和路由器。但是这会大大增加数据中心的费用，因为具有高接口速率的交换机和路由器是非常昂贵的。

因为数据中心的一个关键需求是放置计算和服务的灵活性，所以支持主机到主机的高带宽通信十分重要 [Greenberg 200b; Farrington 2010]。例如，一个大规模的因特网搜索引擎可能运行在跨越多个机架的上千台主机上，在所有主机对之间具有极高的带宽要求。类似地，像EC2这样的云计算服务可能希望将构成用户服务的多台虚拟机运行在具有最大容量的物理主机上，而无需考虑它们在数据中心的位置。如果这些物理主机跨越了多个机架，前面描述的网络瓶颈可能会导致性能不佳。

5.6.3 数据中心网络的发展趋势

为了降低数据中心的费用，同时提高其在时延和吞吐量上的性能，因特网云服务巨头如谷歌、脸谱、亚马逊和微软都在不断地部署新的数据中心网络设计方案。尽管这些设计方案都是专有的，但是许多重要的趋势是一样的。

其中的一个趋势是部署能够克服传统等级设计缺陷的新型互联体系结构和网络协议。一种方法是采用全连接拓扑（fully connected topology）来替代交换机和路由器的等级结构 [Al-Fares 2008; Greenberg 2009b; Guo 2009]，图5-31中显示了这种拓扑。在这种设计中，每台第一层交换机都与所有第二层交换机相连，因此：①主机到主机的流量绝不会超过该交换机层次；②对于 n 台第一层交换机，在任意两台二层交换机间有 n 条不相交的路

径。这种设计可以显著地改善主机到主机的容量。为了理解该问题，重新考虑 40 条流的例子。图 5-31 中的拓扑能够处理这种流模式，因为在第 1 台二层交换机和第 2 台二层交换机间存在 4 条不相交的路径，可以一起为前两台二层交换机之间提供总和为 40Gbps 的聚合容量。这种设计不仅减轻了主机到主机的容量限制，同时创建了一种更加灵活的计算和服务环境。在这种环境中，任何未连接到同一台交换机的两个机架之间的通信在逻辑上是等价的，而不论其在数据中心的位置如何。




图 5-31 高度互联的数据网络拓扑

另外一个主要的趋势就是采用基于海运集装箱的模块化数据中心（Modular Data Center, MDC）[You Tube 2009; Waldrop 2007]。在 MDC 中，在一个标准的 12 米海运集装箱内，工厂构建一个“迷你数据中心”并将该集装箱运送到数据中心的位置。每一个集装箱都有多达数千台主机，堆放在数十台机架上，并且紧密地排列在一起。在数据中心位置，多个集装箱彼此互联，同时也和因特网连接。一旦预制的集装箱部署在数据中心，通常难以检修。因此，每一个集装箱都得设计为性能下降：当组件（服务器和交换机）随着时间的推移出现故障时，集装箱继续运行但是性能下降。当许多组件出现故障并且性能已经下降到低于某个阈值时，整个集装箱将会被移除，并用新的来替换。

创建由集装箱构成的数据中心提出了新的联网挑战。对于 MDC，有两种类型的网络：每一个集装箱中的内部网络和互联每个集装箱的核心网络 [Guo 2009; Farrington 2010]。在每个集装箱内部，在规模上升到数千台主机的时候，通过廉价的商用吉比特以太网交换机创建全连接的网络（如前面所描述）是可行的。然而，核心网络的设计仍然是一个带有挑战性的问题，这需要能互联成百上千的集装箱，同时能够为典型工作负载提供跨多个集装箱的主机到主机间的高带宽。[Farrington 2010] 中提出了一种互联集装箱的混合电/光交换机体系结构。

当采用高度互联拓扑的时候，一个主要的问题是设计交换机之间的路由选择算法。一种可能是采用随机路由选择方式 [Greenberg 2009b]。另一种可能是在每台主机中部署多块网络接口卡 [Guo 2009]，将每台主机连接到多台低成本的商用交换机上，并且允许主机自己在交换机间智能地为流量选路。这些方案的变种和扩展正被部署在当前的数据中心中。在数据中心设计中很可能会出现更多的创新；有兴趣的读者可以去阅读许多有关数据中心网络设计的论文。

5.7 回顾：Web 页面请求的历程

既然我们已经在本章中学过了链路层，并且在前面几章中学过了网络层、运输层和应用层，那么我们沿协议栈向下的旅程就完成了！在本书的一开始（1.1 节），我们说过“本书的大部分内容与计算机网络协议有关”，在本章中，我们无疑已经看到了情况的确如

此！在继续学习本书第二部分中时下关注的章节之前，通过对已经学过的协议做一个综合的、全面的展望，我们希望总结一下沿协议栈向下的旅程。而做这个“全面的”展望的一种方法是识别许多（许多！）协议，这些协议涉及满足甚至最简单的请求：下载一个 Web 页面。图 5-32 图示了我们的场景：一名学生 Bob 将他的便携机与学校的以太网交换机相连，下载一个 Web 页面（比如说 `www.google.com` 主页）。如我们所知，为满足这个看起来简单的请求，背后隐藏了许多细节。本章后面的 Wireshark 实验仔细检查了包含一些分组的踪迹文件，这些分组更为详细地涉及类似的场景。




图 5-32 Web 页请求的历程：网络环境和动作

5.7.1 准备：DHCP、UDP、IP 和以太网

我们假定 Bob 启动他的便携机，然后将其用一根以太网电缆连接到学校的以太网交换机，交换机又与学校的路由器相连，如图 5-32 所示。学校的这台路由器与一个 ISP 连接，本例中 ISP 为 `comcast.net`。在本例中，`comcast.net` 为学校提供了 DNS 服务；所以，DNS 服务器驻留在 Comcast 网络中而不是学校网络中。我们将假设 DHCP 服务器运行在路由器中，就像常见情况那样。

当 Bob 首先将其便携机与网络连接时，没有 IP 地址他就不能做任何事情（例如下载一个 Web 网页）。所以，Bob 的便携机所采取的一个网络相关的动作是运行 DHCP 协议，以从本地 DHCP 服务器获得一个 IP 地址以及其他信息。

1) Bob 便携机上的操作系统生成一个 DHCP 请求报文（4.4.2 节），并将这个报文放入具有目的地端口 67（DHCP 服务器）和源端口 68（DHCP 客户）的 UDP 报文段（3.3 节）该 UDP 报文段则被放置在一个具有广播 IP 目的地地址（255.255.255.255）和源 IP 地址 0.0.0.0 的 IP 数据报中（4.4.1 节），因为 Bob 的便携机还不具有一个 IP 地址。

2) 包含 DHCP 请求报文的 IP 数据报则被放置在以太网帧中（5.4.2 节）。该以太网帧具有目的 MAC 地址 `FF:FF:FF:FF:FF:FF`，使该帧将广播到与交换机连接的所有设备（如果顺利的话也包括 DHCP 服务器）；该帧的源 MAC 地址是 Bob 便携机的 MAC 地址

00:16:D3:23:68:8A。

3) 包含 DHCP 请求的广播以太网帧是第一个由 Bob 便携机发送到以太网交换机的帧。该交换机在所有的出端口广播入帧，包括连接到路由器的端口。

4) 路由器在它的具有 MAC 地址 00:22:6B:45:1F 的接口接收到该广播以太网帧，该帧中包含 DHCP 请求，并且从该以太网帧中抽取出 IP 数据报。该数据报的广播 IP 目的地址指示了这个 IP 数据报应当由在该结点的高层协议处理，因此该数据报的载荷（一个 UDP 报文段）被分解（3.2 节）向上到达 UDP，DHCP 请求报文从此 UDP 报文段中抽取出来。此时 DHCP 服务器有了 DHCP 请求报文。

5) 我们假设运行在路由器中的 DHCP 服务器能够以 CIDR（4.4.2 节）块 68.85.2.0/24 分配 IP 地址。所以本例中，在学校内使用的所有 IP 地址都在 Comcast 的地址块中。我们假设 DHCP 服务器分配地址 68.85.2.101 给 Bob 的便携机。DHCP 服务器生成包含这个 IP 地址以及 DNS 服务器的 IP 地址（68.87.71.226）、默认网关路由器的 IP 地址（68.85.2.1）和子网块（68.85.2.0/24）（等价为“网络掩码”）的一个 DHCP ACK 报文（4.4.2 节）。该 DHCP 报文被放入一个 UDP 报文段中，UDP 报文段被放入一个 IP 数据报中，IP 数据报再被放入一个以太网帧中。这个以太网帧的源 MAC 地址是路由器连到归属网络时接口的 MAC 地址（00:22:6B:45:1F:1B），目的 MAC 地址是 Bob 便携机的 MAC 地址（00:16:D3:23:68:8A）。

6) 包含 DHCP ACK 的以太网帧由路由器发送给交换机。因为交换机是自学习的（5.4.3 节），并且先前从 Bob 便携机收到（包含 DHCP 请求的）以太网帧，所以该交换机知道寻址到 00:16:D3:23:68:8A 的帧仅从通向 Bob 便携机的输出端口转发。

7) Bob 便携机接收到包含 DHCP ACK 的以太网帧，从该以太网帧中抽取 IP 数据报，从 IP 数据报中抽取 UDP 报文段，从 UDP 报文段抽取 DHCP ACK 报文。Bob 的 DHCP 客户则记录下它的 IP 地址和它的 DNS 服务器的 IP 地址。它还在其 IP 转发表中安装默认网关的地址（4.1 节）。Bob 便携机将向该默认网关发送目的地址为其子网 68.85.2.0/24 以外的所有数据报。此时，Bob 便携机已经初始化好它的网络组件，并准备开始处理 Web 网页获取。（注意到在第 4 章中给出的 4 个步骤中仅有最后两个 DHCP 步骤是实际必要的。）

5.7.2 仍在准备：DNS 和 ARP

当 Bob 将 www.google.com 的 URL 键入其 Web 浏览器时，他开启了一长串事件，这将导致谷歌主页最终显示在其 Web 浏览器上。Bob 的 Web 浏览器通过生成一个 TCP 套接字（2.7 节）开始了该过程，套接字用于向 www.google.com 发送 HTTP 请求（2.2 节）。为了生成该套接字，Bob 便携机将需要知道 www.google.com 的 IP 地址。我们在 2.5 节中学过，使用 DNS 协议提供这种名字到 IP 地址的转换服务。

8) Bob 便携机上的操作系统因此生成一个 DNS 查询报文（2.5.3 节），将字符串 www.google.com 放入 DNS 报文的问题段中。该 DNS 报文则放置在一个具有 53 号（DNS 服务器）目的端口的 UDP 报文段中。该 UDP 报文段则被放入具有 IP 目的地址 68.87.71.226（在第 5 步中 DHCP ACK 返回的 DNS 服务器地址）和源 IP 地址 68.85.2.101 的 IP 数据报中。

9) Bob 便携机则将包含 DNS 请求报文的数据报放入一个以太网帧中。该帧将发送（在链路层寻址）到 Bob 学校网络中的网关路由器。然而，即使 Bob 便携机经过上述第 5 步中的 DHCP ACK 报文知道了学校网关路由器的 IP 地址（68.85.2.1），但仍不知道该网

关路由器的 MAC 地址。为了获得该网关路由器的 MAC 地址，Bob 便携机将需要使用 ARP 协议（5.4.1 节）。

10) Bob 便携机生成一个具有目的 IP 地址 68.85.2.1（默认网关）的 ARP 查询报文，将该 ARP 报文放置在一个具有广播目的地址（FF:FF:FF:FF:FF:FF）的以太网帧中，并向交换机发送该以太网帧，交换机将该帧交付给所有连接的设备，包括网关路由器。

11) 网关路由器在通往学校网络的接口上接收到包含该 ARP 查询报文的帧，发现在 ARP 报文中目标 IP 地址 68.85.2.1 匹配其接口的 IP 地址。网关路由器因此准备一个 ARP 回答，指示它的 MAC 地址 00:22:6B:45:1F:1B 对应 IP 地址 68.85.2.1。它将 ARP 回答放在一个以太网帧中，其目的地址为 00:16:D3:23:68:8A（Bob 便携机），并向交换机发送该帧，再由交换机将帧交付给 Bob 便携机。

12) Bob 便携机接收包含 ARP 回答报文的帧，并从 ARP 回答报文中抽取网关路由器的 MAC 地址（00:22:6B:45:1F:1B）。

13) Bob 便携机现在（最终！）能够使包含 DNS 查询的以太网帧寻址到网关路由器的 MAC 地址。注意到在该帧中的 IP 数据报具有 IP 目的地址 68.87.71.226（DNS 服务器），而该帧具有目的地址 00:22:6B:45:1F:1B（网关路由器）。Bob 便携机向交换机发送该帧，交换机将该帧交付给网关路由器。

5.7.3 仍在准备：域内路由选择到 DNS 服务器

14) 网关路由器接收该帧并抽取包含 DNS 查询的 IP 数据报。路由器查找该数据报的目的地址（68.87.71.226），并根据其转发表决定该数据报应当发送到图 5-32 的 Comcast 网络中最左边的路由器。IP 数据报放置在链路层帧中，该链路适合将学校路由器连接到最左边 Comcast 路由器，并且该帧经这条链路发送。

15) 在 Comcast 网络中最左边的路由器接收到该帧，抽取 IP 数据报，检查该数据报的目的地址（68.87.71.226），并根据其转发表确定出接口，经过该接口朝着 DNS 服务器转发数据报，而转发表已根据 Comcast 的域内协议（如 RIP、OSPF 或 IS-IS，4.6 节）以及因特网的域间协议 BGP 所填写。

16) 最终包含 DNS 查询的 IP 数据报到达了 DNS 服务器。DNS 服务器抽取出 DNS 查询报文，在它的 DNS 数据库中查找名字 www.google.com（2.5 节），找到包含对应 www.google.com 的 IP 地址（64.233.169.105）的 DNS 源记录。（假设它当前缓存在 DNS 服务器中。）前面讲过这种缓存数据源于 google.com 的权威 DNS 服务器（2.5.2 节）。该 DNS 服务器形成了一个包含这种主机名到 IP 地址映射的 DNS 回答报文，将该 DNS 回答报文放入 UDP 报文段中，该报文段放入寻址到 Bob 便携机（68.85.2.101）的 IP 数据报中。该数据报将通过 Comcast 网络反向转发到学校的路由器，并从这里经过以太网交换机到 Bob 便携机。

17) Bob 便携机从 DNS 报文抽取出服务器 www.google.com 的 IP 地址。最终，在大量工作后，Bob 便携机此时准备接触 www.google.com 服务器！

5.7.4 Web 客户 - 服务器交互：TCP 和 HTTP

18) 既然 Bob 便携机有了 www.google.com 的 IP 地址，它能够生成 TCP 套接字（2.7 节），该套接字将用于向 www.google.com 发送 HTTP GET 报文（2.2.3 节）。当 Bob 生成 TCP 套接字时，在 Bob 便携机中的 TCP 必须首先与 www.google.com 中的 TCP 执行三次握手

(3.5.6 节)。Bob 便携机因此首先生成一个具有目的端口 80（针对 HTTP 的）的 TCP SYN 报文段，将该 TCP 报文段放置在具有目的 IP 地址 64.233.169.105（www.google.com）的 IP 数据报中，将该数据报放置在 MAC 地址为 00:22:6B:45:1F:1B（网关路由器）的帧中，并向交换机发送该帧。

19) 在学校网络、Comcast 网络和谷歌网络中的路由器朝着 www.google.com 转发包含 TCP SYN 的数据报，使用每台路由器中的转发表，如前面步骤 14 ~ 16 那样。前面讲过支配分组经 Comcast 和谷歌网络之间域间链路转发的路由器转发表项，是由 BGP 协议决定的（4.6.3 节）。

20) 最终，包含 TCP SYN 的数据报到达 www.google.com。从数据报抽取出 TCP SYN 报文并分解到与端口 80 相联系的欢迎套接字。对于谷歌 HTTP 服务器和 Bob 便携机之间的 TCP 连接生成一个连接套接字（2.7 节）。产生一个 TCP SYNACK（3.5.6 节）报文段，将其放入向 Bob 便携机寻址的一个数据报中，最后放入链路层帧中，该链路适合将 www.google.com 连接到其第一跳路由器。

21) 包含 TCP SYNACK 报文段的数据报通过谷歌、Comcast 和学校网络，最终到达 Bob 便携机的以太网卡。数据报在操作系统中分解到步骤 18 生成的 TCP 套接字，从而进入连接状态。

22) 借助于 Bob 便携机上的套接字，现在（最终！）准备向 www.google.com 发送字节了，Bob 的浏览器生成包含要获取的 URL 的 HTTP GET 报文（2.2.3 节）。HTTP GET 报文则写入套接字，其中 GET 报文成为一个 TCP 报文段的载荷。该 TCP 报文段放置进一个数据报中，并交付到 www.google.com，如前面步骤 18 ~ 20 所述。

23) 在 www.google.com 的 HTTP 服务器从 TCP 套接字读取 HTTP GET 报文，生成一个 HTTP 响应报文（2.2 节），将请求的 Web 页内容放入 HTTP 响应体中，并将报文发送进 TCP 套接字中。

24) 包含 HTTP 回答报文的数据报通过谷歌、Comcast 和学校网络转发，到达 Bob 便携机。Bob 的 Web 浏览器程序从套接字读取 HTTP 响应，从 HTTP 响应体中抽取 Web 网页的 html，并终于（最终！）显示了 Web 网页。

上面的场景已经涉及许多网络基础！如果你已经理解上面例子中的大多数或全部，则你也已经涵盖了许多基础知识，因为前面已经学过 1.1 节，其中我们谈道“本书的大部分内容与计算机网络协议有关”，并且你也许想知道一个协议实际是什么样子！上述例子看起来是尽可能详尽，我们已经忽略了一些可能的附加协议（例如，运行在学校网关路由器中的 NAT，到学校网络的无线接入，接入学校网络或对报文段或数据报加密的安全协议，网络管理协议），以及人们将会在公共因特网中遇到的一些考虑（Web 缓存，DNS 等级体系）。我们将在本书的第二部分涉及一些这类主题和更多内容。

最后，我们注意到上述例子是一个综合、完整的例子，还观察了本书第一部分所学习过的许多协议的十分“具体的细节”。该例子更多地关注“怎样做”而不是“为什么做”。对于想开阔视野的读者来说，有关网络协议设计更为深思熟虑的一般观点可参见 [Clark 1988; RFC 5218]。

5.8 小结

在这一章中，我们研究了链路层，包括它的服务、支撑它操作的原则和许多重要的特

定协议，它们使用这些原则实现了链路层服务。

我们看到链路层的基本服务是将网络层的数据报从一个结点（主机、交换机、路由器，WiFi 接入点）移动到一个相邻的结点。我们看到，在通过链路向相邻结点传输之前，所有链路层协议都是通过将网络层数据报封装在链路层帧中来操作的。然而，除了这个共同的成帧功能之外，我们知道了不同的链路层协议提供截然不同的链路接入、交付和传输服务。造成这些差异的部分原因是链路层协议必须工作在很多种链路类型上。一个简单的点对点链路具有单个发送方和接收方，并通过单一“线路”通信。一个多路访问链路在许多发送方和接收方之间共享；因此，对多路访问信道的链路层协议有一个协调链路接入的协议（它的多路访问协议）。在 MPLS 的情况下，连接两个相邻结点（例如，在 IP 意义上的两台相邻的 IP 路由器，它们是到某个目的地的下一跳 IP 路由器）的“链路”，其本身可能实际上就是一个网络。从某种意义上来说，将一个网络视为一条“链路”的想法没有什么可奇怪的。例如，连接家庭调制解调器/计算机到远端调制解调器/路由器的一条电话链路，实际上是一条穿过精密而复杂的电话网络的路径。

在链路层通信所依据的原理中，我们研究了差错检测和纠正技术、多路访问协议、链路层寻址、虚拟化（VLAN）以及扩展的交换局域网和数据中心网络的构造方法。今天对链路层的许多关注在于这些交换网络。在差错检测/纠正场景中，为了对帧通过链路传输时可能发生的比特翻转进行检测并在某些情况下进行纠正，我们研究了在帧的首部增加附加比特的方法。我们讨论了简单的奇偶校验和检验和方案，以及更健壮的循环冗余检测。然后我们转向多路访问协议主题。我们确定和学习了协调访问广播信道的 3 大类方法：信道划分方法（TDM、FDM）、随机接入方法（ALOHA 协议和 CSMA 协议）和轮流方法（轮询和令牌传递）。我们学习了电缆接入网，发现它使用了多种这些多路访问方法。我们看到让多个结点共享单个广播信道的结果，是需要在链路层提供结点地址。我们知道物理地址和网络层地址是非常不同的，而且在因特网场景中，一个专门的协议（ARP，即地址解析协议）用于在这两种寻址形式之间进行转换，并且详细学习了极为成功的以太网协议。然后我们研究了共享一个广播信道的结点是怎样形成一个局域网的，以及多个局域网怎样能够互联形成一个更大的局域网，即互联这些本地结点完全不需要网络层路由选择的干预。我们也知道了多个虚拟局域网是怎样能够产生一个单一的物理局域网体系结构的。

通过关注当 MPLS 网络互联 IP 路由器时是如何提供链路层服务的和展望今天用于大型数据中心的网络设计，我们结束了链路层的学习。通过识别在获取一个简单的 Web 网页时所需要的许多协议，我们完成了本章（实际上是前 5 章）。在学习了链路层后，我们沿协议栈向下的旅程现在结束了！当然，物理层位于数据链路层之下，但是物理层的细节也许最好留给另外一门课程（例如，在通信理论而不是计算机网络课程中）去学习。然而我们在本章和第 1 章（在 1.2 节中讨论了物理媒体）中已经接触了物理层的几个方面。当我们在下一章中学习无线链路特性时，将再次考虑物理层。

尽管我们沿协议栈向下的旅程已结束，但我们计算机网络的学习仍然没有结束。在后面的 4 章中我们将讨论无线网络、多媒体网络、网络安全和网络管理。这 4 个主题不便放进任何一层中；实际上每个主题跨越了多个层次。因此理解这些主题（在某些网络教材中被称为高级主题）需要对协议栈所有层次都有坚实的基础，我们对链路层的学习已经完成了这样的基础！

课后习题和问题

复习题

5.1 ~ 5.2 节

- R1. 考虑在 5.1.1 节中的运输类比。如果一个乘客类比为数据报，什么类比于链路层帧？
- R2. 如果在因特网中的所有链路都提供可靠的交付服务，TCP 可靠传输服务将是多余的吗？为什么？
- R3. 链路层协议能够向网络层提供哪些可能的服务？在这些链路层服务中，哪些在 IP 中有对应的服务？哪些在 TCP 中有对应的服务？

5.3 节

- R4. 假设两个结点同时经一个速率为 R 的广播信道开始传输一个长度为 L 的分组。用 d_{prop} 表示这两个结点之间的传播时延。如果 $d_{\text{prop}} < L/R$ ，会出现碰撞吗？为什么？
- R5. 在 5.3 节中，我们列出了广播信道的 4 种希望的特性。这些特性中的哪些是时隙 ALOHA 所具有的？令牌传递具有这些特性中的哪些？
- R6. 在 CSMA/CD 中，在第 5 次碰撞后，结点选择 $K=4$ 的概率有多大？结果 $K=4$ 在 10Mbps 以太网上对应于多少秒的时延？
- R7. 使用人类在鸡尾酒会交互的类比来描述轮询和令牌传递协议。
- R8. 如果局域网有很大的周长时，为什么令牌环协议将是低效的？

5.4 节

- R9. MAC 地址空间有多大？IPv4 的地址空间呢？IPv6 的地址空间呢？
- R10. 假设结点 A、B 和 C（通过它们的适配器）都连接到同一个广播局域网。如果 A 向 B 发送数千个 IP 数据报，每个封装帧都有 B 的 MAC 地址，C 的适配器会处理这些帧吗？如果会，C 的适配器将会把这些帧中的 IP 数据报传递给 C 的网络层吗？如果 A 用 MAC 广播地址来发送这些帧，你的回答将有怎样的变化呢？
- R11. ARP 查询为什么要在广播帧中发送呢？ARP 响应为什么要在一个具有特定目的 MAC 地址的帧中发送呢？
- R12. 对于图 5-19 中的网络，路由器有两个 ARP 模块，每个都有自己的 ARP 表。同样的 MAC 地址可能出现在两张表中都出现吗？
- R13. 比较 10BASE-T、100BASE-T 和吉比特以太网的帧结构。它们有什么不同吗？
- R14. 考虑图 5-15。在 4.4 节的寻址意义下，有多少个子网呢？
- R15. 在一个支持 802.1Q 协议交换机上能够配置的 VLAN 的最大数量是多少？
- R16. 假设支持 K 个 VLAN 组的 N 台交换机经过一个干线协议连接起来。连接这些交换机需要多少端口？评价你的答案。

习题

- P1. 假设某分组的信息内容是比特模式 1110 0110 1001 1101，并且使用了偶校验方案。在采用二维奇偶校验方案的情况下，包含该检验比特的字段的值是什么？你的回答应该使用最小长度检验和字段。
- P2. 说明（举一个不同于图 5-5 中那个的例子）二维奇偶校验能够纠正和检测单比特差错。说明（举一个例子）某些双比特差错能够被检测但不能纠正。
- P3. 假设某分组的信息部分（图 5-3 中的 D ）包含 10 字节，它由字符串“Networking”的 8 比特无符号二进制 ASCII 表示组成。对该数据计算因特网检验和。
- P4. 考虑前一个习题，但此时假设这 10 字节包含：
 - a. 数字 1 到 10 的二进制表示。

b. 字母 B 到 K (大写) 的 ASCII 表示。

c. 字母 b 到 k (小写) 的 ASCII 表示。

计算这些数据的因特网检验和。

P5. 考虑 5 比特生成多项式, $G = 10011$, 并且假设 D 的值为 1010101010。 R 的值是什么?

P6. 考虑上一个习题, 这时假设 D 具有值:

a. 1001010101。

b. 0101101010。

c. 1010100000。

P7. 在这道习题中, 我们探讨 CRC 的某些性质。对于在 5.2.3 节中给出的生成多项式 $G (= 1001)$, 回答下列问题:

a. 为什么它能够检测数据 D 中的任何单比特差错?

b. 上述 G 能够检测任何奇数比特差错吗? 为什么?

P8. 在 5.3 节中, 我们提供了时隙 ALOHA 效率推导的概要。在本习题中, 我们将完成这个推导。

a. 前面讲过, 当有 N 个活跃结点时, 时隙 ALOHA 的效率是 $Np(1-p)^{N-1}$ 。求出使这个表达式最大化的 p 值。

b. 使用在 (a) 中求出的 p 值, 令 N 接近于无穷, 求出时隙 ALOHA 的效率。(提示: 当 N 接近于无穷时, $(1 - 1/N)^N$ 接近于 $1/e$ 。)

P9. 说明纯 ALOHA 的最大效率是 $1/(2e)$ 。注意: 如果你完成了上面的习题, 本习题就很简单了。

P10. 考虑两个结点 A 和 B, 它们都使用时隙 ALOHA 协议来竞争一个信道。假定结点 A 比结点 B 有更多的数据要传输, 并且结点 A 的重传概率 p_A 比结点 B 的重传概率 p_B 要大。

a. 给出结点 A 的平均吞吐量的公式。具有这两个结点的协议的总体效率是多少?

b. 如果 $p_A = 2p_B$, 结点 A 的平均吞吐量比结点 B 的要大两倍吗? 为什么? 如果不是, 你能够选择什么样的 p_A 和 p_B 使得其成立?

c. 一般而言, 假设有 N 个结点, 其中的结点 A 具有重传概率 $2p$ 并且所有其他结点具有重传概率 p 。给出表达式来计算结点 A 和其他任何结点的平均吞吐量。

P11. 假定 4 个活跃结点 A、B、C 和 D 都使用时隙 ALOHA 来竞争访问某信道。假设每个结点有无限个分组要发送。每个结点在每个时隙中以概率 p 尝试传输。第一个时隙编号为时隙 1, 第二个时隙编号为时隙 2, 等等。

a. 结点 A 在时隙 5 中首先成功的概率是多少?

b. 某个结点 (A、B、C 或 D) 在时隙 4 中成功的概率是多少?

c. 在时隙 3 中出现首个成功的概率是多少?

d. 这个 4 结点系统的效率是多少?

P12. 对 N 的下列值, 画出以 p 为函数的时隙 ALOHA 和纯 ALOHA 的效率。

a. $N = 15$ 。

b. $N = 25$ 。

c. $N = 35$ 。

P13. 考虑具有 N 个结点和传输速率为 R bps 的一个广播信道。假设该广播信道使用轮询进行多路访问 (有一个附加的轮询结点)。假设从某结点完成传输到后续结点允许传输之间的时间量 (即轮询时延) 是 d_{poll} 。假设在一个轮询周期中, 一个给定的结点允许至多传输 Q 比特。该广播信道的最大吞吐量是多少?

P14. 如图 5-33 所示, 考虑通过两台路由器互联的 3 个局域网。

a. 对所有的接口分配 IP 地址。对子网 1 使用形式为 192.168.1.xxx 的地址, 对子网 2 使用形式为 192.168.2.xxx 的地址, 对子网 3 使用形式为 192.168.3.xxx 的地址。

b. 为所有的适配器分配 MAC 地址。

- c. 考虑从主机 E 向主机 B 发送一个 IP 数据报。假设所有的 ARP 表都是最新的。就像在 5.4.1 节中对单路由器例子所做的那样，列举出所有步骤。
- d. 重复 (c)，现在假设在发送主机中的 ARP 表为空（并且其他表都是最新的）。

P15. 考虑图 5-33。现在我们用一台交换机代替子网 1 和子网 2 之间的路由器，并且将子网 2 和子网 3 之间的路由器标记为 R1。




图 5-33 由路由器互联的 3 个子网

- a. 考虑从主机 E 向主机 F 发送一个 IP 数据报。主机 E 将请求路由器 R1 帮助转发该数据报吗？为什么？在包含 IP 数据报的以太网帧中，源和目的 IP 和 MAC 地址分别是什么？
 - b. 假定 E 希望向 B 发送一个 IP 数据报，假设 E 的 ARP 缓存中不包含 B 的 MAC 地址。E 将执行 ARP 查询来发现 B 的 MAC 地址吗？为什么？在交付给路由器 R1 的以太网帧（包含发向 B 的 IP 数据报）中，源和目的 IP 和 MAC 地址分别是什么？
 - c. 假定主机 A 希望向主机 B 发送一个 IP 数据报，A 的 ARP 缓存不包含 B 的 MAC 地址，B 的 ARP 缓存也不包含 A 的 MAC 地址。进一步假定交换机 S1 的转发表仅包含主机 B 和路由器 R1 的表项。因此，A 将广播一个 ARP 请求报文。一旦交换机 S1 收到 ARP 请求报文将执行什么动作？路由器 R1 也会收到这个 ARP 请求报文吗？如果收到的话，R1 将向子网 3 转发该报文吗？一旦主机 B 收到这个 ARP 请求报文，它将向主机 A 回发一个 ARP 响应报文。但是它将发送一个 ARP 查询报文来请求 A 的 MAC 地址吗？为什么？一旦交换机 S1 收到来自主机 B 的一个 ARP 响应报文，它将做什么？
- P16. 考虑前面的习题，但是现在假设用一台交换机代替子网 2 和子网 3 之间的路由器，在这种新的场景中回答前面习题中的问题 (a) ~ (c)。
- P17. 前面讲过，使用 CSMA/CD 协议，适配器在碰撞之后等待 $K \cdot 512$ 比特时间，其中 K 是随机选取的。对于 $K = 100$ ，对于一个 10Mbps 的广播信道，适配器返回到第二步要等多长时间？对于 100Mbps 的广播信道来说呢？
- P18. 假设结点 A 和结点 B 在同一个 10Mbps 广播信道上，这两个结点的传播时延为 325 比特时间。假设对这个广播信道使用 CSMA/CD 和以太网分组。假设结点 A 开始传输一帧，并且在它传输结束之前结点 B 开始传输一帧。在 A 检测到 B 已经传输之前，A 能完成传输吗？为什么？如果回答是可以，则 A 错误地认为它的帧已成功传输而无碰撞。提示：假设在 $t = 0$ 比特时刻，A 开始传输一帧。在最坏的情况下，A 传输一个 $512 + 64$ 比特时间的最小长度的帧。因此 A 将在 $t = 512 + 64$ 比特时刻完成帧的传输。如果 B 的信号在比特时间 $t = 512 + 64$ 比特之前到达 A，则答案是否定的。在最坏的情况下，B 的信号什么时候到达 A？
- P19. 假设结点 A 和结点 B 在相同的 10Mbps 广播信道上，并且这两个结点的传播时延为 245 比特时间。假设 A 和 B 同时发送以太网帧，帧发生了碰撞，然后 A 和 B 在 CSMA/CD 算法中选择不同的 K 值。假设没有其他结点处于活跃状态，来自 A 和 B 的重传会碰撞吗？为此，完成下面的例子就足以说明问题了。假设 A 和 B 在 $t = 0$ 比特时间开始传输。它们在 $t = 245$ 比特时间都检测到了碰撞。假设 $K_A = 0$ ， $K_B = 1$ 。B 会将它的重传调整到什么时间？A 在什么时间开始发送？（注意：这些结点在返回第 2 步之后，必须等待一个空闲信道，参见协议。）A 的信号在什么时间到达 B 呢？B 在它预定的时刻抑制传输吗？
- P20. 在这个习题中，你将对一个类似于 CSMA/CD 的多路访问协议的效率进行推导。在这个协议中，时间分为时隙，并且所有适配器都与时隙同步。然而，和时隙 ALOHA 不同的是，一个时隙的长度

(以秒计) 比一帧的时间 (即传输一帧的时间) 小得多。令 S 表示一个时隙的长度。假设所有帧都有恒定长度 $L = kRS$, 其中 R 是信道的传输速率, k 是一个大整数。假定有 N 个结点, 每个结点都有无穷多帧要发送。我们还假设 $d_{\text{prop}} < S$, 以便所有结点在一个时隙时间结束之前能够检测到碰撞。这个协议描述如下:

- 对于某给定的时隙, 如果没有结点占有这个信道, 所有结点竞争该信道; 特别是每个结点以概率 p 在该时隙传输。如果刚好有一个结点在该时隙中传输, 该结点在后续的 $k-1$ 个时隙占有信道, 并传输它的整个帧。
- 如果某结点占用了信道, 所有其他结点抑制传输, 直到占有信道的这个结点完成了该帧的传输为止。一旦该结点传输完它的帧, 所有结点竞争该信道。

注意到此信道在两种状态之间交替: “生产性状态” (它恰好持续 k 个时隙) 和 “非生产性状态” (它持续随机数个时隙)。显然, 该信道的效率是 $k/(k+x)$, 其中 x 是连续的非生产性时隙的期望值。

- a. 对于固定的 N 和 p , 确定这个协议的效率。
- b. 对于固定的 N , 确定使该效率最大化的 p 值。
- c. 使用在 (b) 中求出的 p (它是 N 的函数), 确定当 N 趋向无穷时的效率。
- d. 说明随着帧长度变大, 该效率趋近于 1。

P21. 现在考虑习题 P14 中的图 5-33。对主机 A、两台路由器和主机 F 的各个接口提供 MAC 地址和 IP 地址。假定主机 A 向主机 F 发送一个数据报。当在下列场合传输该帧时, 给出在封装该 IP 数据报的帧中的源和目的 MAC 地址: (i) 从 A 到左边的路由器; (ii) 从左边的路由器到右边的路由器; (iii) 从右边的路由器到 F。还要给出到达每个点时封装在该帧中的 IP 数据报中的源和目的 IP 地址。

P22. 现在假定在图 5-33 最左边的路由器被一台交换机替换。主机 A、B、C 和 D 和右边的路由器以星形方式与这台交换机相连。当在下列场合传输该帧时, 给出在封装该 IP 数据报的帧中的源和目的 MAC 地址: (i) 从 A 到左边路由器; (ii) 从左边路由器到右边的路由器; (iii) 从右边的路由器到 F。还要给出到达每个点时封装在该帧中的 IP 数据报中源和目的 IP 地址。

P23. 考虑图 5-15。假定所有链路都是 100Mbps。在该网络中的 9 台主机和两台服务器之间, 能够取得的最大总聚合吞吐量是多少? 你能够假设任何主机或服务器能够向任何其他主机或服务器发送分组。为什么?

P24. 假定在图 5-15 中的 3 台连接各系的交换机用集线器来代替。所有链路是 100Mbps。现在回答习题 P23 中提出的问题。

P25. 假定在图 5-15 中的所有交换机用集线器来代替。所有链路是 100Mbps。现在回答在习题 23 中提出的问题。

P26. 在某网络中标识为 A 到 F 的 6 个结点以星形与一台交换机连接, 考虑在该网络环境中某个正在学习的交换机的运行情况。假定: (i) B 向 E 发送一个帧; (ii) E 向 B 回答一个帧; (iii) A 向 B 发送一个帧; (iv) B 向 A 回答一个帧。该交换机表初始为空。显示在这些事件的前后该交换机表的状态。对于每个事件, 指出在其上面转发传输的帧的链路, 并简要地评价你的答案。

P27. 在这个习题中, 我们探讨用于 IP 语音应用的小分组。小分组长度的一个主要缺点是链路带宽的较大比例被首部字节所消耗。基于此, 假定分组是由 P 字节和 5 字节首部组成。

- a. 考虑直接发送一个数字编码语音源。假定该源以 128kbps 的恒定速率进行编码。假设每个源向网络发送分组之前每个分组被完全填充。填充一个分组所需的时间是分组化时延 (packetization delay)。根据 L , 确定分组化时延 (以毫秒计)。
- b. 大于 20 毫秒的分组化时延会导致一个明显的、令人不快的回音。对于 $L = 1500$ 字节 (大致对应于一个最大长度的以太网分组) 和 $L = 50$ 字节 (对应于一个 ATM 信元), 确定该分组化时延。
- c. 对 $R = 622\text{Mbps}$ 的链路速率以及 $L = 1500$ 字节和 $L = 50$ 字节, 计算单台交换机的存储转发时延。
- d. 对使用小分组长度的优点进行评述。

- P28. 考虑图 5-25 中的单个交换 VLAN，假定一台外部路由器与交换机端口 1 相连。为 EE 和 CS 的主机和路由器接口分配 IP 地址。跟踪从 EE 主机向 CS 主机传送一个数据报时网络层和链路层所采取的步骤（提示：重读课文中对图 5-19 的讨论）。
- P29. 考虑显示在图 5-29 中的 MPLS 网络，假定路由器 R5 和 R6 现在是 MPLS 使能的。假定我们要执行流量工程，使从 R6 发往 A 的分组要经 R6-R4-R3-R1 交换到 A，从 R5 发向 A 的分组要过 R5-R4-R2-R1 交换。给出 R5 和 R6 中的 MPLS 表以及在 R4 中修改的表，使得这些成为可能。
- P30. 再次考虑上一个习题中相同的场景，但假定从 R6 发往 D 的分组经 R6-R4-R3 交换，而从 R5 发往 D 的分组经 R4-R2-R1-R3 交换。说明为使这些成为可能所有路由器中的 MPLS 表。
- P31. 在这个习题中，你将把已经学习过的因特网协议的许多东西拼装在一起。假设你走进房间，与以太网连接，并下载一个 Web 页面。从打开 PC 电源到得到 Web 网页，发生的所有协议步骤是什么？假设当你给 PC 加电时，在 DNS 或浏览器缓存中什么也没有。（提示：步骤包括使用以太网、DHCP、ARP、DNS、TCP 和 HTTP 协议。）明确指出在这些步骤中你如何获得网关路由器的 IP 和 MAC 地址。
- P32. 考虑在图 5-30 中具有等级拓扑的数据中心网络。假设现在有 80 对流，在第 1 和第 9 机架之间有 10 个流，在第 2 和第 10 机架之间有 10 个流，等等。进一步假设网络中的所有链路是 10Gbps，而主机和 TOR 交换机之间的链路是 1Gbps。
- a. 每条流具有相同的数据率；确定一条流的最大速率。
 - b. 对于相同的流量模式，对于图 5-31 中高度互联的拓扑，确定一条流的最大速率。
 - c. 现在假设有类似的流量模式，但在每个机架上涉及 20 台主机和 160 对流。确定对这两个拓扑的最大流速率。
- P33. 考虑图 5-30 中所示的等级网络，并假设该数据中心需要在其他应用程序之间支持电子邮件和视频分发。假定 4 个服务器机架预留用于电子邮件，4 个服务器机架预留用于视频。对于每个应用，所有 4 个机架必须位于某单一二层交换机之下，因为二层到一层链路没有充足的带宽来支持应用内部的流量。对于电子邮件应用，假定 99.9% 时间仅使用 3 个机架，并且视频应用具有相同的使用模式。
- a. 电子邮件应用需要使用第 4 个机架的时间比例有多大？视频应用需要使用第 4 个机架的时间比例有多大？
 - b. 假设电子邮件使用和视频使用是独立的，这两个应用需要其第 4 个机架的时间比例有多大（等价地，概率有多大）？
 - c. 假设对于一个应用服务器短缺的时间具为 0.001% 或更少（引起用户在极短时间内性能恶化）。讨论在图 5-31 中的拓扑能够怎样使用，使得仅 7 个机架被共同地分配给两个应用（假设拓扑能够支持所有流量）。

Wireshark 实验

在与本教科书配套的 Web 站点（<http://www.awl.com/kurose-rose>）上，你将找到一个 Wireshark 实验，该实验研究了 IEEE 802.3 协议的操作和以太网帧格式。第二个 Wireshark 实验研究了在家庭网络场景下所获取的分组踪迹。

人物专访

Simon S. Lam 是位于奥斯丁的 T 得克萨斯大学计算机科学系的教授和董事会主席。1971 ~ 1974 年，他在 UCLA 的 ARPA 网络测量中心工作，从事卫星和无线电分组交换方面的工作。他领导的研究组于 1993 年发明了安全套接字及其原型，这是第一个安全套接字层（称为安全网络编程），为此赢得了 2004 年 ACM 软件系统奖。他的研究兴趣在于网络协议和安全服务的设计和分析。他从华盛顿州立大学获得了电子工程学士学位（BSEE），从 UCLA 获得了硕士和博士学位。他于 2007 年当选美国国家工程院院士。



- 为什么您决定专注于网络?

当我于1969年秋季作为一名研究生新生来到UCLA时,我原来的意图是研究控制论。后来我参加了Leonard Kleinrock的排队论课程,他给我留下了深刻印象。不久后,我以排队系统的自适应控制作为可能的论文题目进行了研究。在1972年初,Larry Roberts启动了ARPAnet卫星系统项目(后来称为分组卫星)。Kleinrock教授请我参加该项目。我们做的第一件事是为时隙ALOHA协议引入一个简单而实用的回退算法。不久后,我发现了许多有趣的研究问题,如ALOHA的不稳定性问题和对自适应回退的需求,这些形成了我学位论文的核心。

- 20世纪70年代您开始了在UCLA的学生生涯,活跃于因特网的早期阶段。那时的情况怎样?那时人们对因特网将变成什么样有哪些大致想法?

那时的环境与我曾在产业界和学术界所见到的其他系统构建项目的确没什么不同。ARPAnet初始规定的目标是相当谨慎的,即提供从远程位置接入昂贵的计算机的手段,使许多科学家能够使用这些计算机。然而,随着分组卫星项目于1972年和分组无线电项目于1973年启动,ARPA的目标有了相当大的扩展。到了1973年,ARPA同时建造了3个不同的分组网络,对Vint Cerf和Bob Kahn来说研发互联策略变得有必要了。

回顾过去,所有这些网络方面的进步和进展被视为(我相信)符合逻辑的而不是虚幻的。没有人能够想象到今天的因特网规模和个人计算机的能力。在第一台PC出现之前有十多年时间。那时为了正确地做处理,多数学生以一系列穿孔卡片的形式提交他们的计算机程序以进行批处理。仅有某些学生能够直接接触计算机,而计算机通常位于一个受限的区域中。调制解调器速度缓慢且稀有。作为一名研究生,在书桌上我仅有一部电话机,使用铅笔和纸从事我的大部分工作。

- 您认为网络和因特网领域在未来将往何处发展?

在过去,因特网IP协议的简单性是它在竞争上取胜的最大法宝,并且成为网络互联事实上的标准。与它的竞争对手如20世纪80年代的X.25和20世纪90年代的ATM不同,IP能够在任何链路层联网技术之上运行,因为它仅提供尽力而为的数据报服务。因此,任何分组网络都能够连接到因特网上。

今天,IP的最大长处实际上成为了一种缺点。IP目前像一件紧身衣,限制了因特网向特定方向发展。近年来,许多研究人员仅将他们的努力重新定向到应用层上。在无线自组织网络、传感网络和卫星网络方面也做了大量研究工作。这些网络能够看作独立的系统或链路层系统,因为位于IP的紧身衣之外,所以它们能够繁荣发展。

许多人对于P2P系统可能作为新奇的因特网应用的平台而感到欢欣鼓舞。然而,P2P系统在使用因特网资源方面效率很低。我关注的一个问题是,随着因特网不断互联各种设备和支持未来的P2P使能的应用,因特网核心的传输和交换能力比起对因特网流量的需求来说,前者是否将更快地不断增加。没有大量的容量预留,在面临恶意攻击和拥塞时,确保网络稳定性将是一项重要的任务。

因特网的急剧增长也要求以高速率为全世界的网络操作者和企业分配新的IP地址。以当前速度,未分配的IP地址池将在几年内消耗殆尽。当该事件发生时,仅能从IPv6地址空间中分配大量地址空间的相邻块了。因为IPv6采用的启动缓慢,由于对早期用户缺乏激励,所以IPv4和IPv6将很有可能在今后的因特网上共存很多年。从IPv4主宰的因特网向IPv6主宰的因特网迁移将需要全球做出巨大的努力。

- 您的工作最具挑战性的部分是什么?

我的工作最具挑战性的部分是,作为一名教授传授和激发我课堂上的每个学生以及我所指导的每个博士研究生,而不只是获得重要的成就。非常聪明和有学习动力的人可能要求少量的引导而非许多其他东西。我经常从学生那里学到很多东西,比他们从我这里学到的多。教育和激励学术上落后的学生是一项重要的挑战。

- 您能预见到技术对未来学习方面有哪些影响?

最终几乎所有的人类知识将可以通过因特网得到,因特网将成为最为强有力的学习工具。这种巨大的知识库将具有为全世界的学生们提供公平竞争环境的潜力。例如,任何国家的有上进心的学生将能够访问最好课程的Web站点、多媒体演讲和教学材料。据说IEEE和ACM数字图书馆已经加速了中国的计算机科学研究的发展。与此同时,因特网将超越所有学习的地理障碍。